

بسم الله الرحمن الرحيم

وقل رب زدني علماً

باسمه تعالی



دانشگاه صنعتی مازکت اشتر

مجتمع دانشگاهی برق و کامپیوتر

سمینار کارشناسی ارشد رشته مهندسی کامپیوتر - هوش مصنوعی

عنوان

تطبیق دامنه در شبکه های عصبی عمیق برای کاربرد تشخیص اشیا در هنگام استفاده از داده های آموزشی مصنوعی

توسط

هلیا محمدی

استاد راهنما

دکتر محمدعلی کیوانراد

شهریور ماه ۱۴۰۲

فهرست مطالب

عنوان	صفحه
فهرست مطالب.....ج	
فهرست جدول‌ها.....۵	
فهرست شکل‌ها.....۶	
فصل ۱: مقدمه و کلیات.....۱۲	
۱-۱. مقدمه.....۱۲	
۱-۲. ضرورت انجام پژوهش.....۱۳	
۱-۳. انگیزه و هدف.....۱۳	
۱-۴. ساختار سمینار.....۱۴	
فصل ۲: مبانی نظری تحقیق.....۱۵	
۲-۱. مقدمه.....۱۵	
۲-۲. تشخیص اشیا.....۱۵	
۲-۲-۱. مدل‌های تشخیص دهنده یک مرحله‌ای.....۱۷	
۲-۲-۲. مدل‌های تشخیص دهنده دو مرحله‌ای.....۲۱	
۲-۳. تطبیق دامنه در یادگیری عمیق.....۲۴	
۲-۳-۱. روش‌های مبتنی بر اختلاف.....۲۵	
۲-۳-۲. روشهای خصمانه.....۲۷	
۲-۳-۳. تطابق چند دامنه ای.....۳۲	
۲-۳-۴. روشهای ترکیبی.....۳۴	
۲-۳-۵. تطبیق دامنه چند حالتی.....۳۴	
۲-۳-۶. روشهای نوظهور.....۳۷	
فصل ۳: مبانی تجربی تحقیق.....۳۹	
۳-۱. مقدمه.....۳۹	
۳-۲. تطبیق دامنه برای تشخیص اشیا.....۳۹	
۳-۲-۱. مقالات.....۳۹	
3-2-2. پایان‌نامه‌ها.....۵۴	
۳-۳. معیارهای ارزیابی.....۶۰	

۶۱	۳-۳-۱. معیارهای Precision و recall
۶۲	۳-۳-۲. معیار IoU
۶۲	۳-۳-۳. معیار mAP
۶۳	۳-۴. مجموعه داده‌گان
۶۳	۳-۴-۱. Cityscapes مجموعه داده
۶۴	۳-۴-۲. Foggy Cityscapes مجموعه داده
۶۵	۳-۴-۳. COCO مجموعه داده
۶۶	۳-۴-۴. Caltech مجموعه داده
۶۷	۳-۴-۵. SYNTHIA مجموعه داده
۶۸	۳-۴-۶. KITTI مجموعه داده
۶۹	۳-۴-۷. Pascal VOC مجموعه داده
۷۱	۳-۴-۸. SIM10K مجموعه داده
۷۱	۳-۴-۹. BDD100K مجموعه داده
۷۲	۳-۴-۱۰. YTBB مجموعه داده
۷۴	۳-۵. نتایج
۷۶	فصل 4 نتیجه‌گیری و پیشنهادها
۷۶	۴-۱. نتیجه‌گیری
۷۷	۴-۲. پیشنهاد کارهای آینده
۷۹	مراجع

فهرست جدول‌ها

شماره جدول	عنوان جدول	صفحه
جدول ۱	نتایج عملی تطبیق دامنه برای تشخیص اشیا در مقالات متناظر	۷۵.....

فهرست شکل‌ها

شماره شکل	عنوان شکل	صفحه
شکل ۱	نمونه ای از کار تشخیص اشیا	۱۶
شکل ۲	مثالی از ساختار یک بلوک residual learning	۱۷
شکل ۳	معماری شبکه YOLO [5]	۱۸
شکل ۴	ساختار هرمی معماری SSD [6]	۲۰
شکل ۵	معماری و ساختار FPN [7]	۲۱
شکل ۶	ساختار و نحوه عملکرد شبکه R-CNN [8]	۲۲
شکل ۷	ساختار و نحوه عملکرد شبکه Fast R-CNN [9]	۲۳
شکل ۸	ساختار و نحوه عملکرد شبکه Faster R-CNN [10]	۲۳
شکل ۹	ساختار/معماری شبکه معمولی شبکه‌های عصبی عمیق که روش‌های مبتنی بر اختلاف را برای تطبیق دامنه پیاده‌سازی می‌کنند. در این ساختار، لایه‌های استخراج ویژگی به اشتراک گذاشته می‌شوند منظم می‌شوند. لایه‌های بعدی، "لایه‌های تطبیق" شناخته می‌شوند که شامل معیارهای اختلاف یا نمایشی از شبکه به همراه متریک اختلاف است. لایه‌های خاص وظیفه نقش زیادی در تطبیق ویژگی‌های منبع و هدف ندارند [14].	۲۶
شکل ۱۰	ساختار/معماری شبکه‌های عصبی عمیق که روش‌های مبتنی بر خصومت را برای تطبیق دامنه پیاده‌سازی می‌کنند. مولد(ها) اختیاری هستند و در صورت نیاز فقط برای ایجاد داده‌های مصنوعی استفاده می‌شوند. متمایزکننده دامنه، به دنبال تمایز (طبقه بندی) دامنه های منبع و هدف است، در حالی که وظیفه خاص (مثلاً طبقه بندی یا تشخیص شی) توسط شبکه خاص وظیفه انجام می‌شود [14].	۲۹
شکل ۱۱	شبکه عصبی متخاصم دامنه‌ای (DANN) دو شبکه را همزمان آموزش می‌دهد. DANN یک استخراج‌کننده ویژگی (شبکه سبز) و پیش‌بینی‌کننده کلاس/پرچسب (شبکه آبی) را روی داده منبع آموزش می‌دهد. DANN همچنین یک استخراج‌کننده ویژگی (شبکه سبز) و طبقه‌بندی‌کننده دامنه (شبکه صورتی) را بر روی داده منبع و هدف آموزش می‌دهد. لایه تغییر گرادبان (GRL) به شبکه پیش‌روی اجازه می‌دهد تا به عنوان معمول پیش برود؛ با این حال، در زمان پس‌انتشار، گرادبان از تمییز دامنه تغییر می‌کند (برعکس می‌شود اما با یک مقدار منفی ضرب می‌شود) که منجر به درک ویژگی‌های ثابت دامنه (سردرگمی دامنه) توسط استخراج‌کننده ویژگی (شبکه سبز) می‌شود. پارامتر λ به یادگیری ویژگی‌های دسته‌بندی کمک می‌کند و به تدریج ویژگی‌های دامنه را یاد می‌گیرد [14].	۳۰

شکل ۱۲ ساختار معماری شبکه معمولی برای شبکه های عصبی عمیق که اجرای تطبیق دامنه چند منظوره همگن را انجام می دهند. در بلوک درون دامنه ای، تمیزدهنده ها ویژگی بردارها را مجبور می کنند تا ویژگی های بی تغییر در دامنه را یاد بگیرند. اما دو بلوک بین حوزه ای و بین دامنه ای اختیاری هستند و در هر تنظیم تطبیق دامنه چند منظوره ممکن است مشاهده نشوند [14]..... ۳۶

شکل ۱۳ ساختار روش Faster-RCNN Robust. این شبکه از مدل آموزش دیده در منبع برای به دست آوردن برچسب های نویزی در مجموعه داده دامنه مقصد استفاده می کند. یک ماژول دسته بندی برای به روزرسانی برچسب های نویزی استفاده می شود و کیفیت آنها را بهبود می بخشد. در نهایت، مدل تشخیص بر روی داده های دامنه مقصد با کمک یک تابع ضرر قوی آموزش می بیند که عدم قطعیت را جهت در نظر گرفتن احتمال اشتباهات ممکن در برچسب های نویزی شبه حاصل از مدل آموزش دیده در منبع می گیرد [41]..... ۴۰

شکل ۱۴ مقایسه کیفی روش فوق با Faster R-CNN در آزمایش Cityscapes → KITTI [41] ۴۰

شکل ۱۵ مروری بر معماری "Mean Teacher with Object Relations (MTOR)" برای تشخیص اشیا در دامنه های مختلف، با مدل های معلم و دانش آموز تحت یک backbone مشترک از Faster R-CNN [42]..... ۴۱

شکل ۱۶ معماری شبکه پیشنهادی. این روش با استفاده از یک شبکه تشخیص دهنده دامنه محلی و یک شبکه تشخیص دهنده دامنه جهانی تطبیق قوی محلی انجام می دهد و تطبیق ضعیف جهانی را به انجام می رساند. بردار متناظر از طریق تشخیص دهنده دامنه استخراج می شود و در لایه قبل از لایه کاملاً متصل نهایی ادغام می شود [43]..... ۴۲

شکل ۱۷ ساختار شبکه MAF. این شبکه الهام گرفته از Faster-RCNN مبتنی بر VGG16 است، MAF ماژول های تطبیق ویژگی را هم بر روی ویژگی های دامنه و هم بر روی ویژگی های پیشنهاد اعمال می کند. برای ماژول تطبیق ویژگی دامنه سلسله مراتبی، چندین زیرماژول تطبیق کننده دامنه متخاصم روی بلوک ۳، ۴، ۵ VGG16 پیاده سازی شده است. لایه های GRL برای استراتژی یادگیری تخصصی استفاده می شوند و اندازه نقشه های ویژگی توسط ماژول های کاهش مقیاس SRM کاهش می یابد. در ماژول تطبیق ویژگی، امتیازهای دسته بندی و نتایج بازیابی جعبه مرتبط با ویژگی ها در دامنه دسته بند ترکیب شده است و این در حالی است که WGRL برای استراتژی یادگیری تخصصی معرفی می شود. SRM از دو بخش تشکیل شده است، بخش اول یک لایه پیکسل های کانولوشن 1×1 است که برای کاهش اندازه کانال اعمال می شود. بعد از آن، بخش کاهش مقیاس برای ترکیب ویژگی های مجاور $s \times s$ استفاده می شود تا اندازه نقشه های ویژگی کاهش یابد [44]..... ۴۲

شکل ۱۸ یک نمای کلی از مدل Domain Adaptive Faster R-CNN. در این روش با دو سطح، سطح تصویر و سطح نمونه، تغییر دامنه مورد بررسی قرار داده شده است. در هر سطح، یک طبقه بند دامنه بر پایه ساخته شده است که به شیوه آموزش تخصصی آموزش داده می شود. یک تنظیم کننده

تناسب همراه با این دو طبقه‌بند در داخل این دو طبقه‌بند به منظور یادگیری یک RPN ثابت دامنه برای مدل Faster R-CNN وارد شده است [45]. ۴۳.....

شکل ۱۹ UDA با (MIC). در UDA، یک شبکه معمولاً با یک Loss نظارت شده در دامنه منبع (آبی) و یک تابع ضرر تطبیقی بدون نظارت در دامنه هدف (سبز) آموزش داده می‌شود. MIC سازگاری بین پیش‌بینی‌های تصاویر هدف پوشانده شده (بنفش) و برجسب‌های ساختگی که بر اساس تصویر کامل توسط (EMA Teacher) تولید می‌شوند، اعمال می‌کند. برای به حداقل رساندن Loss مربوط به MIC، شبکه باید بیاموزد که پیش‌بینی های مناطق پوشانده شده را از بافت آن‌ها استخراج کند [46]. ۴۵.....

شکل ۲۰ نمای کلی از روش ConfMix پیشنهادی. ما نمونه‌های منبع xs و نمونه‌های هدف xt را به مدل تشخیص دهنده $F(\theta)$ منتقل می‌کنیم و پیش‌بینی‌های ys و yt را به ترتیب دریافت می‌کنیم. ما ناحیه هدف با بالاترین اعتماد منطقی را برای تشکیل نمونه مخلوط xM با تصویر منبع انتخاب می‌کنیم، سپس این نمونه به مدل تشخیص دهنده $F(\theta)$ منتقل می‌شود و پیش‌بینی‌های yM را تولید می‌کند. ما مدل را با استفاده از دست دادن تشخیص نظارت شده با استفاده از اشارات منبع ys و از دست دادن تناسب خود-نظارتی با مقایسه yM با پیش‌بینی‌های ترکیبی منبع و هدف ys, t آموزش می‌دهیم [47]. ۴۶.....

شکل ۲۱ مروری بر چارچوب CycleGAN در این برنامه. G_N تصاویر را از دامنه روز به دامنه شب نگاشت می‌کند، در حالی که G_D نگاشت را به صورت معکوس انجام می‌دهد. تشخیص‌دهندگان D_D و D_N ارزیابی می‌کنند که آیا این تصویر واقعی است یا به ترتیب تصویر تقلبی در دامنه شب و روز است. محدودیت تطابق چرخه با استفاده از تابع ضرر L1 برای اطمینان از توانایی بازسازی مورد استفاده قرار می‌گیرد [51]. ۴۸.....

شکل ۲۲ بررسی کلی چارچوب رویکرد پیشنهادی TRKP. پیکان‌های سفید به انتقال به جلو اشاره دارند و پیکان‌های خط‌خورده نظارت را نمایان می‌کنند. تشخیص دهنده معلم بر روی تصاویر منبع دارای برجسب آموزش داده می‌شود و برجسب‌های سیاه برای تصاویر بدون برجسب در دامنه هدف تولید می‌کند که تشخیص کننده دانش آموز را راهنمایی می‌کند. TRKP از مازول تبادل چند-منبعی تخصصی (AMSD) برای حفظ دانش ویژگی‌های مخصوص دامنه منبع و از طرح معدن دانش کلی مرتبط با هدف (HTRM) برای تقویت تمرکز دانش مرتبط با هدف استفاده می‌کند، که به طور قابل توجهی به تطبیق دانش چند-منبع با دامنه هدف کمک می‌کند [52]. ۴۹.....

شکل ۲۳ شکل ۷ چارچوب پیشنهادی روش تطبیق دامنه پیشرو را نشان می‌دهد. الگوریتم شامل دو مرحله تطابق است، که در (a) و (b) نشان داده شده است. در (a)، ابتدا تصاویر منبع را تبدیل کرده و تصاویر مصنوعی را با استفاده از مولد G که از طریق CycleGAN یادگرفته شده است، تولید می‌شود. سپس از دامنه منبع با برجسب استفاده کرده و تطابق مرحله اول را با دامنه مصنوعی انجام

می‌دهیم. در b)، مدل یک تطابق مرحله دوم انجام می‌دهد که دامنه مصنوعی با برجسب‌های از منبع به ارث برده شده را می‌گیرد و ویژگی‌های دامنه مصنوعی را با توزیع هدف هماهنگ می‌کند. علاوه بر این، وزن w از تشخیص‌دهنده Dcycle در CycleGAN به منظور تعادل کیفیت تصاویر مصنوعی در از دست دادن تشخیص به دست می‌آید. ساختار کلی شبکه تطابق ما در c) نشان داده شده است. تصاویر با برجسب و بدون برجسب هر دو از طریق شبکه رمزگذار E منتقل می‌شوند تا ویژگی‌های CNN featL و featU استخراج شود. سپس از آنها برای: ۱) یادگیری تشخیص اشیا تحت نظر با شبکه تشخیص از featL استفاده می‌شود، و ۲) هر دو ویژگی را به GRL و یک تشخیص‌دهنده دامنه ارسال می‌کنیم تا ویژگی‌های بی‌دامنه را به صورت مقابله‌ای و با تحدید نوعی دامنه یادگرفته شود [53]. ۴۹.....

شکل ۲۴ نمونه‌هایی از نتایج تشخیص از سه وظیفه تطبیق روش تطبیق دامنه پیشرو. دو ردیف اول به ترتیب نتایج آزمایش KITTI به Cityscapes و Cityscapes به Foggy Cityscapes هستند، در حالی که دو ردیف آخر نتایج Cityscapes به BDD100k هستند. نتایج تشخیص روی دامنه مقصد قبل و بعد از اعمال روش تطبیق دامنه به همراه برجسب‌های واقعی نمایش داده شده است [53]. ۵۰.....

شکل ۲۵ معماری چارچوب تطبیق دامنه روش فوق برای تشخیص اشیا. این چارچوب بر پایه شبکه تشخیص اشیا ساخته شده است [54]. ۵۱.....

شکل ۲۶ توضیح مختصری از AsyFOD. پس از استخراج نقشه ویژگی تصاویر ورودی از طریق بخش اصلی، نمونه‌های ویژگی مرتبط با نمونه به وسیله مازول پروژه‌ای و حقایق ارائه شده استخراج می‌شوند. سپس، AsyFOD نمونه‌های منبع را به دو مجموعه تشخیص هدف مشابه (آبی تیره) و مجموعه تشخیص هدف نامشابه (آبی روشن) تقسیم می‌کند. نمونه‌های منبع مشابه هدف برای افزایش نمونه‌های هدف استفاده می‌شوند. با این تقسیم‌بندی، تطبیق ناهمگام بین نمونه‌های منبع نامشابه هدف و نمونه‌های هدف افزایش یافته انجام می‌شود که باعث کاهش یادگیری زودهنگام ناشی از توزیع داده‌های بسیار نامتعادل می‌شود. همچنین، AsyFOD آموزش نظارت شده متمرکز بر وظیفه را برای وظایف طبقه‌بندی و مکان‌یابی به طور جداگانه انجام می‌دهد. بهترین نمایش در حالت رنگی مشاهده می‌شود [61]. ۵۳.....

شکل ۲۷ ساختار DannFixbi برای رویکرد اول [63]. ۵۵.....

شکل ۲۸ ساختار DannFixbi برای رویکرد دوم [63]. ۵۵.....

شکل ۲۹ فلوچارت روشهای پیشنهادی تطبیق دامنه‌های افزایشی [66]. ۵۸.....

شکل ۳۰ مدل ارائه شده برای انجام تطبیق وجه [67]. ۶۰.....

شکل ۳۱ چند نمونه از تصاویر مختلف مجموعه داده Cityscapes ۶۴.....

شکل ۳۲ مجموعه داده Cityscapes (سمت چپ) در مقابل Foggy Cityscapes (سمت راست)	۶۵
شکل ۳۳ چند نمونه از تصاویر مختلف مجموعه داده COCO	۶۶
شکل ۳۴ چند نمونه از تصاویر مختلف مجموعه داده Caltech	۶۷
شکل ۳۵ چند نمونه از تصاویر مختلف مجموعه داده SYNTHIA	۶۸
شکل ۳۶ چند نمونه از تصاویر مجموعه داده KITTI	۶۹
شکل ۳۷ چند نمونه از تصاویر مختلف مجموعه داده Pascal VOC 2007	۷۰
شکل ۳۸ چند نمونه از تصاویر مختلف مجموعه داده SIM10K	۷۱
شکل ۳۹ چند نمونه از تصاویر مختلف مجموعه داده BDD100K	۷۲
شکل ۴۰ چند نمونه از تصاویر مختلف مجموعه داده YTBB	۷۳

چکیده

شبکه های عصبی عمیق¹ (DNNs) با سرعت زیادی در سال های گذشته توسعه یافته اند. این مدل ها نتایج امیدوارکننده ای در وظایف مختلف بینایی ماشینی از جمله شناسایی اشیاء نشان داده اند، اما معمولاً به دلیل تغییرات دامنه از دامنه منبع به دامنه هدف، با کاهش دقت مواجه می شوند. برای مقابله با این اتفاق مخصوصاً در شرایطی که برچسب های دامنه هدف در دسترس نیستند، رویکردهای تطبیق دامنه بدون نظارت (UDA) پیشنهاد می شوند. روش های موجود در شناسایی اشیاء به صورت بدون نظارت، ویژگی ها را از سطح تصویر استخراج می کنند و همانطور که در این حالت برای وظایف طبقه بندی عمل می کنند، ویژگی های کامل را به صورت مستقیم تطبیق می دهند. با این حال، تطبیق ویژگی ها به صورت کامل بر سطح تصویر به عنوان یک کل برای وظیفه شناسایی اشیاء مطلوب نیست.

کلید واژه ها: یادگیری عمیق، داده های برچسب گذاری شده، توزیع داده ها، دامنه منبع، دامنه هدف، تطبیق توزیع، شناسایی اشیا

¹ Deep Neural Networks

فصل ۱: مقدمه و کلیات

۱-۱. مقدمه

شبکه های عصبی عمیق (DNNs) با موفقیت در بسیاری از وظایف بینایی ماشینی، مانند شناسایی اشیاء، به دقت بالایی و تقریباً معادل دقت انسانی دست یافته اند. با اینکه تحقیقات با استفاده از مدل های DNNs به نتایج بسیار خوبی رسیده اند، اما هنوز این مدل ها قابل مقایسه با قابلیت بینایی انسانی در ارتباط با شناسایی اشیاء نیستند. عملکرد بینایی انسانی کمتر تحت تأثیر محیط اطراف، تغییرات محیطی و غیره قرار می گیرد [1]. افزودن نویز تصادفی یا ایجاد تغییرات مختلف در پس زمینه باعث کاهش اعتماد به پیش بینی مدل های DNNs خواهد شد و این قضیه به صورت تجربی در بسیاری از مقالات و تحقیقات مختلف به صورت تجربی ثابت شده است. ارائه پیش بینی قابل اعتماد در محیط های مختلف بسیار حیاتی و چالش برانگیز است.

کمبود قابلیت سازگاری جلوگیری شدیدی از کاربردهای مدل های DNNs می کند. در تحقیقات، کمبود قابلیت سازگاری معمولاً با استفاده از دو یا بیشتر مجموعه داده ها اندازه گیری می شود، به این معنا که وقتی یک شبکه بر روی یک یا چند مجموعه داده آموزش داده می شود و بر روی یک مجموعه داده دیگر برای حل همان وظیفه استفاده می شود، مدل احتمالاً عملکرد خوبی از خود نشان نمی دهد. این پدیده به دلیل تفاوت توزیع داده ها بین دو مجموعه داده ایجاد می شود، که به عنوان "فاصله دامنه" نیز ارجاع می شود.

۲-۱. ضرورت انجام پژوهش

تطبیق دامنه^۱ یک مفهوم مهم در حوزه یادگیری ماشین و شبکه های عصبی است که به تطابق یک مدل یادگیری با داده های آموزشی و داده های آزمایشی از دامنه های مختلف اشاره دارد. در مواردی که داده ها از دامنه های مختلف باشند، ممکن است مدل یادگیری عمیق عملکرد نامطلوبی داشته باشد، زیرا اختلاف های بین دامنه ها می تواند به تخریب دقت مدل منجر شود. به عبارت دیگر، مدلی که بر روی یک دامنه آموزش دیده شده است، ممکن است بر روی دامنه های دیگر کارایی خود را از دست دهد.

در زمینه تشخیص اشیا، این مسئله حائز اهمیت است. چرا که داده های آموزشی مصنوعی که برای آموزش مدل های تشخیص اشیا استفاده می شوند، معمولاً از دامنه های مصنوعی و محدود به شرایط خاصی تولید می شوند. اما در محیط های واقعی، اشیا در شرایط مختلف از زوایا مختلف، با شرایط تابش تور متفاوت و پس زمینه های متنوع قرار می گیرند. بنابراین، انتقال دانش از دامنه های مصنوعی به دامنه های واقعی و تطبیق مدل های یادگیری به شرایط واقعی اهمیت زیادی دارد.

از جمله دلایل دیگری که میتوان در وصف اهمیت تطبیق دامنه اشاره نمود، محدودیت منابع داده های برچسب دار است. عموماً جمع آوری داده های برچسب دار در دامنه مقصد هزینه بر و زمان بر می باشد. بنابراین، انتقال دامنه به ما امکان می دهد تا با بهره گیری از دانش ویژگی ها و الگوهای یادگرفته شده در دامنه منبع، عملکرد مدل ها در دامنه مقصد را بهبود بخشیم.

همچنین استفاده از دانش عمومی مدل ها نیز دارای اهمیت است. مدل های یادگیری عمیق عموماً قادرند الگوها و ویژگی های کلان و عمومی را از داده ها استخراج کنند که در چندین دامنه قابل استفاده هستند. بدین ترتیب، اگر یک مدل در یک دامنه خاص خوب عمل کند، قابل انتظار است که بتواند بخشی از این دانش را به دامنه های مشابه منتقل نماید.

این پژوهش ها می توانند به تعریف روش ها و الگوریتم هایی کمک کنند که مدل های عصبی را قادر به تطبیق با تغییرات دامنه ها کنند و در شرایط واقعی به عملکرد بهتری دست یابند.

۳-۱. انگیزه و هدف

یکی از اهداف اصلی تحقیق در این حوزه، بهبود دقت و کارایی شبکه های عصبی در تشخیص اشیا در تصاویر است. این بهبودات می توانند در بسیاری از کاربردهای عملیاتی مانند خودروهای بدون راننده، پزشکی تصویری، امنیت و نظارت ترافیکی مفید باشند. همچنین بسیاری از شبکه های عصبی برای آموزش و تشخیص اشیا نیاز به داده های آموزشی بزرگ و متنوع دارند. اما تهیه و برچسب گذاری این داده ها ممکن است پرهزینه و زمان بر باشد. از این رو، هدف می تواند تلاش برای بهبود کارایی شبکه ها

¹ Domain Adaptation

با استفاده از داده های آموزشی مصنوعی و ایجاد تطبیق بین داده های مصنوعی و واقعی باشد. از طرفی تطبیق دامنه به شبکه های عصبی امکان می دهد تا در مواجهه با تغییرات و تنوع های محیطی، عملکرد خود را بهتر حفظ کنند و از سیستم های مقاوم تری برخوردار باشند.

سوالات این پژوهش عبارت اند از:

۱. چگونه روش های انتقال یادگیری می توانند عملکرد مدل را در شرایط تطبیق دامنه بهبود بخشند؟
۲. چگونه می توان دامنه های مشابه با داده های آموزشی مصنوعی را انتخاب کرد تا تطبیق دامنه بهبود یابد؟
۳. آیا استفاده از تکنیک های ترکیب داده های مصنوعی با داده های واقعی می تواند به بهبود تطبیق دامنه کمک کند؟
۴. چگونه می توان از ترکیب روش های مختلف مانند انتقال یادگیری، یادگیری نیمه نظارتی و یادگیری تقویتی بهره برد تا تطبیق دامنه بهبود یابد؟
۵. دامنه میانی چه تاثیری بر بهبود عملکرد تطبیق دامنه دارد؟

۴-۱. ساختار سمینار

در فصل اول، به مقدمات و بررسی دلایل نیاز به تطبیق دامنه و استفاده از آن برای کاربرد تشخیص اشیا پرداخته شده است. در فصل دوم با نگاهی مبسوط، به الگوریتم های پایه و اساسی تشخیص اشیا و تطبیق دامنه به صورت کلی پرداخته می شود و یک دسته بندی کلی از روش های تطبیق دامنه ارائه می شود. در فصل سوم نتایج تجربی حاصل شده از مقالات و پایان نامه های مرتبط و توضیحات مربوط به معیارهای ارزیابی و مجموعه دادگان مختلف مربوط به کار با این موضوع پرداخته می شود. و در نهایت در فصل چهارم نتیجه گیری ها بیان و پیشنهاداتی جهت کارهای آتی مطرح می شود.

فصل ۲: مبانی نظری تحقیق

۲-۱. مقدمه


در این فصل، در ابتدا به الگوریتم های پایه و اساسی تشخیص اشیا و تطبیق دامنه به صورت کلی پرداخته می شود و سپس یک دسته بندی کلی از روش های تطبیق دامنه ارائه می شود.

۲-۲. تشخیص اشیا

تشخیص اشیا^۱ یک وظیفه مهم در زمینه هوش مصنوعی و بینایی کامپیوتری است که به کامپیوتر اجازه می دهد تا اشیا و اجزای مختلف یک تصویر یا ویدئو را تشخیص دهد و آن ها را به صورت خودکار مشخص کند. این وظیفه برای بسیاری از کاربردها از جمله خودران های اتومبیل، تحت نظر گرفتن اشیا در تصاویر پزشکی، شناسایی اشیا در تصاویر مدار بسته، تشخیص چهره در عکس ها و ویدئوها و بسیاری از سیستم های هوش مصنوعی دیگر مورد استفاده قرار می گیرد.

¹ Object detection

همچنین تشخیص اشیا به وسیله تکنولوژی های مختلفی انجام می شود، از جمله شبکه های عصبی عمیق مانند YOLO¹، SSD² و Faster R-CNN³. این شبکه ها از ترکیب الگوریتم های یادگیری ماشین و شبکه های عصبی عمیق برای تشخیص اشیا با دقت و سرعت بالا استفاده می کنند.



شکل ۱ نمونه ای از کار تشخیص اشیا

وظیفه تشخیص اشیا می تواند به عنوان ترکیبی از دو مرحله اصلی دیده شود: یافتن مناطق تصویری که ممکن است شامل اشیا باشند، و سپس دسته بندی اشیا در این مناطق به صورت مستقل. قبل از ظهور یادگیری عمیق، این کار با استفاده از رویکرد sliding window انجام می شد. در این رویکرد، یک دسته بند تصویر به مناطق مختلف تصویر اعمال می شد و تنها پیش بینی هایی با احتمال بالاتر حفظ می شدند. اما در حال حاضر، دو خانواده اصلی از آشکارسازهای اشیا شناخته می شوند.

چندین معماری شبکه به عنوان شبکه های پایه در آشکارسازهای اشیا استفاده شده اند تا ویژگی های تصاویر ورودی را برای وظیفه تشخیص اشیا استخراج کنند. به دلیل عملکرد بالا، یکی از محبوب ترین این معماری ها، معماری residual neural network (ResNet) است [2].

شبکه های ResNet توسط استفاده از اتصال های کوتاه یا اتصالات پرش مشخص می شوند. از طریق این اتصالات پرش، خروجی یک بلوک شبکه به سیگنال ورودی همان بلوک اضافه می شود. این امر منجر به انتقال گرادینان از لایه های سطح بالا به لایه های سطح پایین در مرحله پس انتشار می شود و از ویژگی های اولیه استخراج شده در لایه های ابتدایی شبکه در فرآیند استنباط بهره بری می کند. این به


¹ You Only Look Once

² Single Shot MultiBox Detector

³ Region-based Convolutional Neural Network

ایجاد شبکه های عمیق بسیاری که مشکلات معماری های قبلی مربوط به آموزش و دقت را حل کرده اند، امکان پذیر شده است. ساختار یک بلوک باقیمانده در شکل 2 نشان داده شده است.

تعداد لایه های یک شبکه ResNet معمولاً به عنوان یک پسوند مشخص می شود. مقادیر معمول شامل ۱۸، ۳۴، ۵۰ (ResNet-50)، ۱۵۲ و حتی بیش از ۱۰۰۰ لایه [3] هستند.



شکل ۲ مثالی از ساختار یک بلوک residual learning

مدل های تشخیص دهنده را میتوان به دو دسته یک مرحله و دو مرحله ای تقسیم کرد که در ادامه به توضیح هر کدام خواهیم پرداخت.

۲-۲-۱. مدل های تشخیص دهنده یک مرحله ای^۱

مدل های تشخیص دهنده یک مرحله ای با تفاوت اساسی نسبت به مدل های دو مرحله ای عمل می کنند. این مدل ها فاز پیشنهاد منطقه را نادیده می گیرند و به جای آن تمرکز خود را بر روی پیش بینی مناطق و کلاس های اشیاء در تصاویر می گذارند. این باعث می شود که پیش بینی ها نسبت به مدل های دو مرحله ای سریع تر انجام شود و برای برنامه های واقعی زمان واقعی اما با هزینه کیفیت پیش بینی کمتری مناسب باشند. کار پیشرو در زمینه تشخیص اشیاء در یک مرحله کار توسط Pierre Sermanet و همکارانش [4] انجام شده است. در این روش، لایه های طبقه بندی آخر شبکه عصبی کانولوشنی استاندارد با یک شبکه رگرسیون برای هر کلاس جایگزین می شوند تا مختصات جعبه های محدود کننده اشیاء را پیش بینی کنند.

۲-۲-۱-۱. شبکه YOLO

شبکه YOLO^۲ یک مدل عمیق یادگیری عمیق برای شناسایی اشیاء و تشخیص اشیاء در تصاویر و ویدئوها است. این مدل در سال ۲۰۱۶ توسط جوزف ردمن و مجتبی کارویو [5] ارائه شد و به عنوان یک روش موثر و سریع برای شناسایی اشیاء در زمان واقعی شناخته می شود.

^۱ One stage object detectors


^۲ You Only Look Once

این مدل، بحث شناسایی اشیاء را به عنوان یک مسئله ی رگرسیون معرفی می کند و به گونه ای عمل می کند که تصویر را به سلول های کوچکتر تقسیم می کند. اگر مرکز یک شیء درون یک سلول قرار بگیرد، آن سلول مسئولیت تشخیص و پیش بینی مکان محدوده مستطیلی^۱، امتیاز اعتماد^۲ و احتمال کلاس برای اشیاء تشخیص داده شده را دارد. برای یادگیری بهینه پیش بینی مکان محدوده مستطیلی و کلاس های اشیاء به صورت همزمان، یک تابع خسارت خاص استفاده می شود.

مهمترین ویژگی YOLO این است که به عنوان یک مدل تک مرحله ای عمل می کند، به این معنا که به جای اجرای چندین مرحله از پیش پردازش و اجرای شبکه های پیچیده، تصویر ورودی را یک بار پردازش می کند و اشیاء موجود در تصویر را در یک گام تشخیص می دهد. این ویژگی باعث می شود که YOLO بسیار سریع باشد و به راحتی در زمان واقعی برای کاربردهایی مانند تشخیص اشیاء در ویدئوها یا مانیتورینگ ترافیک استفاده شود.

معماری شبکه YOLO الهام گرفته از مدل GoogLeNet برای دسته بندی تصاویر است. با این حال، به جای استفاده از ماژول های inception که در GoogLeNet استفاده می شوند، YOLO از لایه های کاهنده^۳ 1×1 به آن ها پیوسته به لایه های کانولوشن 3×3 استفاده می کند. پیش بینی نهایی یک تنسور $7 \times 7 \times 30$ است.

علاوه بر این، یک نسخه سریع از YOLO وجود دارد که از یک شبکه عصبی با تعداد کمتری لایه کانولوشن (۹ به جای ۲۴) و تعداد کمتری فیلتر در این لایه ها استفاده می کند.



شکل ۳ معماری شبکه YOLO [5]

شبکه تشخیص از ۲۴ لایه کانولوشن^۴ و پس از آن دو لایه تماماً متصل^۵ تشکیل شده است. لایه های کانولوشنال برای استخراج ویژگی های تصویر به کار می روند و لایه های تماماً متصل برای

¹ bounding box

² confidence score

³ Reduction Layers

⁴ Convolutional Layers

⁵ Fully Connected Layers

دسته بندی و تصمیم گیری نهایی استفاده می شوند. در معماری این شبکه، از لایه های کانولوشنال 1×1 به صورت متناوب استفاده می شود. این لایه ها به کاهش ابعاد ویژگی های تصویر از لایه های قبلی می پردازند. از این لایه ها برای کاهش تعداد کانال ها و بهبود محاسبات در شبکه استفاده می شود.

در مرحله ای از آموزش، لایه های کانولوشنال ابتدا بر روی مسئله دسته بندی تصاویر ImageNet آموزش داده می شوند. این آموزش با استفاده از تصاویری با وضوح نصف (224×224 پیکسل) انجام می شود. سپس، در مرحله تشخیص، وضوح تصاویر به دو برابر افزایش پیدا می کند تا برای شناسایی بهتر اشیاء استفاده شود.

نویسندگان مقاله عملکرد YOLO را با استفاده از مجموعه داده PASCAL VOC بررسی کرده و نشان داده اند که این روش بیش از دو برابر دقت متوسط میانگین دیگر سیستم های زمان واقعی را دارد و در حین پردازش ویدئوهای جاری، دارای کمتر از ۲۵ میلی ثانیه تاخیر است. مقاله همچنین مزایای YOLO نسبت به روش های سنتی شناسایی اشیاء را بررسی می کند و یک پیوند به یک نمونه از سیستم کار در زمان واقعی با دوربین وب ارائه می دهد.


YOLO به دلیل سرعت بالا و عملکرد برتر در شناسایی اشیاء در زمان واقعی در بسیاری از کاربردهای بینایی ماشین و پردازش تصویر مورد استفاده قرار گرفته است. این مدل در نسخه های مختلفی مانند YOLOv1 تا YOLOv5 و YOLOX عرضه شده و بهبودهای متعددی در زمینه دقت و سرعت اجرا داشته است.

۲-۲-۱-۲. شبکه SSD

SSD^۱ [6] روشی برای تشخیص اشیاء در تصاویر با استفاده از یک شبکه عصبی عمیق تکین است. اصلی ترین اجزای SSD شامل پیش بینی امتیازهای دسته بندی و انتقال های جعبه (مربع) برای یک مجموعه ثابت از جعبه های مربعی پیش فرض با استفاده از فیلترهای کانولوشنی کوچکی است که به نقشه های ویژگی اعمال می شوند. SSD از یک شبکه عصبی کانولوشنی به نام "VGG-16" به عنوان پایه استفاده می کند و به روی آن چندین لایه کانولوشنی با اندازه های کمتر اضافه می کند. این کار به منظور ساخت یک نمایش پیرامونی از تصاویر و تشخیص کارهای مختلف با اندازه های مختلف در هر لایه پیرامونی انجام می شود. به جای تقسیم تصاویر به سلول ها، از جعبه های مرجع^۲ برای تشخیص سریع تر استفاده می شود.

¹ Single Shot MultiBox Detector

² Anchor boxes



شکل ۴ ساختار هرمی معماری SSD [6]

در اصل، SSD یک روش برای تشخیص اشیا در تصاویر است که با استفاده از یک شبکه عصبی کانولوشنی به تصویر ورودی نگاه می کند و اشیا مختلفی که در تصویر وجود دارند را به صورت همزمان و با دقت تشخیص می دهد. این به این شکل کار می کند که تصاویر را در لایه های مختلف پیرامونی تجزیه و تحلیل می کند تا بتواند اشیا با اندازه های مختلف را تشخیص دهد. همچنین، از جعبه های مرجع به عنوان نقاط مرجع برای تشخیص اشیا استفاده می شود تا فرآیند تشخیص سریع تر و کارآمدتری داشته باشد.


برای دستیابی به دقت بالای تشخیص، SSD پیش بینی های مقیاس های مختلف را از نقشه های ویژگی با مقیاس های مختلف تولید می کند و به صراحت پیش بینی ها را بر اساس نسبت ابعاد متمایز می کند. این ویژگی های طراحی باعث می شوند که آموزش از ابتدا تا انتها ساده باشد و دقت بالایی را به ارمغان بیاورد، حتی بر روی تصاویر ورودی با رزولوشن پایین، که تجارت سرعت در مقایسه با دقت را بهبود می بخشد. SSD نسبت به تکنیک های قبلی تک مرحله ای (مانند YOLO) سریع تر است و با اختلاف قابل توجهی دقت بالاتری دارد، به حدی که به دقت تکنیک های کندتری که اقتراح های منطقه ای و پولینگ صریح را انجام می دهند (شامل Faster R-CNN) را داراست. آزمایشات شامل تحلیل زمانی و دقت بر روی مدل های با اندازه ورودی متغیری است که بر روی مجموعه داده های PASCAL VOC، COCO، و ILSVRC ارزیابی شده و با مجموعه ای از رویکردهای معاصر وضعیت آخرین مقالات مقایسه می شوند.

۳-۲-۲. شبکه FPN¹

شبکه FPN [7] از تعدادی سطح هرمی تشکیل شده است که با مراحل مختلف شبکه متناظر هستند. هر مرحله از چندین لایه کانولوشنی با اندازه یکسان تشکیل شده است و اندازه این لایه ها به ازای مراحل مختلف دو برابر می شود. به علاوه، مراحل مختلف با یک مسیر بالا به پایین در جهت معکوس از یکدیگر جفت می شوند و اتصالات جانبی دارند. این اتصالات و مسیر بالا به پایین امکان می دهند تا شبکه یک هرم ویژگی چندسطحی و غنی را برای هر تصویر ورودی ایجاد کند.

¹ Feature Pyramid Network

پس از معرفی این روش در دسته ی مدل های تشخیص دهنده تک مرحله ای، FPN ها همچنین به عنوان بخشی از اسکلت مدل های تشخیص دهنده دو مرحله ای مورد استفاده قرار گرفته اند تا به بهبود عملکرد این مدل های تشخیص دهنده کمک کنند.



شکل ۵ معماری و ساختار FPN [7]

۲-۲-۲. مدل های تشخیص دهنده دو مرحله ای^۱

همانطور که اشاره شد، مدل های بسیار متداول برای تشخیص اشیا بر مبنای یک رویکرد دو مرحله ای هستند و به خانواده شبکه های عصبی کانولوشنی مبتنی بر مناطق^۲ (R-CNNs) تعلق دارند.

۲-۲-۲-۱. شبکه R-CNN

در R-CNN ابتدایی [8]، تعداد قابل مدیریتی از مناطق ممکن جهت تمرکز^۳ (RoIs) با استفاده از الگوریتم جستجوی انتخابی^۴، از تصویر استخراج می شوند. جستجوی انتخابی به هدف محلی سازی اشیا در تصاویر ورودی انجام می شود و در مقابل جستجوی جامع استفاده شده در گذشته قرار می گیرد، که در آن از رویکرد پنجره های لغزان برای شناسایی نواحی مهم استفاده می شود. در جستجوی انتخابی، تصویر ورودی ابتدا به نواحی کوچک تقسیم می شود، سپس به تدریج بر اساس شباهت آنها به یکدیگر ادغام می شوند. این عملیات تا زمانی ادامه می یابد که مناطق مستقل بزرگتری ایجاد شوند. این نواحی به عنوان مناطق ممکن برای تمرکز نامزد باز می گردانده می شوند.

سپس یک CNN به صورت مستقل بر روی هر منطقه تمرکز پیشنهادی ارزیابی می شود تا ویژگی ها استخراج شوند که به یک ماشین بردار پشتیبانی (SVM) داده می شوند تا تشخیص دهد آیا یک شیء


¹ Two stage object detectors

² Region-Based Convolutional Neural Networks

³ Regions of Interest

⁴ Selective Search

در این جعبه محدودکننده وجود دارد (وظیفه دسته‌بندی) و همچنین مکان آن را با مکان شیء متناظر تطابق دهد (وظیفه رگرسیون). از آنجایی که SVM یک الگوریتم دسته‌بندی دودویی است، به همین دلیل تعدادی SVM برای وظیفه دسته‌بندی برای هر کلاس مورد علاقه استفاده می‌شوند. خلاصه‌ای از روش در شکل ۵ گزارش شده است.




شکل ۶ ساختار و نحوه عملکرد شبکه R-CNN [8]

مدل‌های Fast R-CNN [9] و Faster R-CNN [10] معماری و عملکرد R-CNN را بهبود دادند و زمان استنتاج را کاهش دادند.

۲-۲-۲. شبکه Fast R-CNN

شبکه Fast R-CNN [9] بهبودهایی در عملکرد نسبت به روش R-CNN ارائه می‌دهد که از طریق اضافه کردن لایه RoI pooling و یک روش آموزش تک‌مرحله‌ای با یک تابع هدف چند وظیفه‌ای بهینه‌سازی شده به دست آمده است. لایه RoI pooling به شبکه اجازه می‌دهد تا پردازش را به صورت موازی انجام دهد و این موضوع باعث می‌شود تا یکی از علت‌های اصلی کندی معماری R-CNN حل شود. به عبارت دیگر، در R-CNN هر پیشنهاد RoI به صورت مستقل به یک شبکه عصبی کانولوشنی (CNN) برای استخراج ویژگی‌ها ارسال می‌شود. با استفاده از RoI pooling، تصویر ورودی کامل فقط یک بار به استخراج‌کننده ویژگی‌ها (CNN) ارسال می‌شود. سپس نقشه‌های ویژگی مستطیلی که متناظر با هر پیشنهاد RoI است از ویژگی‌های تصویر استخراج می‌شوند.

برای افزایش سرعت تست، Fast R-CNN از تکنیک "بازگردانی جعبه محدود کننده" استفاده می‌کند که به شبکه امکان بهبود دقت مکانی پیشنهاد‌های اشیاء را می‌دهد. این کار منجر به کاهش تعداد پیشنهاد‌هایی می‌شود که باید پردازش شوند و در نتیجه به سرعت تست کاهش می‌دهد.




شکل ۷ ساختار و نحوه عملکرد شبکه Fast R-CNN [9]

۲-۲-۳. شبکه Faster R-CNN

شبکه Faster R-CNN [10]، بهبودهایی نسبت به شبکه قبلی (Fast R-CNN) دارد. یکی از اصلی ترین بهبودهای این روش نسبت به Fast R-CNN، معرفی یک شبکه به نام Region Proposal Network (RPN) است. این شبکه به گونه ای طراحی شده است که بخشی از لایه های شبکه عصبی کانولوشنی برای مرحله پیشنهاد مناطق تصویر را جایگزین الگوریتم جستجوی انتخابی که گران و زمان بر است، می کند. این تغییر به بهبود عملکرد و کاهش زمان مورد نیاز برای تشخیص اشیا در تصاویر کمک می کند.

در شکل ۷ نحوه عملکرد Faster R-CNN به اختصار توصیف شده است.



شکل ۸ ساختار و نحوه عملکرد شبکه Faster R-CNN [10]

هدف اصلی RPN این است که مجموعه ای از RoIs از یک تصویر ورودی استخراج کند. این CNN با به اشتراک گذاشتن یک مجموعه مشترک از لایه های کانولوشنی با یک شناسایی کننده شیء Fast R-CNN همراه است و مناطق تصویری را که باید بر روی آن ها تمرکز کند، مشخص می کند.

برای تولید پیشنهادهای RoI، RPN ویژگی های استخراج شده توسط آخرین لایه کانولوشنی مشترک را به عنوان ورودی دریافت می کند و از یک روش پنجره ای لغزان برای استخراج پیشنهادهای چندگانه استفاده می کند. هر RoI به یک نقشه ویژگی با ابعاد کمتر نگاشت می شود که به دو لایه مشابه (یک لایه تصمیم گیری دودویی برای تخمین احتمال این که آیا RoI ورودی واقعاً یک شیء را شامل می شود یا خیر و یک لایه بهبود مستطیل های محیطی برای بهبود پیشنهادهای مستطیلی) تغذیه می شود. نواحی که در هر مکان پنجره لغزان تولید می شوند، ابعاد و نسبت های جانبی مختلفی دارند و به عنوان Anchor Boxes شناخته می شوند. این مفهوم مهم در تشخیص اشیا مدرن است.

RPN می تواند با هدف کمینه کردن یک تابع از دست دادن چند وظیفه ای آموزش داده شود. اما چون RPN و شناسایی کننده شیء Fast R-CNN از یک مجموعه از لایه های کانولوشنی به اشتراک گذاشته می کنند، آموزش مستقل از این دو مؤلفه ممکن است وزن ها را به روش های مختلفی تغییر دهد و نتایج ناسازگار باشند. برای این کار، سه تکنیک معرفی شده است:

- آموزش متناوب: در این روش، RPN به عنوان یک شبکه عصبی کانولوشنی از پیش آموزش داده شده مقدماتی شده و به طور کامل بر روی وظیفه پیشنهاد RoI به طور انتها به انتها آموزش داده می شود، و پیشنهادهای تولید شده برای آموزش یک شناسایی کننده شیء Fast R-CNN استفاده می شود.

- آموزش مشترک تقریبی: در این روش، مؤلفه های RPN و Fast R-CNN به یک شبکه ترکیب می شوند، اما این آموزش مشترک به نتایج تقریبی منجر می شود.

- آموزش مشترک غیرتقریبی: در این روش، مشکل تقریبی آموزش مشترک با توجه به مختصات مستطیل های پیشنهادی را حل کرد. این نیاز به توسعه یک لایه تجمع RoI که با توجه به مختصات مستطیل ها قابل تفکیک باشد، دارد.

به دلیل عملکرد خوب و سرعت مناسب آن، Faster R-CNN به عنوان یک مدل مرجع برای ارزیابی و به عنوان پایه برای ایجاد مدل های مشتق شده در حوزه تشخیص اشیا در تصاویر گسترش یافته است.


۲-۳. تطبیق دامنه در یادگیری عمیق

از آنجایی که شبکه های عصبی عمیق با دقت بالا (یا هر معیار مورد نیاز دیگری) مرتبط هستند و می توانند مطابق آخرین پیشرفت ها^۱ نتایج را ارائه دهند، استفاده از آن ها در بسیاری از برنامه ها و وظایف هوش مصنوعی و یادگیری ماشین افزایش یافته است. با این حال، این شبکه ها با مشکلات تغییر دامنه مواجه هستند و قادر به تطبیق خود با توزیع های مختلف داده ها (نسبت به دامنه منبع) نمی باشند

¹ State-of-the-art

و نتایج بهترین های فعلی را ارائه نمی دهند. علاوه بر این، از آنجایی که شبکه های عصبی عمیق به حجم زیادی از داده های برچسب خورده برای آموزش نیاز دارند و دسترسی همیشگی به داده های برچسب خورده مشکل است (زمان بر، دشوار یا گاهی غیرممکن می باشد)، استفاده از یادگیری انتقالی برای شبکه های عصبی عمیق بسیار ضروری است. برخلاف تطبیق دامنه در یادگیری سطحی، تمرکز و هدف تطبیق دامنه شامل گنجاندن آن در فرآیند یادگیری عمیق و کانال ارتباطی^۱ است به طوری که بازنمایی های قابل انتقال آموخته شوند [11].

نمودار ۱ روش ها و رویکردهای یادگیری عمیق تطبیق دامنه را نشان می دهد و طبقه بندی روش های تطبیق دامنه که توسط وانگ و دنگ [12] اشاره شده است را بسط می دهد. با این حال، این مقاله تنها بر تکنیک های تطبیق دامنه عمیق در حوزه ی تصویری تمرکز دارد. در مقابل، هدف ما این است که رویکردهای تطبیق دامنه عمیقی که برای کاربرد تشخیص اشیا بکار رفته اند را بررسی و طبقه بندی کنیم.



نمودار ۱ درختواره روش های تطبیق دامنه


۲-۳-۱. روش های مبتنی بر اختلاف

Mathelin و همکارانش [13] یک رویکرد نوآورانه برای طراحی استراتژی های یادگیری فعال ارائه می دهند که منجر به تطبیق دامنه می شود. نویسندگان مرزهای خطاهای تعمیم را استخراج نموده و یک الگوریتم عملی را پیشنهاد می کنند که قادر به مدیریت مجموعه های داده بزرگ می باشد.

این رویکرد پیشنهادی با کارهای پیشین در زمینه یادگیری فعال تفاوت دارد زیرا به جای تطابق کشفی یا توزیع، بر اساس اندازه گیری اختلاف بین توزیع های دارای برچسب و بدون برچسب می باشد. نویسندگان نشان می دهند که این اندازه گیری اختلاف می تواند برای استخراج مرزهای خطاهای تعمیم، که به ریسک هدف وابسته هستند، به کار رود. آنها یک الگوریتم عملی پیشنهاد می کنند که این اندازه گیری اختلاف را به حداقل می رساند تا نقاطی که برای برچسب گذاری اطلاعات بیشتری ارائه می کنند، انتخاب شوند.

¹ Pipeline

الگوریتم پیشنهادی بر اساس یک شرط منظم است که توابع ضرر باید آن را رعایت کنند تا مرزهای خطاهای تعمیم حفظ شوند. نویسندگان توضیح می دهند که این شرط توسط بسیاری از توابع ضررهای معمولی که به طور معمول استفاده می شوند، از جمله squared loss و logistic loss، رعایت می شود.



شکل ۹ ساختار معماری شبکه معمولی شبکه های عصبی عمیق که روش های مبتنی بر اختلاف را برای تطبیق دامنه پیاده سازی می کنند. در این ساختار، لایه های استخراج ویژگی به اشتراک گذاشته می شوند منظم می شوند. لایه های بعدی، "لایه های تطبیق" شناخته می شوند که شامل معیارهای اختلاف یا نمایشی از شبکه به همراه متریک اختلاف است. لایه های خاص وظیفه نقش زیادی در تطبیق ویژگی های منبع و هدف ندارند [14].

۱-۳-۲. روش های اختلاف: مبتنی بر معیارها

سردرگمی دامنه عمیق^۱ (DDC) [15] اولین ایده کلیدی بود که به طور مشترک وظایف (طبقه بندی) و سردرگمی دامنه را بهینه کرد. تلفیق دامنه برای تطبیق دو لایه متصل کننده با ایده استفاده شده است: ویژگی هایی که شبکه یاد می گیرد باید بی طرف باشند، یعنی باید در فضای ویژگی قرار بگیرند که در این شرایط اطلاعات دامنه از بین می رود در حالی که اطلاعات کلاس ها باقی می ماند. روش MMD [16] به عنوان یک معیار اختلاف برای ضرر دامنه استفاده می شود. DDC این تابع را به عنوان ضرر مشترک برای تطبیق دامنه معرفی می کند:

$$L_{\text{Domain_Adaptation}} = L_{\text{classification}} + \lambda MMD^2(P(X^s), P(X^t))$$

معادله ۱

معادله ۱ همچنین به ما کمک می کند تا درک کنیم که معیار اختلاف (مانند MMD یا مشابه آن) چگونه به عنوان یک تنظیم کننده برای کل شبکه عمل می کند. در ادامه، بسیاری از کارها بر ایده کلیدی DDC با استفاده از معیارهای اختلاف متفاوت یا مشابه ساخته اند.

¹ Deep Domain Confusion

Kashyap و همکارانش [17] معیار اختلاف مبتنی بر معیار را به سه دسته تقسیم کرده اند: دسته اول هندسی است که به فاصله بین بردارها اشاره دارد، دسته دوم اطلاعاتی-نظریه ای است که به فاصله بین توزیع های احتمال اشاره دارد و دسته سوم اندازه گیری های مرتبه بالا است که در آن از فاصله بین لحظه های بالاتر توزیع ها، یا فاصله بین پروژکشن ها یا حتی فاصله بین نمایش ها گفته می شود.

۲-۱-۳. روش های اختلاف: مبتنی بر معماری (ساختار)

در این روش ها، تمرکز بیشتری روی یادگیری ویژگی ها و معماری قابل انتقال نسبت به معیارهاست. این روش ها به تطابق ویژگی ها و ساختارها در معماری مدل ها توجه می کنند. اصل اساسی در روش های تطابق بر مبنای ساختار این است که اطلاعات درباره تغییر دامنه (از دامنه مبدأ به دامنه مقصد) تنها به یک تبدیل تساوی مختصات (تبدیل آفین) بستگی دارد. به عبارت دیگر، وجود یک تبدیل کوچک بر روی وزن ها می تواند در فرآیند تبدیل ویژگی های دامنه مبدأ به دامنه مقصد کمک کند. این تبدیل کوچک می تواند تبدیل آفین یا شبکه های چند لایه ای (MLP/شبکه های عمیق) خود باشد.

یکی از مثال های این روش ها، شبکه انطباق عمیق (DAN) است که از اصلی استفاده می کند که در شبکه های عمیق پیچشی^۱، لایه های ابتدایی ویژگی های عمومی را درک می کنند در حالی که لایه های بعدی ویژگی های وظیفه محور را درک می کنند. در این روش، لایه های ابتدایی منجمد می شوند، لایه های میانی بهبود یافته و از روش های مبتنی بر اختلاف مانند MK-MMD (تغییرهای هسته ای چندگانه - MMD) برای تطبیق لایه های بعدی استفاده می شود. به طور معمول، روش های مبتنی بر اختلاف به تراز کردن توزیع های حاشیه ای داده های دامنه مبدأ و مقصد نگاه می کنند، اما رویکردهای مختلفی نیز وجود دارند،

یک مفهوم دیگر در این متن مربوط به شبکه های پروتوتایپی انتقال پذیر (TPN) [18] است که بر روی تفاوت ها (فواصل) برای هر کلاس در یک فضای تعبیه شده از سه مجموعه داده تمرکز دارد: فقط دامنه مبدأ، فقط دامنه مقصد و ترکیبی از دامنه مبدأ و مقصد. همچنین به نمونه های بدون برچسب دامنه مقصد، شبه برچسب ها را اختصاص می دهد. تطبیق طوری انجام می شود که پروتوتایپ هر کلاس در فضای تعبیه شده نزدیک یکدیگر باشند.

۲-۲-۳. روشهای خصمانه

ایده پشت روش های خصمانه این است که به همراه افزایش ابهام دامنه، همزمان به طور قوی آموزش داده می شوند تا تجزیه و تفکیک دامنه را درک کند. این ایده ارتباط نزدیکی با شبکه متخاصم

¹ Deep convolutional networks

مولد یا GANها [19] دارد که شامل دو بخش تولید کننده^۱ و متمایز کننده^۲ در یک محیط خصمانه است. هدف مولد تولید خروجی (معمولاً تصاویر) برای فریب دادن متمایز کننده است، در حالی که متمایز کننده، از سوی دیگر، سعی می کند تصاویر واقعی و مصنوعی را از هم دیگر تفکیک کند.

در تطبیق دامنه (DA)، ایده ای که اقتباس می شود، این است که تمیز دهنده باید قادر باشد تا توزیع دامنه های منبع و هدف را با استفاده از ویژگی های نامتغیر دامنه از یکدیگر تفکیک کند. تطبیق دامنه متمایز کننده متخاصمانه^۳ (ADDA) [20] یک چارچوب عمومی برای تطبیق دامنه با استفاده از مدل های متخاصم معرفی کرد.

ADDA یک چارچوب عمومی برای تطابق داده ها از دو دامنه مختلف با استفاده از مدل های تخصصی ارائه می دهد. شکل ۵، این چارچوب را نشان می دهد.

معماری معمول برای تطابق داده های تخصصی متمایز کننده، از یک معماری سیامی با دو شاخه داده استفاده می کند: یک شاخه از داده های منبع و یک شاخه از داده های هدف. این معماری با استفاده از تابع ضرر (معمولاً دسته بندی) و یا یک تابع ضرر تخصصی یا مبتنی بر اختلاف، آموزش می بیند.


معماری تخصصی تولیدی (در ساده ترین شکل خود) شامل یک مولد است که نگاشتی از یک دامنه به دامنه دیگر تولید می کند؛ سپس نگاشت تولیدی و سایر نگاشت ها به معماری متمایز کننده تخصصی متصل می شوند و پس از بهبود یافتن با یکدیگر، نگاشت تولید شده و سایر نگاشت ها از معماری تبعیض آمیز تبعیت می کنند.

در کل، ADDA یک چارچوب عمومی برای تطابق داده ها از دو دامنه مختلف با استفاده از مدل های تخصصی است، در این فرآیند داده ها از دامنه منبع به دامنه هدف منتقل می شوند و مدعی است که این چارچوب بهبودهای قابل توجهی در کارایی مدل در دامنه هدف ایجاد می کند.

¹ Generator

² Discriminator

³ Adversarial Discriminative Domain Adaptation



شکل ۱۰ ساختار معماری شبکه های عصبی عمیق که روش های مبتنی بر خصوصیت را برای تطبیق دامنه پیاده سازی می کنند. مولد (ها) اختیاری هستند و در صورت نیاز فقط برای ایجاد داده های مصنوعی استفاده می شوند. متمایز کننده دامنه^۱، به دنبال تمایز (طبقه بندی) دامنه های منبع و هدف است، در حالی که وظیفه خاص (مثلاً طبقه بندی یا تشخیص شی) توسط شبکه خاص وظیفه انجام می شود [14].

۲-۳-۲-۱. مدل های تمایزگر متخاصم

یکی از کارهای اساسی در حوزه تطبیق دامنه در یادگیری عمیق، Domain-Adversarial Neural Network (DANN) است. یادگیری دامنه باید تمایزدهنده باشد اما همزمان آن را فریب دهد. این مدل نشان داد که هر مدل feedforward می تواند اگر با یک لایه گرادیان معکوس^۲ (GRL) نوآوری شده تقویت شود، تطبیق دامنه را پشتیبانی کند.

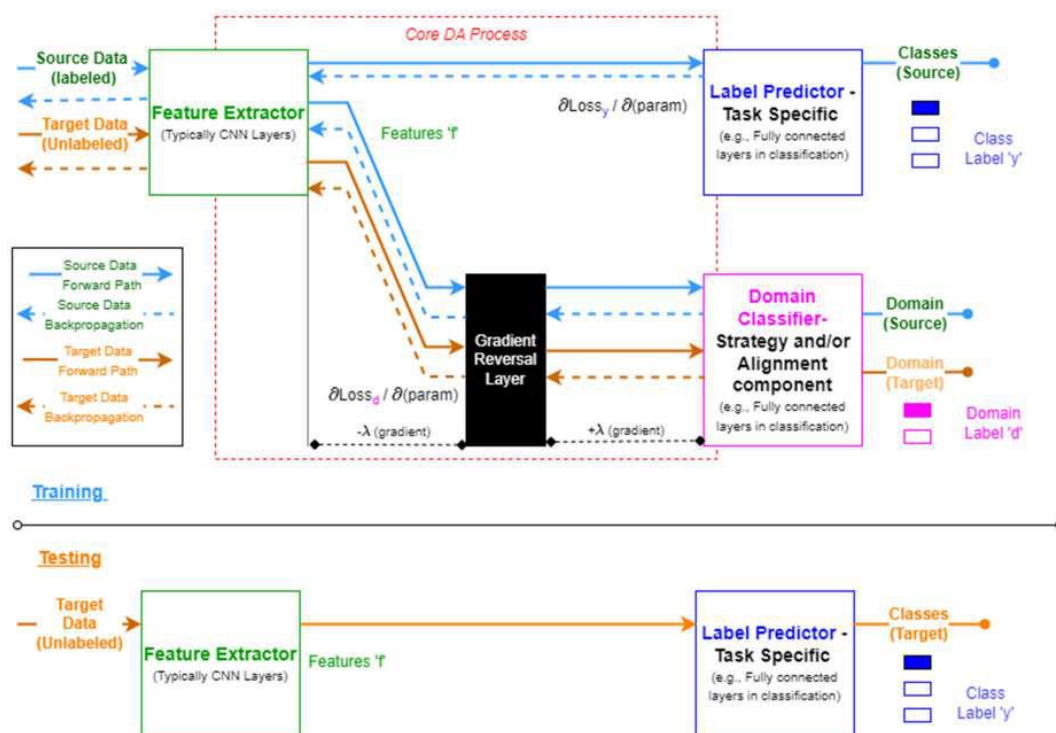
DANN گسترده ترین رویکرد تطبیق دامنه را در تمام حوزه های داده دارد. در ابتدا این روش در حوزه بینایی ماشین ابتدا برای تشخیص اعداد و دسته بندی تصاویر استفاده شد و سپس برای وظایف پیچیده تری مانند تقسیم بندی معنایی و تشخیص اشیاء نیز استفاده شد. در مورد تقسیم بندی معنایی، یک شبکه سیامی (که از دو مسیر موازی تشکیل شده است) استفاده می شود، که یک مسیر نمونه های منبع و مسیر دیگر نمونه های هدف را پردازش می کند. به دلیل پیچیدگی ذاتی وظایف، تطبیق دامنه (طبقه بندی دامنه - شبکه صورتی در شکل ۶) در لایه ها/مراحل مختلف وجود دارد، و لایه های کانولوشن (ورودی به استخراج ویژگی) و لایه های دکانولوشن (استخراج ویژگی به نقشه معنایی^۳) همراستا هستند (اشتراک دارند، نگاشت مشترک دارند یا معیار آماری استفاده می شود). Hoffman و همکارانش [21] به جز تابع ضرر اصلی، از دو تابع ضرر دیگر هم استفاده کردند؛ یک تابع ضرر برای سازگاری با پارامترهای

¹ Domain Discriminator

² Gradient Reversal Layer

³ Feature map

مختص دسته، یعنی سازگاری خاص دسته و تابع ضرر دیگری برای کاهش فاصله توزیع جهانی، یعنی تطبیق جهانی دامنه. Huang و همکارانش [22] نیز به تطابق ویژگی ها در هر لایه شبکه نگاه کردند. ADDA نیز از فلسفه ای مشابه با DANN استفاده می کند، اما با این تفاوت که استخراج ویژگی ها بین منبع و هدف به اشتراک گذاشته نمی شود، و تابع هزینه استفاده شده در ADDA تابع هزینه GAN است در حالی که DANN از تابع هزینه min-max استفاده می کند و آموزش چند مرحله ای است. شبکه های تخصصی دامنه مشروط [23] (CDAN) از یک تمیزدهنده شرطی استفاده می کنند که ورودی را از هردو استخراج کننده ویژگی و طبقه بندی کننده می گیرد. Shen و همکارانش [24] به جای استفاده از یک طبقه بند خالص در تمیزدهنده، از تابع ضرر به عنوان فاصله Wasserstein (مشابه Wasserstein GAN توسط Arjovsky و همکارانش [25]) در طول آموزش بین نمونه های منبع و هدف استفاده کردند.



شکل ۱۱ شبکه عصبی متخاصم دامنه ای (DANN) دو شبکه را همزمان آموزش می دهد. DANN یک استخراج کننده ویژگی (شبکه سبز) و پیش بینی کننده کلاس/برچسب (شبکه آبی) را روی داده منبع آموزش می دهد. DANN همچنین یک استخراج کننده ویژگی (شبکه سبز) و طبقه بندی کننده دامنه (شبکه صورتی) را بر روی داده منبع و هدف آموزش می دهد. لایه تغییر گرادیان (GRL) به شبکه پیش روی اجازه می دهد تا به عنوان معمول پیش برود؛ با این حال، در زمان پس انتشار، گرادیان از تمیز دامنه تغییر می کند (برعکس می شود اما با یک مقدار منفی ضرب

می‌شود) که منجر به درک ویژگی‌های ثابت دامنه (سردرگمی دامنه) توسط استخراج‌کننده ویژگی (شبکه سبز) می‌شود. پارامتر λ به یادگیری ویژگی‌های دسته‌بندی کمک می‌کند و به تدریج ویژگی‌های دامنه را یاد می‌گیرد [14].

۲-۳-۲. مدل های مولد متخاصم

مدل های تولیدی متخاصم شامل یک بخش مولد (معمولاً یک مولد در یک GAN) به همراه بخش تمایزدهنده‌ای از مدل های تمایزدهنده هستند. این مولد به طور معمول داده‌های هدف مصنوعی را از داده‌های منبع با برچسب تولید می‌کند. این داده‌های هدف مصنوعی باعث کاهش نیاز به نمونه‌های دارای برچسب در دامنه‌های هدف می‌شوند. سپس شبکه آموزش داده می‌شود که فرض کند که تغییرات دامنه کم یا هیچ‌گونه تأثیری روی داده‌های مصنوعی ندارد. جزء نگاشت منبع، مولدی است که دامنه منبع را به دامنه هدف نگاشت می‌کند. بنابراین به طور عام، این مولدها به نام دامنه‌نگارها هم شناخته می‌شوند. یکی از کارهای اولیه در زمینه مدل های مولد متخاصم شبکه مولد متخاصم مشترک (CoGAN) می‌باشد [26]. همانطور که از نامش پیداست، دو GAN به طور موازی اجرا می‌شوند و در لایه‌های ابتدایی برای مولدها و لایه‌های نهایی برای تمایزدهنده‌ها به اشتراک گذاشته می‌شود. این لایه‌ها ویژگی‌های سطح بالا در تمایزدهنده‌ها و مفاهیم سطح بالا در مولدها را ثبت می‌کنند. این کار کمک می‌کند تا GAN توزیع مشترک دامنه‌ها را درک کند. در CoGAN، دامنه هدف به دامنه منبع تبدیل شده و سپس دسته‌بندی انجام می‌شود.

به طور معمول، تنها برای یک کار، تطبیق دامنه اختصاصی است (در دو دامنه به اشتراک گذاشته می‌شود). با این حال، PixelDA [27] یک تنظیم تطبیق دامنه تولیدی متخاصم را استفاده کرد تا چارچوبی را ارائه دهد که از جزئیات مربوط به کار جدا شده باشد. به طور معمول، تصاویر منبع به تصاویر شبیه به هدف تبدیل می‌شوند؛ با این حال، Generate-to-adapt [28] از GAN برای تطبیق دامنه با ایجاد تصاویر شبیه به منبع برای موارد دامنه هدف استفاده می‌کند. این از تعبیرهای (در طول آموزش) تصاویر به عنوان فضای نهفته به عنوان ورودی فرعی به GAN استفاده می‌کند تا تصاویر شبیه به منبع را از مولد و تمایزدهنده ایجاد کند که دامنه واقعی را از مصنوعی را تمایز می‌دهد و برچسب‌های کلاس را ارائه می‌دهد.

۲-۳-۳. روش‌های مبتنی بر بازسازی تخصصی

نوع دیگری از روش‌های تولیدی تخصصی، روش‌های مبتنی بر بازسازی هستند (به همان خطوط راهبرد تطبیق دامنه با تطبیق ویژگی‌های سطح کم عمق): روش‌های بازسازی معمولاً از شبکه‌های GAN یا شبکه‌های رمزگذار خودکار^۱ (AE) استفاده می‌کنند تا محتوای یک دامنه را با سبک دامنه دیگر بازسازی کنند. در ادامه به بررسی ایده‌های کلیدی پشت روش‌های بازسازی تخصصی می‌پردازیم.

¹ AutoEncoder

شبکه جداساز دامنه^۱ (DSN) [29] یک چارچوب مبتنی بر AE است. AE یک مدل یادگیری عمیق است که برای تبدیل ویژگی های ورودی به یک نمایش مخفی و سپس بازیابی ویژگی های ورودی از این نمایش استفاده می کند. این چارچوب سعی دارد تا ویژگی ها و نمایش هایی که ویژگی های خصوصی یک دامنه خاص هستند را درک کند، همچنین ویژگی ها و نمایش هایی که در چندین دامنه به اشتراک گذاشته می شوند. نمایش های اشتراکی و نمایش های خصوصی در این چارچوب به گونه ای طراحی شده اند که مستقل از یکدیگر هستند و با یکدیگر تداخل ندارند. همچنین قادر است اطلاعات مختص به هر دامنه را از اطلاعاتی که در چندین دامنه به اشتراک گذاشته می شوند جدا کند.

این چارچوب از یک معیار به نام “reconstruction loss” (تلفیق با سایر معیارها) استفاده می کند که شبکه رمزگشا را مجبور به بازسازی مثال ورودی اصلی با استفاده از ویژگی های موجود در نمایش های خصوصی و اشتراکی دامنه مربوطه می کند.

CycleGAN [15] یک نوع مدل مبتنی بر GAN است که به منظور ترجمه تصاویر از یک دامنه مبدا به دامنه مقصد (ترجمه تصویر به تصویر) استفاده می شود. هدف اصلی این مدل این است که تصویر مبدا را به دامنه مقصد ترجمه کرده و سپس تلاش کند تا تصویر مبدا را بازسازی کند، به طوری که تفاوت ها و تغییرات ناشی از ترجمه را تا جای ممکن کاهش دهد.

برای انجام این کار، CycleGAN از مفهوم “Cycle consistency” استفاده می کند. یعنی اگر یک تصویر از دامنه مبدا به دامنه مقصد ترجمه شود و سپس باز به دامنه مبدا بازگردانده شود، تصویر بازگردانده شده باید به تصویر اصلی مبدا شباهت داشته باشد؛ یعنی ترجمه و بازگردانی باید به اندازه کافی دقیق باشد تا تصاویر نهایی به یکدیگر متناظر باشند و به نوعی اطمینان می یابیم که اطلاعات معنایی در طول ترجمه از دست نرفته است.

یکی از نکات مهم در CycleGAN این است که برخلاف بسیاری از روش های ترجمه تصویر به تصویر دیگر، نیازی به داشتن تصاویر جفت (تصاویر متناظر در دو دامنه) نیست. این به معنای این است که برای آموزش این مدل، مجموعه ای از تصاویر از دامنه مبدا و دامنه مقصد بدون نیاز به تصاویر متناظر در دو دامنه مختلف کافی است. این ویژگی به عنوان یکی از مزایای این روش مطرح می شود.

۲-۳-۳. تطابق چند دامنه ای

تطابق چند دامنه ای^۲ در واقع تفاوت هایی با مدل های تطبیق دامنه معمولی دارد. در تطبیق دامنه معمولی، معمولاً تنها یک دامنه منبع و یک دامنه مقصد وجود دارد که مدل باید از حوزه منبع به حوزه مقصد تطابق پیدا کند. اما در تطابق چند حوزه ای، دو حالت ممکن است رخ دهد:

¹ Domain Separation Networks

² Multi Domain Adaptation

تطابق چند منبعی^۱: در این حالت، تعداد حوزه های منبع بیشتر از یکی است. به عبارت دیگر، مدل باید از چندین حوزه منبع به حوزه مقصد تطابق پیدا کند. این تطابق می تواند در مواقعی کاربرد داشته باشد که داده های مختلفی از منابع مختلف برای تطابق در یک حوزه مقصد مشترک استفاده می شوند. تطابق چند هدفه^۲: در این حالت، تعداد حوزه های مقصد بیشتر از یکی است. این بدان معناست که مدل باید از یک حوزه منبع به چند حوزه مقصد متفاوت تطابق پیدا کند. این مفهوم زمانی به کار می رود که یک مدل یکپارچه با چندین حوزه مقصد متفاوت نیاز دارد و باید توانایی تطابق با همه این حوزه ها را داشته باشد.

۱-۳-۲. تطابق چند منبعی

به منظور ایجاد مدل های تطبیقی دامنه ای قوی تر، منطقی است که مدل ها را بر روی چند منبع آموزش دهیم. در مطالعات اولیه (قبل از یادگیری عمیق)، Shi، Sun و Wu [30] اشاره کرده اند که می توان یک طبقه بند فردی را بر روی دامنه های منبع فردی و یک دامنه هدف آموزش داد و سپس طبقه بندهای پایه را یا تمام منابع را به عنوان یک منبع یکپارچه در نظر گرفت و آموزش داد. همچنین برای یادگیری عمیق، Zhao و همکاران [31] به استفاده از استراتژی های اختلاف، تخصصی و تطابق ویژگی اشاره کرده اند.

یکی از استراتژی ها و یا حوزه هایی که برای تطبیق استفاده شده است، تولید دامنه میانی برای تطبیق است. در این حالت، یک دامنه با استفاده از مولفه های دامنه (معمولاً بر اساس GAN) ایجاد می شود.

۲-۳-۲. تطابق چند هدفه

به طور معمول، تطبیق دامنه از روش pairwise پیروی می کند، یعنی دامنه منبع به دامنه هدف متصل می شود و تلاش می شود تا مدلی که در دامنه منبع آموزش دیده است، به دامنه هدف منتقل شود.

با الهام از روش ذکر شده در مقاله [32]، Gholami و همکاران [33] به دنبال یافتن اطلاعات مشترک بین دامنه ها هستند. آن ها رویکردی به نام "روش اطلاعاتی تطبیق چند هدفه" یا MTDA-ITA ارائه می دهند. این روش از فضاهای خصوصی و مشترک بین ترکیب های دامنه های منبع و هدف استفاده می کند، مشابه روش DSN [29]. همچنین Isobe و همکاران [34] از تطابق چند هدفه برای وظایف تقسیم بندی معنایی با استفاده از مدل های مبدأ-مقصد و پل های مجزایی که بین جفت های مدل مبدأ-مقصد ایجاد شده اند برای همکاری استفاده کردند. یک مدل دانش آموز بر اساس تمام جفت های مدل

¹ Multi-Source Adaptation

² Multi-Target Adaptation

مبدأ-مقصد فردی با استفاده از تنظیمات متغیر در هر جفت مدل مبدأ-مقصد فردی یادگرفته می شود. دانش مشابهی نیز در یادگیری توجه چند معلمه چند مقصدی (MT-MTDA) درک شده است [35].

۲-۳-۴. روش های ترکیبی

در این بخش به ادغام تکنیک های متعددی که قبلاً برای تطبیق دامنه مورد بحث قرار گرفته است، می پردازیم.

۱-۴-۳-۲. روش های مبتنی بر تجمیع

روش های مبتنی بر تجمیع^۱ شامل چندین مدل مختلف هستند، که خروجی چندین مدل با هم ترکیب می شود. به طور معمول در وظایف رگرسیون از میانگین گیری، و در وظایف طبقه بندی از رای گیری استفاده می شود. تنوع مدل ها باعث می شود که انحراف از میزان درستی آن زیاد نباشد. یکی از مشکلات مهم این روش ها این است که از نظر محاسباتی پرهزینه هستند. روش های تجمیع برای تطبیق دامنه به دو زیر روش تقسیم می شوند:

◀ تجمیع با برچسب گذاری مصنوعی

در این روش، برچسب های دامنه هدف بر اساس دیدگاه ترکیب مدل های مختلف تعیین می شوند. اگر اکثر مدل ها به یک نتیجه مشابه برسند و اطمینان زیادی در مورد کلاس برچسب برای یک مثال خاص در دامنه هدف وجود داشته باشد، شبه برچسب ها برای آن مثال تعیین می شود. در واقعیت، یک مثال از دامنه هدف (نه منبع) برای آموزش طبقه بند هدف استفاده می شود.

◀ تجمیع خودتشکیلی

در این روش، ترکیب خروجی ها بر روی خروجی های یک مدل تکراری در طول زمان انجام می شود. ترکیب خروجی ها در طول زمان همچنین به عنوان تجمیع زمانی^۲ نیز شناخته می شود. به عبارت دیگر، اطلاعات زمانی نیز به ترکیب خروجی ها اضافه می شود.

۲-۳-۵. تطبیق دامنه چند حالت

تطبیق دامنه چند حالت^۳، به معنای تطبیق مدل های یادگیری ماشینی در مقابل دامنه های مختلفی است که داده های آنها دارای حالت های متفاوتی هستند. این داده ها معمولاً از چندین منبع ورودی به شکل های مختلفی تشکیل شده اند، مثلاً تصاویر و متون ممکن است با یکدیگر ترکیب شوند.

¹ Ensemble-Based Methods

² temporal ensembling

³ Multi-Modal Domain Adaptation

بزرگترین چالش در تطبیق دامنه چند حالتی این است که فرآیند تطبیق دامنه باید ساختارهای مختلف حالت و تغییرات مختلف دامنه برای هر حالت را در نظر بگیرد. به عبارت دیگر، هنگامی که با داده های چند حالتی سر و کار داریم، لازم است که مدل ها و الگوریتم های تطبیق دامنه به اختلاف ها و تفاوت هایی که در ساختار حالت ها و تغییرات دامنه وجود دارد، توجه داشته باشند.


در مواجهه با تطبیق دامنه چند حالتی، فرآیند تطبیق دامنه باید همچنین به فضاهای ویژگی مختلف، نمایش های مختلف و ابعاد مختلف فضای ویژگی داده ها نیز توجه کند. به عبارت دیگر، ویژگی های مختلف (مانند ویژگی های تصویری و ویژگی های متنی) باید با چالش تطبیق دامنه مرتبط شوند و مدل ها باید بتوانند از هر دو حالت بهره ببرند تا در محیط های مختلف به خوبی عمل کنند.

۱-۵-۳-۲. تطبیق دامنه چندحالتی یکپارچه

بیشتر کارهای مرتبط با تطبیق دامنه، داده های یکپارچه را پشتیبانی می کنند، و این بدین معناست که فضای ویژگی ثابت می ماند ($X^s = X^t$)، اما تغییر به دلیل توزیع های متفاوت داده ها اتفاق می افتد، به عبارت دیگر $P(X^s) \neq P(X^t)$. وقتی که هر دو دامنه منبع و مقصد حداقل دو حالت داده داشته باشند، به عبارت دیگر چندگانه باشند، اما همچنان فضای ویژگی (ویژگی های ورودی برای مسئله) یکسان باشد، حالت تطبیق دامنه چندگانه یکپارچه رخ می دهد. این شبکه ها توانایی ارتباط داخلی حالتی را بطور اجباری اجرا می کنند، اما مشاهده شده است که پیاده سازی ارتباطات میان حالتی و میان دامنه اختیاری است.

Xu, Yang و همکارانش [36] یک شبکه تطبیق دامنه چندگانه را با مازول های توجه و ادغام به همراه محدودیت های دامنه ترکیبی ایجاد کردند تا ویژگی های دامنه ای ثابت را یاد بگیرند. مازول توجه به درک ارتباط بین حالت ها کمک می کند و مدل دوخطی^۱ برای ادغام استفاده می شود.

¹ bilinear model



شکل ۱۲ ساختار/معماری شبکه معمولی برای شبکه های عصبی عمیق که اجرای تطبیق دامنه چند منظوره همگن را انجام می دهند. در بلوک درون دامنه ای^۱، تمیزدهنده ها ویژگی بردارها را مجبور می کنند تا ویژگی های بی تغییر در دامنه را یاد بگیرند. اما دو بلوک بین حوزه ای^۲ و بین دامنه ای^۳ اختیاری هستند و در هر تنظیم تطبیق دامنه چند منظوره ممکن است مشاهده نشوند [14].

۲-۵-۳-۲. تطبیق دامنه چند حالت ناهمگن^۴

در دنیای واقعی، داده های چند حالت و ناهمگن بسیار شایع هستند. با توجه به استفاده روزافزون از شبکه های عمیق در پردازش این داده های چند حالت و ناهمگن، یادگیری تطبیق دامنه در محیط های چند حالت و ناهمگن بسیار مهم است.

در تطبیق دامنه ناهمگن، معمولاً از شبکه های جداگانه برای استخراج ویژگی های دو دامنه مختلف استفاده می شود. سپس، اطلاعات ویژگی های مشترک بین دو دامنه به سطح وظیفه منتقل می شود، و این انتقال می تواند به دو صورت صورت بگیرد: در حالت اول وزن ها به صورت قوی (کامل) بین دو دامنه

¹ Intra Modality

² Inter Modality

³ Inter Domain

⁴ Heterogeneous Multi-Modal Domain Adaptation

به اشتراک گذاشته می شوند^۱ و در حالت دوم وزن ها به صورت ضعیف به اشتراک گذاشته می شوند^۲، که در کار Shu و همکارانش [37] ذکر شده است.

اهمیت تطبیق دامنه چند حالت ناهمگن زمانی مشخص می شود که یکی از حالت ها (مثلاً یکی از داده ها) در دامنه هدف وجود نداشته باشد. به عنوان مثال، اگر دامنه منبع دارای دو حالت m_1 و m_2 باشد ولی دامنه هدف تنها شامل m_3 باشد و m_4 را نداشته باشد، مسئله ی فقدان حالت^۳ پیش می آید. این مسئله توسط Ding و همکارانش [38] مورد بررسی قرار گرفته و روشی با عنوان یادگیری انتقال فقدان حالت از طریق محدودیت نرم افزاری نهان^۴ (M2TL) ارائه شده است. انتقال یادگیری در اینجا دوجانبه است: انتقال از یک پایگاه داده به پایگاه داده دیگر (انتقال میان پایگاه داده) و انتقال از حالت منبع به حالت هدف (انتقال میان حالت). در این روش از محدودیت ماتریس کم رتبه^۵ برای یادگیری زیرفضای داده در چارچوبی مختلف برای حالت های مختلف و با استفاده از MMD متغیرهای ویژگی بین پایگاه داده ها در دامنه منبع (حالت های مشخص شده) را به اشتراک می گذارند.

از جمله روش های مختلفی که در تطبیق دامنه چند حالت ناهمگن مورد استفاده قرار می گیرند میتوان به استفاده از شبکه های متخاصم دامنه مشروط^۶ (CDAN) [23] که توانایی تطبیق به توزیع های داده چند حالت دارند، اشاره کرد. این شبکه ها توسط مدل های مقابله ای ساخته می شوند و از اطلاعات تمایز دهنده برای تطابق با دامنه های مختلف استفاده می کنند. در اینجا، متمایز کننده بر اساس ماتریس ترکیبی داده های ویژگی خاص به هر دامنه و پیش بینی های طبقه بندی استفاده می شود. این رویکردها معمولاً برای مسائلی با فرآیندهای مختلف و داده های مختلف (مثلاً تصویر و صدا) مورد استفاده قرار می گیرند.

۲-۳-۶. روش های نوظهور

در این بخش، به تکنیک ها و مدل هایی اشاره می کنیم که در ادبیات موجود در زمینه تطبیق دامنه جای نمی گیرند. این تکنیک ها و مدل ها، توجه زیادی به خود جلب کرده اند و به نوعی نسبت به تنظیمات عملی بیشتری و/یا چالش های واقعی جهان واقعی تطبیق یافته اند.

¹ strong parameter sharing weights

² weakly parameter-shared weights

³ Missing Modality Problem

⁴ Missing Modality Transfer Learning

⁵ low-rank matrix

⁶ conditional domain adversarial networks

۲-۳-۱. تطبیق دامنه با داده های کم

چالش اصلی در تطبیق دامنه با داده های کم^۱ این است که تعداد داده های هدف کافی نیست تا به طور قاطع به نیازهای همزمان تطبیق دامنه پاسخ دهد. این نیازها شامل تبدیل دامنه و تطبیق نمایش بین دو دامنه می شوند.

۲-۳-۲. تطبیق دامنه بدون داده

تطبیق دامنه بدون داده^۲ به وضعیتی اشاره دارد که در آن داده های واقعی دامنه هدف در زمان آموزش حاضر نیستند، تنها برخی اطلاعات مرتبط با آن (معمولاً ابرداده های هدف) در دسترس است. تطبیق دامنه بدون داده از تطبیق دامنه معمولی متمایز می شود، زیرا در تطبیق دامنه معمولی هیچ اطلاعاتی در مورد داده های هدف موجود نیست، حتی ابرداده ها.

یادگیری بدون داده با استفاده از داده های مرتبط با وظیفه: Peng و همکارانش [39] در وظیفه های بینایی کامپیوتر از اطلاعات موجود در داده های مرتبط با وظیفه (جفت های دامنه) برای کمک به درک اطلاعات شبکه در مورد دامنه هدف که در زمان آموزش در دسترس نیست، استفاده می کنند.

یادگیری بدون داده با برچسب های جدید در دامنه هدف: هدف در اینجا این است که برچسب های کلاس های "متفاوت" در دامنه هدف را بر اساس برچسب های موجود در منبع یاد بگیریم. این موضوع در واقعیت یک سناریوی تطبیق دامنه نیست، زیرا دامنه برچسب در هر دو منبع یک مثال ذکر شده در مقاله کودیروف و همکارانش [40] برچسب "خرس قطبی" را می توان با استفاده از بردارهای تعبیه "پوست دارد"، "سفید است" و "ماهی می خورد" نمایان کرد. هر تعبیه معنایی که به این بردارهای تعبیه نزدیک باشد، به کمک در برچسب گذاری مؤثر خواهد بود.

¹ Few-Shot Domain Adaptation

² Zero-Shot Domain Adaptation

فصل ۳: مبانی تجربی تحقیق


۳-۱. مقدمه

در این فصل در ابتدا به بررسی مقاله ها و پایان نامه های انجام شده در زمینه تطبیق دامنه برای تشخیص اشیا که الگوریتم های پایه آن در بخش مبانی نظری بررسی شده اند، می پردازیم. سپس مجموعه دادگان استفاده شده در این زمینه را بررسی کرده و در نهایت، نتایج مقاله ها و پایان نامه های ذکر شده را مشاهده می کنیم.


۳-۲. تطبیق دامنه برای تشخیص اشیا

۳-۲-۱. مقالات

Khodabandeh و همکارانش [41] یک رویکرد یادگیری قوی برای تشخیص اشیا با تطبیق دامنه ارائه داده اند. نویسندگان مسئله را به عنوان آموزش با برچسب های نویزی فرموله کرده اند. بر اساس مجموعه ای از جعبه های محدود نویزی که توسط یک مدل تشخیص تنها در دامنه مبدأ آموزش داده شده اند، مدل نهایی تشخیص آموزش داده می شود.




شکل ۱۳ ساختار روش **Faster-RCNN Robust**. این شبکه از مدل آموزش دیده در منبع برای به دست آوردن برچسب های نویزی در مجموعه داده دامنه مقصد استفاده می کند. یک مازول دسته بندی برای به روزرسانی برچسب های نویزی استفاده می شود و کیفیت آنها را بهبود می بخشد. در نهایت، مدل تشخیص بر روی داده های دامنه مقصد با کمک یک تابع ضرر قوی آموزش می بیند که عدم قطعیت را جهت در نظر گرفتن احتمال اشتباهات ممکن در برچسب های نویزی شبه حاصل از مدل آموزش دیده در منبع می گیرد [41].




شکل ۱۴ مقایسه کیفی روش فوق با Faster R-CNN در آزمایش Cityscapes → KITTI [41]

Cai و همکارانش [42] رویکرد Mean Teacher را برای تشخیص اشیا در دامنه های متفاوت بهبود داده اند و روش Mean Teacher با روابط اشیا (MTOR) را ارائه داده اند. این روش به طور نوآورانه Mean Teacher را تحت تأسیس Faster R-CNN تغییر می دهد و روابط اشیا را با محاسبه هزینه سازگاری ادغام می کند.




شکل ۱۵ مروری بر معماری “Mean Teacher with Object Relations (MTOR)” برای تشخیص اشیا در دامنه های مختلف، با مدل های معلم و دانش آموز تحت یک backbone مشترک از [42]Faster R-CNN.

Kuniaki Saito و همکارانش [43] یک رویکرد جدید برای تطبیق بدون نظارت تشخیص دهنده های اشیا از دامنه های دارای برچسب به دامنه های کم برچسب پیشنهاد می دهد که می تواند هزینه های برچسب گذاری مرتبط با تشخیص را به طرز قابل توجهی کاهش دهد. روش پیشنهادی بر تطبیق محلی قوی و تطبیق جهانی ضعیف تمرکز دارد و در چندین مجموعه داده با میزان بسیار بالایی از روش های موجود ارتقاء می یابد. مدل تطبیق ضعیف برای تمرکز بر تلفیق نقضی روی تصاویری طراحی شده است که به طور جهانی مشابه هستند و کمتر تأکیدی بر تطبیق تصاویری دارند که به طور جهانی متفاوت هستند. مدل تطبیق دامنه قوی برای تنها نگاه کردن به میدان های محلی از نقشه ویژگی طراحی شده است. روش پیشنهادی در صورتی که دو دامنه متفاوت و مشابه باشند، تأثیربخش در مواقع تطبیق اثبات شده است.



شکل ۱۶ معماری شبکه پیشنهادی. این روش با استفاده از یک شبکه تشخیص دهنده دامنه محلی و یک شبکه تشخیص دهنده دامنه جهانی تطبیق قوی-محلی انجام می‌دهد و تطبیق ضعیف-جهانی را به انجام می‌رساند. بردار متناظر از طریق تشخیص دهنده دامنه استخراج می‌شود و در لایه قبل از لایه کاملاً متصل نهایی ادغام می‌شود [43].


Zhenwei He و همکارانش [44] یک روش جدید برای تشخیص اشیا در محیط‌های نامحدود با بهره‌گیری از دانش دامنه آموزش داده شده، از یک دامنه منبع فرعی پیشنهاد شده است. چارچوب multi-adversarial Faster-RCNN (MAF) پیشنهادی را برای به حداقل رساندن اختلاف دامنه برای تطبیق دامنه در نمایش ویژگی بیان می‌کند و شامل یک ماژول تطبیق ویژگی دامنه سلسله مراتبی، یک ماژول کاهش مقیاس اطلاعات ثابت (SRM) و یک ماژول تطبیق ویژگی پیشنهاد جمع شده می‌شود. تشخیص دهنده MAF می‌تواند به صورت تماماً انتها به انتها با بهینه‌سازی تابع از دست دادن تطبیق دامنه و تابع از دست دادن تشخیص Faster-RCNN آموزش داده شود. آزمایشات انجام شده بر روی چندین مجموعه داده با دامنه‌های مختلف نشان می‌دهد که رویکرد پیشنهادی نتایج برتری دارد و اثربخشی مدل را تایید می‌کند. به طور کلی، این مقاله یک راه‌حل موثر برای مسئله چالش برانگیز تشخیص اشیا در محیط‌های نامحدود ارائه می‌دهد.



شکل ۱۷ ساختار شبکه MAF. این شبکه الهام گرفته از Faster-RCNN مبتنی بر VGG16 است. MAF ماژول‌های تطبیق ویژگی را هم بر روی ویژگی‌های دامنه و هم بر روی ویژگی‌های پیشنهاد اعمال می‌کند. برای ماژول تطبیق ویژگی دامنه سلسله مراتبی، چندین زیرماژول تطبیق کننده دامنه متخاصم روی بلوک ۳، ۴، ۵ VGG16

پایه سازی شده است. لایه های GRL برای استراتژی یادگیری تخصصی استفاده می شوند و اندازه نقشه های ویژگی توسط ماژول های کاهش مقیاس SRM کاهش می یابد. در ماژول تطبیق ویژگی، امتیازهای دسته بندی و نتایج بازایی جعبه مرتبط با ویژگی ها در دامنه دسته بندی ترکیب شده است و این در حالی است که WGRL برای استراتژی یادگیری تخصصی معرفی می شود. SRM از دو بخش تشکیل شده است، بخش اول یک لایه پیکسل های کانولوشن 1×1 است که برای کاهش اندازه کانال اعمال می شود. بعد از آن، بخش کاهش مقیاس برای ترکیب ویژگی های مجاور $S \times S$ استفاده می شود تا اندازه نقشه های ویژگی کاهش یابد [44].

Yuhua Chen و همکارانش [45] یک رویکرد جدید برای بهبود انطباق دامنه ای و کاهش آسیب پذیری در تشخیص اشیا ارائه می دهند، به نام Faster R-CNN تطبیق دامنه ای. چالش اصلی در تشخیص اشیا هنگامی که داده های آموزش و آزمون از توزیع های مختلفی گرفته شوند، تغییر دامنه است. برای حل این مشکل، رویکرد پیشنهادی دو مؤلفه تطبیق دامنه را در سطح تصویر و سطح نمونه به مدل Faster R-CNN اضافه می کند تا کمینه کردن همگرایی H بین دو دامنه را انجام دهد. در هر مؤلفه، یک طبقه بند دامنه آموزش داده می شود و استراتژی آموزش دشمن گرایی برای یادگیری ویژگی های مقاوم در برابر دامنه های مختلف استفاده می شود که دامنه ثابت باشند. یک تنظیم مرتب سازی همچنین بین طبقه بند دامنه ها در سطوح مختلف جهت یادگیری یک شبکه پیشنهاد منطقه (RPN) ثابت دامنه در مدل Faster R-CNN اضافه می شود. رویکرد پیشنهادی بر روی چندین مجموعه داده ارزیابی می شود و کارایی خود را در تشخیص قوی اشیا اثبات می کند. مشارکت های این کار شامل تحلیل تئوری مشکل تغییر دامنه، طراحی دو مؤلفه تطبیق دامنه برای کاهش اختلاف دامنه در سطح تصویر و سطح نمونه، تنظیم مرتب سازی جهت تشویق RPN به تبدیل شدن به ثابت دامنه و ادغام مؤلفه های پیشنهادی در مدل Faster R-CNN است که می تواند به صورت کامل آموزش داده شود.




شکل ۱۸ یک نمای کلی از مدل Domain Adaptive Faster R-CNN در این روش با دو سطح، سطح تصویر و سطح نمونه، تغییر دامنه مورد بررسی قرار داده شده است. در هر سطح، یک طبقه بند دامنه بر پایه ساخته شده است که به شیوه آموزش تخصصی آموزش داده می شود. یک تنظیم کننده تناسب همراه با این دو طبقه بند در داخل این دو طبقه بند به منظور یادگیری یک RPN ثابت دامنه برای مدل Faster R-CNN وارد شده است [45].

Lukas Hoyer و همکارانش [46] رویکرد نوآورانه ای به نام MIC را ارائه دادند. در این روش ابتدا شبکه f_θ روی دامنه منبع آموزش می بیند و تابع ضرر بسته به اینکه کدام کار بینایی کامپیوتر انجام می شود انتخاب می گردد که در اینجا $\mathcal{L}^S$ مربوط به قطعه بندی معنایی است و نماد تابع ضرر مربوط به دامنه منبع است. سپس متناسب با روش UDA انتخابی و الگوریتم آن $\mathcal{L}^T$ که نماد تابع ضرر مربوط به دامنه هدف است انتخاب می شود. شبکه f_θ یکبار روی دامنه منبع آموزش می بیند و وزن های آپدیت می شوند. بعد از آن روی دامنه هدف اجرا می شود و یک وزنی می گیرد. سپس مازول MIC شروع به کار می کند. تصاویر دامنه هدف به صورت تصادفی پوشیده می شوند و به شبکه f_θ وارد می شوند. شبکه برای هر کدام از تصاویر پوشیده شده باید پیش بینی انجام دهد و حتی برای قسمت های پوشیده شده نیز باید پیش بینی کند که متعلق به چه کلاسی هستند و باید این کار را با استفاده از اطلاعات باقی مانده از تصویر انجام دهد و از اطلاعات زمینه ای استفاده کند.

از آن جایی که در دامنه هدف برچسبی وجود ندارد برای ارزیابی پیش بینی های شبکه از یک شبکه EMA Teacher استفاده می شود. این شبکه با گرفتن تصاویر پوشیده نشده دامنه هدف برچسب های ساختگی تولید می کند. شبکه f_θ به عنوان شبکه Student فقط آموزش می بیند و سپس در هر مرحله از آموزش با ضربی وزن های خود را به مدل EMA Teacher تخصیص می دهد. شبکه EMA Teacher با یک ضربی وزن های قبلی خود را نگه می دارد. پس در واقع مدل EMA Teacher به یک بازه زمانی از وزن های Student دسترسی دارد. اولین وزنی که از student به EMA Teacher تخصیص می یابد وزنی است که حاصل از آموزش f_θ روی دامنه هدف است.

مدل EMA Teacher علاوه بر اینکه به وزن های f_θ دسترسی دارد به تصاویر دامنه هدف که پوشیده شده نیستند نیز دسترسی دارد. پس در واقع این مدل هم به اطلاعات محلی و هم به اطلاعات زمینه ای دسترسی دارد. اطلاعات محلی از تصاویر پوشیده نشده و اطلاعات زمینه ای از تخصیص وزن


های f_θ به مدل EMA Teacher حاصل می شود. این مدل با داشتن این اطلاعات می تواند در نهایت برچسب های ساختگی قوی تولید بکند.



شکل ۱۹ UDA با (MIC). در UDA، یک شبکه معمولاً با یک Loss نظارت شده در دامنه منبع (آبی) و یک تابع ضرر تطبیقی بدون نظارت در دامنه هدف (سبز) آموزش داده می شود. MIC سازگاری بین پیش بینی های تصاویر هدف پوشانده شده (بنفش) و برچسب های ساختگی که بر اساس تصویر کامل توسط (EMA Teacher) تولید می شوند، اعمال می کند. برای به حداقل رساندن Loss مربوط به MIC، شبکه باید بیاموزد که پیش بینی های مناطق پوشانده شده را از بافت آن ها استخراج کند [46].

Giulio Mattolin و همکارانش [47] یک روش نوآورانه برای تطبیق دامنه بدون نظارت در تشخیص اشیاء ارائه دادند که یک استراتژی مخلوط کردن نمونه ها بر اساس اعتماد تشخیص در سطح ناحیه را معرفی می کند. رویکرد پیشنهادی هدف، آموزش یک تشخیص دهنده اشیاء پیش آموزش دیده به یک دامنه هدف جدید است که برای آن توصیف ها در دسترس نیست. ConfMix از دو مرحله اصلی تشکیل شده است: (۱) مرحله آموزش فقط در دامنه منبع، در این مرحله تشخیص دهنده بر روی دامنه منبع آموزش داده می شود؛ و (۲) مرحله تطبیق دامنه، در این مرحله تشخیص دهنده بر روی مخلوطی از نمونه های منبع و هدف تنظیم می شود. استراتژی مخلوط کردن بر اساس امتیازهای اعتماد تشخیص دهنده در دامنه هدف مبتنی است و به تدریج نمونه های با اعتماد کم را فیلتر می کند تا از انتقال منفی جلوگیری شود. ConfMix در چندین مجموعه داده، از جمله KITTI، Sim10k و Cityscapes، کارایی بهتر از روش های تطبیق دامنه بدون نظارت موجود را داشته و عملکرد بهتری را از خود نشان می دهد.

همچنین نشان داده شده است که رویکرد پیشنهادی در حالات با تغییرات آب و هوا و دوربین نیز موثر است و پتانسیل کاربردهای واقعی را نشان می دهد.



شکل ۲۰ نمای کلی از روش ConfMix پیشنهادی. ما نمونه های منبع x_s و نمونه های هدف x_t را به مدل تشخیص دهنده $F(\theta)$ منتقل می کنیم و پیش بینی های $\tilde{y}_s$ و $\tilde{y}_t$ را به ترتیب دریافت می کنیم. ما ناحیه هدف با بالاترین اعتماد منطقی را برای تشکیل نمونه مخلوط x_m با تصویر منبع انتخاب می کنیم، سپس این نمونه به مدل تشخیص دهنده $F(\theta)$ منتقل می شود و پیش بینی های $\tilde{y}_m$ را تولید می کند. ما مدل را با استفاده از دست دادن تشخیص نظارت شده با استفاده از اشارات منبع $\tilde{y}_s$ و از دست دادن تناسب خود-نظارتی با مقایسه $\tilde{y}_m$ با پیش بینی های ترکیبی منبع و هدف $\tilde{y}_{s,t}$ آموزش می دهیم [47].

CycleGAN است و از توابع cycle-consistent loss به عنوان یکی از مؤلفه های آن استفاده می کند. در واقع، CyCADA از یک ترکیب از تفاوت های تصویری، اطلاعات ویژگی و هدف برای انجام یک وظیفه خاص به عنوان یک مجموعه از توابع ضرر برای آموزش مدل استفاده می کند.

اولین تابع ضرری که در CyCADA استفاده می شود، تابع ضرر cycle-consistent است. این تابع مطمئن می شود که تصاویر بین دو دامنه (دامنه مبدا و دامنه مقصد) به درستی ترجمه شده و بازگردانده شده و تغییرات ناشی از ترجمه در حداقل کمیت هایی از این تابع هدف نمایان می شوند.


علاوه بر آن سایر توابع ضرر در سه سطح ارائه می شوند: feature-level، image-level و task. در سطح تصویری معمولاً به مقایسه تصاویر میان دو دامنه و محاسبه تفاوت های تصویری بین آنها می پردازد. سطح ویژگی به معنای مقایسه ویژگی های تصاویر و محاسبه تفاوت های ویژگی بین دو دامنه است. این تابع های هدف به کمک آموزش مدل به تفاوت ها و تطابق های بین دو دامنه کمک می کنند. تابع task نیز برای حل یک وظیفه خاص (مثلاً تشخیص شیء در یک تصویر) در دامنه مقصد مورد استفاده قرار می گیرد. در نهایت، تمام این تابع های هدف با هم ترکیب می شوند و سعی در به حداقل رساندن مقدار آنهاست.

شبکه های بازگردنده در تصویر¹ (DRCN) [49] یک روش در حوزه بینایی ماشین و پردازش تصویر hsj که برای مسائل بازگردنده و پیچیده در تصویربرداری و پردازش تصاویر مورد استفاده قرار می گیرد. این روش تلاش می کند تا با استفاده از اتصالات بازگردنده میان اطلاعات مختلف در تصاویر، اطلاعات ساختاری و معنایی عمیق تری از تصاویر استخراج کند. هدف اصلی DRCN بهبود کیفیت تصاویر است. این بهبود کیفیت می تواند شامل افزایش وضوح، کاهش نویز، افزایش تبیین و ویژگی های دیگری باشد که به تصاویر اضافه می شود. ایده اصلی در DRCN این است که از شبکه های بازگردنده برای استخراج ویژگی های تصویر استفاده شود و سپس از این ویژگی ها برای بهبود تصویر اصلی استفاده کنیم.

در ادبیات، روش های دیگری وجود دارند که به طور کامل با تعریف بازسازی تخصیص همخوانی ندارند، اما به شدت به روش کار آن نزدیک هستند و یک مثال آن روش DiscoGAN است. DiscoGAN [50] همانند روش CycleGAN عمل می کند، با این تفاوت که از cycle-consistent loss استفاده نمی کند.


Arruda و همکارانش [51] یک روش تشخیص اتومبیل در دامنه های مختلف با استفاده از ترجمه تصویر به تصویر بدون ناظر ارائه داده اند. آن ها از CycleGAN به منظور ترجمه تصاویر از دامنه روز به دامنه شب به منظور ایجاد مجموعه داده مصنوعی استفاده کردند. در این مرحله، تصاویر از دامنه روز به دامنه شب ترجمه شده و مجموعه داده مصنوعی ایجاد می شود. در نهایت، مدل تشخیص (مدلی که اتومبیل ها را تشخیص می دهد) بر روی مجموعه داده مصنوعی آموزش داده می شود و اطلاعات برچسب گذاری شده از دامنه منبع به مجموعه داده مصنوعی منتقل می شود و مدل تشخیص از تصاویر ترجمه شده از دامنه روز به دامنه شب به طور خودکار یاد می گیرد. این امر به ایجاد یک مدل تشخیص قادر به تشخیص اتومبیل ها در دامنه های مختلف در شرایط مختلف نورپردازی کمک می کند.

¹ Deep Reconstruction Classification Networks




شکل ۲۱ مروری بر چارچوب CycleGAN در این برنامه. G_N تصاویر را از دامنه روز به دامنه شب نگاشت می‌کند، در حالی که G_D نگاشت را به صورت معکوس انجام می‌دهد. تشخیص‌دهندگان D_D و D_N ارزیابی می‌کنند که آیا این تصویر واقعی است یا به ترتیب تصویر تقلبی در دامنه شب و روز است. محدودیت تطابق چرخه با استفاده از تابع ضرر L1 برای اطمینان از توانایی بازسازی مورد استفاده قرار می‌گیرد [51].

Jiaxi Wu و همکارانش [52]، یک رویکرد جدید برای تشخیص چند منبعی بدون نظارت و تطبیق دامنه (DAOD) ارائه شده است که به مسئله کاهش دانش در طی ترکیب آن‌ها پرداخته است. روش پیشنهادی، به نام حفظ دانش مرتبط با هدف (TRKP)، از دو مؤلفه اصلی تشکیل شده است: مازول تبادل چند منبعی تخصصی (AMSD) و یک طرح معدن دانش کلی مرتبط با هدف (HTRM). مازول AMSD ویژگی‌های مختص منبع و ویژگی‌های مرتبط با هدف را از یکدیگر جدا می‌کند، در حالی که طرح HTRM دانش مرتبط با هدف را از ویژگی‌های چند منبع استخراج می‌کند. رویکرد پیشنهادی بر روی چندین مجموعه داده مرجع ارزیابی شده و با روش‌های برتر مقایسه شده است. نتایج نشان می‌دهند که TRKP در اصطلاح عملکرد و کارایی نسبت به روش‌های دیگر از جمله عملکرد برتری دارد.



شکل ۲۲ بررسی کلی چارچوب رویکرد پیشنهادی TRKP. پیکان های سفید به انتقال به جلو اشاره دارند و پیکان های خط خورده نظارت را نمایان می کنند. تشخیص دهنده معلم بر روی تصاویر منبع دارای برچسب آموزش داده می شود و برچسب های سیاه برای تصاویر بدون برچسب در دامنه هدف تولید می کند که تشخیص کننده دانش آموز را راهنمایی می کند. TRKP از ماژول تبادل چند-منبعی (AMSD) برای حفظ دانش ویژگی های مخصوص دامنه منبع و از طرح معدن دانش کلی مرتبط با هدف (HTRM) برای تقویت تمرکز دانش مرتبط با هدف استفاده می کند، که به طور قابل توجهی به تطبیق دانش چند-منبع با دامنه هدف کمک می کند [52].

Han-Kai Hsu و همکارانش [53] یک رویکرد نوآورانه به نام تطبیق دامنه پیشرو^۱ برای شناسایی اشیا ارائه می دهد تا شکاف دامنه را پوشش دهد و عملکرد مدل های شناسایی اشیا را بهبود ببخشد. این روش از یک دامنه میانی و یادگیری متخاصم برای تطابق توزیع ها در سطح ویژگی استفاده می کند. همچنین از یک تابع ضرر وزن دار ویژگی های تصویر نامتعادل استفاده می کند. این روش به تدریج به دامنه مقصد با استفاده از فضای ویژگی میانی سازگار می شود و نسبت به روش پایه در معیار mAP بهبود می یابد. روش پیشنهادی در موارد مختلف مانند موارد دور بین متقاطع، شرایط آب و هوا و تطبیق با مجموعه داده های بزرگ عملکرد بهتری داشته است.



شکل ۲۳ شکل ۷ چارچوب پیشنهادی روش تطبیق دامنه پیشرو را نشان می دهد. الگوریتم شامل دو مرحله تطابق است، که در (a) و (b) نشان داده شده است. در (a)، ابتدا تصاویر منبع را تبدیل کرده و تصاویر مصنوعی را با استفاده

¹ progressive domain adaptation

از مولد G که از طریق CycleGAN یادگرفته شده است، تولید می شود. سپس از دامنه منبع با برچسب استفاده کرده و تطابق مرحله اول را با دامنه مصنوعی انجام می دهیم. در b ، مدل یک تطابق مرحله دوم انجام می دهد که دامنه مصنوعی با برچسب های از منبع به ارث برده شده را می گیرد و ویژگی های دامنه مصنوعی را با توزیع هدف هماهنگ می کند. علاوه بر این، وزن w از تشخیص دهنده Dcycle در CycleGAN به منظور تعادل کیفیت تصاویر مصنوعی در از دست دادن تشخیص به دست می آید. ساختار کلی شبکه تطابق ما در c نشان داده شده است. تصاویر با برچسب و بدون برچسب هر دو از طریق شبکه رمزگذار E منتقل می شوند تا ویژگی های $featL$ و $featU$ استخراج شود. سپس از آنها برای: (۱) یادگیری تشخیص اشیاء تحت نظر با شبکه تشخیص از $featL$ استفاده می شود، و (۲) هر دو ویژگی را به GRL و یک تشخیص دهنده دامنه ارسال می کنیم تا ویژگی های بی دامنه را به صورت مقابله ای و با تحدید نوعی دامنه یادگرفته شود [53].



شکل ۲۴ نمونه هایی از نتایج تشخیص از سه وظیفه تطبیق روش تطبیق دامنه پیشرو. دو ردیف اول به ترتیب نتایج آزمایش KITTI به Cityscapes و Cityscapes به Foggy Cityscapes هستند، در حالی که دو ردیف آخر نتایج Cityscapes به BDD100k هستند. نتایج تشخیص روی دامنه مقصد قبل و بعد از اعمال روش تطبیق دامنه به همراه برچسب های واقعی نمایش داده شده است [53].

T. Kim و همکارانش [54] یک چارچوب تطبیق دامنه جهانی برای تشخیص اشیاء پیشنهاد می شود که لایه های تشخیص اشیاء بدون تغییر دامنه را با داده های برچسب گذاری شده و تنوع دار آموزش می دهد، در عین حال دامنه های منتشر را به سوی یک فضای ویژگی مشترک تشویق می کند. این چارچوب به مسئله تمایل به تمایز بر مبنای منبع و مسئله ترجمه ناقص پرداخته است. رویکرد شامل دو مرحله به نام تنوع دامنه (DD) و یادگیری نمایندگی چند دامنه ای (MRL) است و به نسبت زیادی روش های جاری را در انواع مختلف مجموعه داده ها پیش می گیرد.

مرحله اول، تنوع دامنه، روشی است که با تولید عمدی تغییرات متفاوت در دامنه از طریق متغیرهای دامنه، دامنه منبع را متنوع تر می کند. توزیع متنوع داده های برچسب گذاری شده، مدل را تشویق به استنباط میان داده های با تفاوت داخلی کلاس بزرگ و تفاوت بیرون کلاس می کند. این امکان را به مدل می دهد تا ویژگی های معنایی بدون تعصب از دامنه هدف استخراج کند که متمایزتر از ویژگی های تعصبی به منبع هستند.

مرحله دوم، یادگیری نمایندگی چند دامنه ای، یک روش است که لایه های تشخیص اشیا بدون تغییر دامنه را با داده های برچسب گذاری شده و تنوع دار آموزش می دهد، در عین حال دامنه های منتشر را به سوی یک فضای ویژگی مشترک تشویق می کند. این مرحله به مسئله تمایل به تمایز بر مبنای منبع و مسئله ترجمه ناقص پرداخته است. رویکرد نشان داده است که عملکرد برتری را در مجموعه های داده مختلف از جمله مجموعه های داده جهان واقعی، مجموعه های داده رسانه هنری و مجموعه های داده صحنه های شهری به دست آورده است.



شکل ۲۵ معماری چارچوب تطبیق دامنه روش فوق برای تشخیص اشیا. این چارچوب بر پایه شبکه تشخیص اشیا ساخته شده است [54].

یک مثال از تجمیع خودتشکیلی در تطبیق دامنه، استفاده از معماری "Teacher-Student" است که Valpola و همکارانش [55] ارائه داده اند و Fisher و همکارانش [56] از آن در مقاله خود استفاده کرده اند. در این روش، یک شبکه معلم به عنوان مدل منبع روی وظیفه آموزش می شود و خروجی هایی که احتمالاتی هستند (برخلاف برچسب های صحیح) را تولید می کند. سپس شبکه دانش آموز از معلم یاد می گیرد و می تواند اطلاعات بهتری را فهمیده و به عنوان نتیجه بهتری داشته باشد. ترکیب خروجی ها برای آموزش شبکه دانش آموز با استفاده از کاهش گرادیان^۱ انجام می شود، و وزن معلم به عنوان میانگین متحرک از شبکه دانش آموز استفاده می شود.

(M3DA^۲) [57] مجموعه داده چند دامنه ای به نام DomainNet با ۶ دامنه ایجاد کرد. علاوه بر این، آن ها لحظات توزیع ویژگی ها را بین دامنه های منبع دارای برچسب چندگانه و دامنه هدف به صورت پویا تطابق دادند.

^۱ gradient descent

^۲ Moment Matching for Multi-Source Domain Adaptation


Zhao و همکارانش [34] شبکه تجمع دامنه تخصصی چند منبعی (MADAN) را معرفی کردند که اساساً از CycleGAN (تفکیک کننده زیر دامنه برای دامنه های منبع و متمایز کننده چرخه متقابل دامنه برای دامنه های منبع-هدف) استفاده می کند و یک دامنه تطبیقی پنهان برای تمام داده های منبع و داده های هدف ایجاد می کند.

روش Few-Shot Adversarial Domain Adaptation (FADA) توسط Motiian و همکارانش [58] معرفی شده است و از یادگیری تضادی با تمرکز بر سرعت تطبیق استفاده می کند. آنها با ترکیب نمونه های منبع و هدف به چهار دسته بر اساس دامنه و برچسب های کلاسی تقسیم کردند و سپس طبقه بند بر روی این چهار دسته به جای دو دسته معمولی کار می کند. آنها شبکه را (استخراج کننده و طبقه بند برچسب) فقط با داده های منبع مقداردهی اولیه کردند، سپس متمایز کننده دسته دامنه (استخراج کننده ویژگی را فریز کردند) را به روز کردند. در نهایت، متمایز کننده دسته دامنه را فریز کردند و استخراج کننده و طبقه بند برچسب را به روز کردند.

روش Domain-Adaptive Few-Shot Learning (DA-FSL) [59] به حل یک مسئله پیچیده تر مرتبط با یادگیری Few-Shot پرداخته می شود، یعنی داده های هدف ممکن است کلاس هایی داشته باشند که متعلق به دامنه های مختلفی باشند. تمرکز شبکه تضادی دامنه ای (DAPN) در DA-FSL بر دستیابی به تطابق در توزیع دامنه جهانی است، و این کار با معرفی توابع ضرر جدید صورت می گیرد در حالی که تمایز کلاسی را حفظ می کند. این توابع ضرر از طریق یک مکانیزم تغییر وزن تطبیقی وزن دهی می شوند. جنبه نوآورانه دیگر در استفاده از مکانیزم توجه قبل از تعبیه منبع است.

روش Prototypical Cross-domain Self-Supervised Learning (PCS) توسط Yue و همکارانش [60] معرفی شده و شامل یادگیری خودکار (که به عنوان چارچوب یادگیری خودی متقابل میان دامنه ای تقلبی (PCS) نامیده می شود) و بدون نظارت است. ایده اصلی انتقال دانش از منبع به هدف این است که شباهت هایی بین نمونه و نماینده (نمونه نماینده) پیدا کند تا انتقال به شکل مستحکم تری انجام شود.

تشخیص اشیاء در دامنه های تطبیقی کم داده (FSDAOD) یک وظیفه چالش برانگیز است که تنها تعداد محدودی تصاویر هدف برای آموزش در کنار تعداد کافی تصاویر منبع برچسب گذاری شده در دسترس است. کمبود داده در دامنه هدف منجر به عدم تعادل شدید داده بین دامنه های منبع و هدف می شود، که احتمالاً در تطبیق سنتی ویژگی باعث انجام یادگیری بیش از حد می شود. برای حل این مشکل، نویسندگان مقاله [61] یک پارادایم تطبیق نامتقارن به نام AsyFOD ارائه می دهند که از نمونه های منبع و هدف از دیدگاه های مختلف بهره می برد.



شکل ۲۶ توضیح مختصری از AsyFOD. پس از استخراج نقشه ویژگی تصاویر ورودی از طریق بخش اصلی، نمونه های ویژگی مرتبط با نمونه به وسیله ماژول پروژه های و حقایق ارائه شده استخراج می شوند. سپس، AsyFOD نمونه های منبع را به دو مجموعه تشخیص هدف مشابه (آبی تیره) و مجموعه تشخیص هدف نامشابه (آبی روشن) تقسیم می کند. نمونه های منبع مشابه هدف برای افزایش نمونه های هدف استفاده می شوند. با این تقسیم بندی، تطبیق ناهمگام بین نمونه های منبع نامشابه هدف و نمونه های هدف افزایش یافته انجام می شود که باعث کاهش یادگیری زود هنگام ناشی از توزیع داده های بسیار نامتعادل می شود. همچنین، AsyFOD آموزش نظارت شده متمرکز بر وظیفه را برای وظایف طبقه بندی و مکان یابی به طور جداگانه انجام می دهد. بهترین نمایش در حالت رنگی مشاهده می شود [61].

AsyFOD ابتدا نمونه های مشابه به هدف را با استفاده از تخمین توزیع هدف تشخیص می دهد، که به افزایش تعداد محدودی نمونه هدف کمک می کند. سپس، AsyFOD تطبیق ناهمگام بین مجموعه نمونه های منبع نامشابه هدف و مجموعه محدود نمونه هدف انجام می دهد تا از یادگیری بیش از حد جلوگیری کند. نویسندگان همچنین یک عملیات توقف-گردان را ارائه داده اند تا از جریان گردان به دامنه منبع در طول فرآیند تطبیق جلوگیری کنند.

Jaemin Na و همکارانش [62] رویکرد جدیدی برای تطبیق دامنه بدون نظارت^۱ (UDA) برای یادگیری نمایش های مقاوم در برابر تغییرات دامنه به نام FixBi ارائه دادند. بیشتر مطالعات بر اساس تطبیق مستقیم از دامنه منبع به دامنه مقصد انجام شده اند و از تفاوت های بزرگ دامنه رنج می برند. در این مقاله، یک روش UDA ارائه شده است که به طور موثر با تفاوت های بزرگ دامنه ای مقابله می کند.

در این روش، از مخلوط مبتنی بر نسبت ثابت برای افزایش دامنه های میانی چندگانه بین دامنه منبع و دامنه مقصد استفاده می شود. از این دامنه های افزوده، مدل مغرور از دامنه منبع و مدل مغرور از دامنه مقصدی را آموزش می دهیم که ویژگی های تکمیلی دارند. با استفاده از روش های یادگیری مبتنی بر اعتماد، مانند مطابقت دوطرفه با پیش بینی های با اعتماد بالا و خود تنبیه با استفاده از

¹ Unsupervised Domain Adaptation


پیش بینی های با اعتماد پایین، مدل ها می توانند از یادگیری از یکدیگر یا از نتایج خود یاد بگیرند. از طریق روش های پیشنهادی نویسندگان، مدل ها به تدریج دانش دامنه را از دامنه منبع به دامنه مقصد منتقل می کنند. آزمایش های گسترده نشان می دهند که روش پیشنهادی فوق برتری خود را در سه بنچمارک عمومی، Office-31، Office-Home و VisDA-2017، اثبات کرده است.

۲-۲-۳. پایان نامه ها

Artem Bitiutskii در پایان نامه خود [63]، در مورد روش جدید توسعه یافته ای به نام "DannFixbi" بحث می کند که رویکرد Fixbi [62] و رویکرد بازگشت عصبی را ترکیب می کند. تصمیم برای ترکیب این دو رویکرد بر اساس نقاط قوت متقابل و قابلیت تعامل متقابل میان آن ها اتخاذ شده است. با استفاده از تکنیک Fixbi که اختلاف حوزه را مدیریت می کند و بهره برداری از مزایای بازگشت عصبی، DannFixbi به بهبود عملکرد و استحکام تطبیق حوزه در زمینه تصاویر هدف می گیرد. توسعه DannFixbi نمایانگر یک مشارکت اصیل در این زمینه است.


این روش جدید از دو شبکه عصبی تشکیل شده است که با استفاده از یک نسخه اصلاح شده از رویکرد Fixbi آموزش داده می شوند. برای بهبود عملکرد این روش، دو طبقه بند حوزه به هر دو این دو شبکه اضافه شده است. دو رویکرد مختلف برای یادگیری این طبقه بندهای حوزه مورد بررسی قرار گرفته است.

رویکرد اول شامل افزودن یک طبقه بند حوزه به هر شبکه عصبی است (اشاره به شکل ۲۷). در طول مرحله آموزش، تصاویر حاصل از میکس کردن داده های حوزه منبع و حوزه مقصد با نسبت های mixup از پیش تعیین شده به این طبقه بندها وارد می شوند.



شکل ۲۷ ساختار DannFixbi برای رویکرد اول [63]

در رویکرد دوم، از یک طبقه‌بند حوزه برای هر یک از شبکه‌ها با تصاویر از حوزه منبع و حوزه مقصد بدون هیچ مخلوطی استفاده می‌شود، مشابه روش بازگشت عصبی (اشاره به شکل ۲۸).



شکل ۲۸ ساختار DannFixbi برای رویکرد دوم [63]

Gabriele Degola در پایان‌نامه خود [64] در مورد انتقال دانش بین حوزه‌های مختلف در یک سناریوی تشخیص اشیا مطالعه داشته است. این وظیفه با چالش‌های زیادی همراه است و کاربردهای متعددی در حوزه‌های تجاری مختلف دارد.

یکی از چالش‌های اصلی در این پروژه، کمبود داده‌های توصیف شده (annotated data) برای مورد مطالعه مورد نظر است. این مشکل اغلب یکی از مهم‌ترین موانع برای پروژه‌های یادگیری ماشین است. مهندسان باید ساعت‌ها صرف جمع‌آوری و امکاناً توصیف داده‌های مرتبط کنند، به جای اینکه بر روی الگوریتم‌ها و بهینه‌سازی تمرکز کنند. از سوی دیگر، داده‌های مصنوعی به راحتی و به تعداد زیادی قابل

تولید هستند. علاوه بر این، وظایف در دست معمولاً مشابه هستند، اما داده ها تحت شرایط مختلفی از نور، طیف نور، زاویه دوربین و موارد مشابه جمع آوری شده اند.

مدل های آموزش داده شده در گذشته قابل استفاده مجدد نیستند، و به همین دلیل فرآیند آموزش طولانی نیاز دارد. به همین منظور، تحقیق انجام شده در این پایان نامه، رویکردها ساده ای برای تشخیص اشیا با تطبیق دامنه را ارائه و نشان می دهد که مستقل از معماری های شبکه مورد استفاده و بدون معرفی تغییرات پیچیده در معماری می توانند نتایج قابل قبولی را به دست آورند و با روش های پیچیده تری که پیش تر در ادبیات معرفی شده اند، رقابت کنند.

در بخش نتایج آزمایشی پایان نامه خود، نویسنده عملکرد شبکه های Faster R-CNN و RetinaNet را روی مجموعه داده CityScapes ارزیابی کرد. او از رویکردهای یادگیری ویژگی مقاوم در برابر دامنه و تطبیق دامنه برای بهبود عملکرد این شبکه ها استفاده کرد. نتایج نشان داد که تغییرات در روشنایی، تضاد، اشباع و رنگ های تصاویر باعث افزایش نتایج تشخیص در مجموعه داده CityScapes می شود. تغییرات اضافی مانند Solarization (تغییر دیگری در نور و رنگ تصویر)، Equalization (متعادل کردن تصویر) یا تقسیم کردن تصویر به اندازه و شکل های مختلف تأثیر مثبت زیادی بر عملکرد نهایی ندارند یا تأثیر اندکی دارند.

همچنین نویسنده اعلام کرده که رویکردهای اجرا شده برای تشخیص اشیا با تطبیق دامنه از منبع دامنه تولید ماشین به دامنه هدف واقعی دنیا، موثر هستند. تغییرات بسیار ساده در ظاهر تصاویر آموزشی تأثیر زیادی بر عملکرد تشخیص دارند. بهترین نتایج برای هر دو از شبکه های RetinaNet و Faster R-CNN از طریق تطبیق دامنه بر اساس تطبیق آماره های تصاویر منبع و هدف به دست می آید. این روش بدون هیچ تغییر معماری ای انجام می شود و نیازی به هیچ توصیف برای دامنه هدف ندارد. قبل از این، آزمایش های انجام شده به وضوح نشان می دهند که تنها تغییر دامنه، که از طریق عملگرهای اصلاحی ابتدایی داده، می تواند نتایج قابل قبولی را به دست آورد و تفاوت بین دامنه منبع و هدف را به طور قابل توجهی کاهش دهد. این روش بسیار ساده برای تنظیم و آزمایش است و اگر با تکنیک های دیگر ترکیب شود، می تواند به نتایج بهتری منجر شود.

Yuchen Yang در پایان نامه خود [65] در ابتدا چالش تغییر دامنه و به طبع آن کاهش دقت مدل ها را بیان می کند برای کم کردن این کاهش دقت بدون نیاز به برچسب از دامنه هدف، روش های تطبیق دامنه بدون نظارت (UDA) پیشنهاد شده اند.

در مقایسه با بیشتر مطالعات UDA که به تصویربرداری از کلاس ها و تصویربرداری سطح پیکسل (تقسیم تصویر به قطعات کوچک) می پردازند، UDA برای تشخیص اشیا یک حوزه نسبتاً جدید است. یک روند پردازش معروف برای اعمال آموزش مقاوم در برابر دامنه شامل آموزش معکوس با دامنه تمییزدهنده است. دامنه تمییزدهنده توزیع ویژگی های دامنه منبع و دامنه هدف را همگام می کند.

روش های موجود در تشخیص اشیا با تطبیق دامنه ویژگی ها را از سطح تصویر استخراج می کنند و به طور مستقیم آن ها را به عنوان ویژگی های کامل در UDA برای وظایف دسته بندی تطبیق می دهند. با این حال، همگام سازی ویژگی های کامل تصویر به عنوان یک کلیت برای وظیفه تشخیص اشیا مناسب نیست، زیرا وجود پس زمینه های متنوع ممکن است با نتایج تطبیق تداخل داشته باشد. برای جلوگیری از همگام سازی ویژگی های کامل، این پایان نامه یک چارچوب تطبیق دامنه متمرکز بر روی جلوه های اصلی (FFDA) را پیشنهاد می کند. این چارچوب FFDA از توابع ضرر تمیز دهنده های دامنه به منظور تمرکز همگام سازی روی جلوه های اصلی در زمان بازگشت به عقب استفاده می کند. FFDA پیش بینی های هدف و برچسب های تصویر منبع را جمع آوری می کند و از آنها برای تولید ماسک های جستجو استفاده می کند که مناطق جلوه را مشخص می کنند. سپس این ماسک ها را به تمیز دهنده های دامنه سطح تصویر و نمونه اعمال می کند تا فقط در مناطق جستجویی به عقب برگردد. به علاوه، با تقویت این تطبیق متمرکز بر روی جلوه در طول چند لایه مختلف در مدل تشخیص اشیا، FFDA باعث افزایش قابل توجهی در پیش بینی دامنه هدف می شود.

روش FFDA، نسبت به روش های قبلی به بهترین دقت جدید در تطبیق از Cityscape به مجموعه داده Foggy Cityscape می رسد. FFDA نیز نتایج رقابتی را در مجموعه های داده دیگری که شامل سناریوهای مختلفی برای برنامه های رانندگی خودکار هستند، نشان می دهد.

علاوه بر مشکل تشخیص اشیا، این پایان نامه به بررسی کاربرد UDA برای دسته بندی تصویر کلی اسلاید WSI¹ نیز می پردازد. دسته بندی تصویر برای WSI در مقایسه با دسته بندی تصویر عمومی به دلیل دقت بالا و اطلاعات کلیدی پراکنده ای که دارد، یک وظیفه چالش برانگیز است. کارهای قبلی یک لوله کدینگ جدید برای دسته بندی WSI ارائه داده اند. با این حال، این لوله کدینگ همچنان هنگام استفاده از مجموعه داده های WSI متفاوت از یک مؤسسه مختلف برای انجام همان وظیفه از همان پدیده کاهش دقت رنج می برد. این مسئله محدودیت های استفاده عملی از این لوله کدینگ را، به خصوص وقتی تشخیص های WSI سخت به دست آمده اند، ایجاد می کند.


از سوی دیگر، کارهای قبلی که از UDA در تصویربرداری پزشکی استفاده کرده اند، معمولاً بر روی نمونه های کوچک تصویرهای میکروسکوپی یا قطعات تصویر استخراج شده از WSI تمرکز دارند. UDA برای کاربرد در دسته بندی تمام WSI به دلیل محدودیت تعداد لوله کدینگ ها و مجموعه داده هایی که پشتیبانی از دسته بندی WSI را دارند، هنوز بررسی نشده است.

هدف این پایان نامه ارائه یک راه حل UDA برای افزایش مقاومت لوله کدینگ های قبلی با کاهش دقت ناشی از مجموعه داده های مختلف WSI است. این راه حل دسته بند دامنه را در مراحل مختلف میانه ای در لوله کدینگ قبلی درج می کند تا ویژگی ها را در طول آموزش همگام سازد. نتایج نشان

¹ Whole Slide Image

می دهند که با قرار دادن دسته بند دامنه در مراحل مختلف، لوله کدینگ نمایش دقت بالاتری را بر روی داده های WSI هدف نشان می دهد.

روش پیشنهادی در پایان نامه حمیده خادم پیر [66]، توسعه ای از روش ADDA [20] می باشد. در این پایان نامه برای اینکه دقت مدل افزایش پیدا کند و کاستی های روش ADDA جبران شود از روش تطبیق دامنه افزایشی استفاده می شود که در آن به تدریج تعدادی از مطمئن ترین داده های دامنه هدف شناسایی شده و به مجموعه داده های دامنه منبع اضافه میشوند. برای تشخیص مطمئن ترین داده های دامنه هدف از یک شبکه خودرمنگار استفاده می شود. این شبکه بخش رمزگذار خود را از قسم مولد شبکه تمیزدهنده که در مرحله قبل آموزش دیده است می گیرد [66]. در شکل دیاگرام چارچوب کلی مسئله رسم شده است [66].



شکل ۲۹ فلوجارت روشهای پیشنهادی تطبیق دامنه های افزایشی [66]

همانطور که مشاهده میشود دیاگرام از سه قسم اصلی تشکیل شده است. قسمت اول شبکه عصبی پیچشی اس که خود از دو قسم استخراج کننده ویژگی و طبقه بند تشکیل شده است. استخراج کننده ویژگی شامل لایه های پیچشی و max_pooling میباشد که تصاویر را به یک بردار ویژگی نگاشت می دهد. طبقه بند متشکل از لایه تماما متصل است که ویژگیهای استخراج شده را به کلاس هر دامنه

نگاشت میدهد. قسمت دوم که رمزگشا نام دارد یک شبکه پادپیچشی است که ترانهاده شبکه پیچشی می باشد. قسم سوم تمایزدهنده می باشد که به وسیله لایه های تماما متصل وظیفه تشخیص دامنه ورودی را دارد [66].

روش پیشنهادی در پایان نامه نیلوفر شعبانی [67]، متشکل از دو بخش می باشد. در بخش اول روشی که به منظور انجام تطبیق وجه برای داده های چند وجهی طراحی شده است، توضیح داده می شود. سپس در بخش دوم، روش پیشنهادی این پایان نامه به منظور انجام تطبیق دامنه برای داده های چند وجهی معرفی خواهد شد [67].


مدل پیشنهادی نویسنده در بخش اول دارای سه ویژگی عمده می باشد که موجب تمایز آن با سایر روش ها می شود، این سه ویژگی عبارتند از:

۱. روش پیشنهاد شده در این پایان نامه برای تطبیق وجه علاوه بر استخراج اطلاعات معمول وجه های مختلف داده، اطلاعاتی را که در وجه های مختلف داده مکمل یکدیگر هستند را نیز استخراج می کند [67].

۲. در این روش اطلاعات موجود در فضای برجسب نیز در نظر گرفته می شود [67].

۳. روش پیشنهادی در این بخش یک معماری یکپارچه می باشد بدین معنا که تمامی پارامترهای شبکه در یک گام بروزرسانی می شوند. این در حالی است که در سایر روش های انجام تطبیق وجه که براساس یادگیری رقابتی عمل می کنند، در هر گام بخشی از پارامترهای شبکه ثابت نگه داشته می شوند و بقیه پارامترها بروزرسانی می شوند و این فرآیند تا زمانی که مدل همگرا شود ادامه می یابد [67].

مدل پیشنهادی در این بخش تلاش دارد تا با استفاده از ساختار خودکدگذارها، اطلاعات مشترک بین وجه های مختلف داده را استخراج نماید.



شکل ۳۰ مدل ارائه شده برای انجام تطبیق وجه [67]

روش پیشنهادی در بخش اول دارای دو گام مختلف می باشد. در گام اول برای هر وجه داده یک خودکدگذار آموزش داده می شود. در گام دوم برای هر وجه داده یک کدگذار جدید در نظر گرفته می شود. بدین ترتیب شبکه در این گام به ازای هر وجه داده یک زیرشبکه خواهد داشت [67].

بخش دوم شامل سه مرحله می باشد که عبارتند از: مرحله پیش آموزش که خود شامل دو گام مختلف است، مرحله اصلی و مرحله آزمایش. در روش پیشنهادی این بخش از ایده به دست آوردن اطلاعات مشترک بین دو وجه در حین به دست آوردن اطلاعات خاص هر وجه که در بخش اول توضیح داده شد بهره برده شده است [67].

برای سنجش مدل پیشنهادی بخش اول این پایان نامه از مجموعه داده های چند نمایی COIL100 و ALOI100 به منظور انجام طبقه بندی اشیا استفاده شده است [67].

در بخش دوم این پایان نامه نیز از چهار مجموعه داده مختلف به منظور انجام طبقه بندی استفاده شده است که عبارتند از: MNIST, USPS, NYU Depth Dataset V2 و RGB+D DATABASE [67].

۳-۳. معیارهای ارزیابی

در این بخش به مفاهیم اساسی و معیارهای رایج در اندازه گیری عملکرد الگوریتم های تشخیص اشیاء می پردازیم.

ارزیابی الگوریتم یک بخش اساسی از پروژه های یادگیری ماشین است و می تواند با توجه به وظیفه و هدف، به روش های مختلفی انجام شود. تشخیص اشیاء یک وظیفه پیچیده تر از دسته بندی تصاویر

سنتی است زیرا تعداد غیرثابتی از اشیاء ممکن است در یک تصویر وجود داشته باشد و مدل تشخیص باید به دقت کلاس آن ها را همراه با موقعیت آن ها پیش بینی کند. به همین دلیل، باید معیارهای اختصاصی معرفی و تعریف شوند.

۳-۱-۳. معیارهای Precision و recall

برای توضیح این معیار ابتدا باید مفاهیم زیر در زمینه تشخیص اشیاء تعریف شوند:

- مقدار مثبت واقعی (TP): یک bounding box به درستی به یک شیء اختصاص داده می شود که در واقع در تصویر ظاهر شده است.

- مقدار مثبت غلط (FP): تشخیص نادرست، یعنی شیء تشخیص داده می شود که در واقع در bounding box حاضر نیست یا فقط جزئی از آن است.

- مقدار منفی غلط (FN): شیء حاضر در تصویر توسط مدل تشخیص اشیاء تشخیص داده نمی شود. مفهوم منفی واقعی (TN) در زمینه تشخیص اشیاء معنی ندارد، زیرا عدم تشخیص یک شیء غیر حاضر در تصویر مرتبط نیست. در واقع، این به معنای این است که مدل به درستی پس زمینه را به عنوان متعلق به هیچ کلاسی تشخیص داده است.

Precision: این معیار دقت، اندازه گیری می کند که چقدر پیش بینی های مدل دقیق هستند، بنابراین درصد یا کسری از پیش بینی های صحیح را باز می گرداند. به عبارت دیگر، این معیار دقت نشان می دهد که از تمام پیش بینی هایی که مدل انجام داده است، چه تعداد به درستی اشتباه نیافته اند.

این معیار طبق رابطه ی زیر محاسبه می شود:

$$Precision = \frac{TP}{TP + FP}$$

معادله ۲

Recall: این معیار توانایی تشخیص مدل را اندازه گیری می کند، بنابراین درصد یا کسری از اشیاء که به درستی تشخیص داده شده اند را باز می گرداند. به عبارت دیگر، این معیار نشان می دهد که از تمام اشیاء موجود در تصویر، چه تعداد به درستی تشخیص داده شده اند.

این معیار طبق رابطه ی زیر محاسبه می شود:

$$Recall = \frac{TP}{TP + FN}$$

معادله ۳

۲-۳-۲. معیار IoU^1

این معیار برای هر bounding box پیش بینی شده، اشتراک آن را با bounding box واقعی^۲ محاسبه می کند تا یک پیش بینی به عنوان مثبت واقعی یا مثبت غلط ارائه دهد. برای یک جفت bounding box، معیار IoU به صورت زیر محاسبه می شود:

$$IoU = \frac{\text{area of overlap}}{\text{area of union}}$$

معادله ۴

در اینجا، area of overlap بخشی از تصویر است که توسط هر دو bounding box پوشش داده می شود، و area of union کل مساحت هر دو bounding box را اشغال می کند. اگر IoU بالا باشد، به معنای این است که میزان تطابق و دقت بیشتری در تشخیص اشیاء وجود دارد.

۳-۳-۳. معیار mAP

mAP^3 یک معیار ارزیابی است که برای ارزیابی عملکرد سیستم های بازیابی اطلاعات^۴ استفاده می شود. این معیار به طور خاص در مواردی که در جستجوی اطلاعات بازیابی چندگانه (مثلاً در موتورهای جستجو) مورد استفاده قرار می گیرد.

mAP معیاری است که هم دقت و هم بازیابی و امتیازهای اعتماد مرتبط را در نظر می گیرد. برای محاسبه mAP، ابتدا برای هر جستجو، باید لیستی از مجموعه ای از نتایج بازیابی را داشته باشیم، که هر کدام دارای یک مقدار ارزش (مثلاً ثبت شده به عنوان یک برچسب) هستند. سپس با استفاده از این لیست نتایج، $Precision@K$ (دقت در مقدار K) محاسبه می شود، که نسبت تعداد نتایج صحیح به تعداد کل نتایج بازیابی شده در K نتیجه را نشان می دهد.

با محاسبه $Precision@K$ برای تمامی جستجوها، می توان معیار Average Precision (AP) را محاسبه کرد. سپس با محاسبه میانگین AP برای تمام جستجوها، متوسط عملکرد دقیق (MAP) به دست می آید.

¹ Intersection over Union

² ground truth

³ Mean Average Precision

⁴ Information Retrieval

MAP معیاری از کلیت و کیفیت عملکرد یک سیستم بازیابی اطلاعات را نشان می دهد، زیرا سیستم هایی که در جستجوها به خوبی عمل می کنند و نتایج با ارزش بالا را بازیابی می کنند، در این معیار امتیاز بالاتری خواهند داشت.

۳-۴. مجموعه دادگان

۳-۴-۱. مجموعه داده Cityscapes

مجموعه داده Cityscapes مجموعه ای برای بررسی و پژوهش در زمینه تشخیص و تفسیر تصاویر شهری و خودروها در محیط های شهری است. این دیتاست ابتدا توسط دانشگاه Tübingen در آلمان ایجاد شد و با همکاری شرکت ها، دانشگاه ها و موسسات تحقیقاتی دیگر توسعه یافته است. هدف اصلی از ایجاد این دیتاست، تشویق تحقیقات در زمینه تشخیص اشیا، ترافیک، خیابان ها و معماری شهری با استفاده از تصاویر واقعی از محیط های شهری بوده است.

این مجموعه داده دارای تصاویر معنایی و اصلی (۵۰۰۰ برچسب با کیفیت بالا، ۲۰۰۰۰ برچسب بزرگ) از ۵۰ شهر مختلف هستند. هر تصویر در مجموعه داده Cityscapes دارای برچسب های دقیق برای اشیا مختلف موجود در تصویر می باشد. این برچسب ها از جمله دسته بندی اشیا، تشخیص مرزهای اشیا (Segmentation)، تشخیص نقاط مختلف روی اشیا (Keypoints) و سایر اطلاعات مرتبط با تصویر می شوند. این به عنوان یکی از مجموعه داده های معیار در تقسیم بندی معنایی جاده/مناظر شهری عمل می کند و شامل تصاویر با وضوح بالا (۱۰۸۰p) از محیط های شهری مختلف است که از نقاط مختلف شهرهای مختلف جمع آوری شده اند. علاوه بر تصاویر محیط شهری، این مجموعه داده شامل تصاویر از خودروها با زوایای مختلف و در شرایط مختلف ترافیکی نیز می شود و دارای تنوع محیطی بالایی است.

از دیگر کاربردهای این مجموعه داده می توان به توسعه الگوریتم ها و مدل های هوش مصنوعی برای خودکارسازی خودروها، ارزیابی ایمنی خودروها، پژوهش های مرتبط با شهرهوشمند و بهینه سازی ترافیک اشاره کرد. به دلیل حجم بالای داده ها و پیچیدگی تسک های مرتبط، این دیتاست به عنوان یک چالش مهم برای پژوهش های مختلف در زمینه بینایی ماشین و یادگیری عمیق مطرح است.



شکل ۳۱ چند نمونه از تصاویر مختلف مجموعه داده Cityscapes

۳-۴-۲. مجموعه داده Foggy Cityscapes

مجموعه داده "Foggy Cityscapes" یک مجموعه داده تصویری است که برای آموزش و ارزیابی مدل های یادگیری عمیق مخصوصاً در زمینه بینایی ماشین، تقسیم بندی معنایی و تشخیص اشیا در شرایط آب و هوای مه آلود و غبار آلود توسعه داده شده است. ویژگی اصلی این مجموعه داده، حضور مه و غبار در تصاویر است که می تواند برای مدل های یادگیری عمیق به چالشی تبدیل شود. مه و غبار معمولاً باعث کاهش وضوح و کیفیت تصاویر می شوند و تشخیص اشیا و ویژگی های تصویری به طور

معمول دشوارتر می شود. این مجموعه داده شامل تصاویری از صحنه های شهری در شرایط آب و هوای مه و غبارآلود است.

از این مجموعه داده می توان برای آموزش مدل های یادگیری عمیق مانند شبکه های عصبی کانولوشنی برای تقسیم بندی معنایی، تشخیص اشیاء، تشخیص ترافیک، تشخیص افراد و سایر وظایف بینایی ماشین استفاده کرد. این مجموعه داده معمولاً به همراه برچسب هایی مشخص برای اشیاء مختلف ارائه می شود که به مدل ها کمک می کند تا اشیاء را در تصاویر شناسایی کنند.



شکل ۳۲ مجموعه داده Cityscapes (سمت چپ) در مقابل Foggy Cityscapes (سمت راست)


۳-۴-۳. مجموعه داده COCO

مجموعه داده ی COCO یکی از مجموعه های داده معروف و گسترده در زمینه تشخیص اشیاء و تفسیر صحنه در تصاویر است. نام "COCO" مخفف "Common Objects in Context" می باشد، به این معنا که در این مجموعه داده، اشیاء مختلف در متناوب و با توجه به مفهوم کلی تصویر قرار دارند. این مجموعه داده در سال ۲۰۱۴ توسط محققانی از دانشگاه استنفورد ایجاد شد و به منظور ترویج تحقیقات در زمینه تشخیص اشیاء، دسته بندی، تفسیر صحنه و وظایف مشابه دیگر در حوزه بینایی ماشین و یادگیری عمیق ساخته شد.

مجموعه COCO شامل بیش از ۳۳۰ هزار تصویر با بیش از ۱.۵ میلیون جفت تصویر و برچسب می باشد. این تصاویر به اشیاء مختلف در محیط های مختلف اشاره دارند و دارای تنوعی از شرایط

نورپردازی، پس زمینه، مقیاس و انواع اشیاء هستند. همچنین، این مجموعه داده دارای ۸۰ دسته اشیاء مختلف است که از جمله آنها می توان به اشیاء روزمره مانند خودروها، حیوانات، میوه ها، ابزارها، مبلمان و غیره اشاره کرد.

از این مجموعه داده به عنوان یک چالش معتبر برای ارزیابی الگوریتم ها و مدل های مختلف در حوزه تشخیص اشیاء و تفسیر صحنه استفاده می شود. این مجموعه داده باعث توسعه و پیشرفت در زمینه هایی مانند شناخت تصویری، یادگیری عمیق، شبکه های عصبی کانولوشنی (CNN) و ترکیب تشخیص اشیاء با درک صحنه شده است.



شکل ۳۳ چند نمونه از تصاویر مختلف مجموعه داده COCO

۳-۴-۴. مجموعه داده Caltech

مجموعه داده Caltech 101 یک مجموعه داده معروف در زمینه تشخیص اشیاء در تصاویر است. این مجموعه داده به منظور توسعه و ارزیابی الگوریتم ها و مدل های تشخیص اشیاء در حوزه بینایی ماشین و یادگیری عمیق ایجاد شده است. نام "Caltech 101" اشاره دارد به دانشگاه کالیفرنیا جنوبی (Caltech) که این مجموعه داده از آنجا نامگذاری شده است و "۱۰۱" به تعداد دسته های مختلف اشیاء در این مجموعه داده اشاره دارد.

مجموعه داده Caltech 101 دارای ۱۰۱ دسته اشیا مختلف می باشد. این دسته ها شامل اشیا مختلفی مانند حیوانات، وسایل نقلیه، اشیا روزمره و غیره هستند. همچنین شامل تقریباً ۹,۰۰۰ تصویر از اشیا مختلف در تنوعی از شرایط نورپردازی، زوایا و پس زمینه ها است.

مجموعه داده Caltech 101 به عنوان یک مجموعه داده معتبر و استاندارد در زمینه تشخیص اشیا و یادگیری عمیق مورد استفاده قرار می گیرد. این مجموعه داده از ابزارهای معتبر برای ارزیابی عملکرد مدل ها و الگوریتم های جدید در زمینه تشخیص اشیا بهره می برد.




شکل ۳۴ چند نمونه از تصاویر مختلف مجموعه داده Caltech

۳-۴-۵. مجموعه داده SYNTHIA

مجموعه داده SYNTHIA یک دیتاست مصنوعی است که برای تحقیقات در زمینه بینایی ماشین، یادگیری عمیق و واقع گرایی مصنوعی ایجاد شده است. این دیتاست به منظور ارائه یک محیط تستی و شبیه سازی واقعی برای تجزیه و تحلیل الگوریتم ها و مدل های یادگیری ماشینی در شرایط مختلف تصاویر شهری و خودروها تولید شده است. این مجموعه دارای ۹۴۰۰ تصویر شهر مجازی در ۱۳ کلاس و شامل تصاویری با نور مصنوعی در شرایط روز و شب است. همچنین دارای تنوع محیطی خوب و میزان شباهت نسبتاً بالا به تصاویر واقعی است. این ویژگی امکان آزمایش الگوریتم ها و مدل ها در شرایط مختلف نوردهی را به ارمغان می آورد.

دیتاست SYNTHIA به عنوان یک ابزار تستی برای تحقیقات در زمینه بینایی ماشینی، تشخیص اشیاء و خودروها، ترافیک شهری و سایر حوزه های مرتبط با تصاویر شهری و محیط های خارجی بسیار مناسب است.



شکل ۳۵ چند نمونه از تصاویر مختلف مجموعه داده SYNTHIA

۳-۴-۶. مجموعه داده KITTI

مجموعه داده KITTI یکی از مجموعه های داده معروف در زمینه بینایی ماشین و پردازش تصویر برای وظایف مختلفی از جمله شناسایی اشیاء، تخمین عمق، رهگیری اشیاء و غیره است. این مجموعه داده به ویژه برای تحقیقات مربوط به خودروهای هوش مصنوعی و خودروهای خودران مناسب است.¹ KITTI یک پروژه تحقیقاتی است که در دانشگاه کارلسروهه و دانشگاه مونیخ در آلمان انجام شده است.

این پلتفرم برای تعیین و ارزیابی الگوریتم ها و مدل های مرتبط با بینایی ماشین در شرایط واقعی و چالش آور استفاده می شود. وظایف مورد علاقه در این پلتفرم شامل تخمین عمق از تصاویر استریو، جریان نوری^۲، تعیین حرکت دوربین^۳، تشخیص اشیاء سه بعدی و پیگیری اشیاء سه بعدی می باشند.

این مجموعه داده شامل ساعت ها فیلم از سناریوهای ترافیکی است که با استفاده از حسگرهای با کیفیت بالا متنوعی مانند حسگرهای RGB، تصویر سیاه و سفید و حسگرهای عمق ضبط شده اند. مجموعه داده تشخیص اشیاء KITTI شامل ۷,۴۸۱ تصویر آموزشی و ۷,۵۱۸ تصویر آزمون می شود که به مجموع ۸۰,۲۵۶ شیء با برچسب تعلق دارند. این اشیاء به ۸ دسته مختلف تقسیم شده اند که عبارتند از: خودرو، ون، کامیون، عابر پیاده، شخص نشسته، دوچرخه سوار، تراموا و سایر.

مجموعه داده KITTI شامل چندین زیرمجموعه داده مختلف است، از جمله:

Stereo 2012: برای تخمین عمق از تصاویر استریو.

¹ KITTI Vision Benchmark Suite

² optical flow

³ visual odometry

Vision Odometry: برای تخمین حرکت دوربین.

Object Detection: برای تشخیص و پیگیری اشیاء مانند خودروها و افراد.

Semantic Segmentation: برای تشخیص اجزاء مختلف محیط از جمله جاده، خودروها و درختها.

Road Detection: برای تشخیص و تعیین مسیر جاده.




شکل ۳۶ چند نمونه از تصاویر مجموعه داده KITTI

۳-۴-۷. مجموعه داده Pascal VOC

مجموعه داده Pascal VOC یک مجموعه داده واقعی است که شامل اشیاء عمومی است. این مجموعه داده برای وظایف متنوعی مانند دسته‌بندی به مقیاس بزرگ، تشخیص اشیاء و تقسیم‌بندی معرفی شده است. مجموعه تصاویر Pascal VOC در بازه زمانی بین سال ۲۰۰۵ تا ۲۰۱۲ چندین بار به روزرسانی شده است.

در این مجموعه داده، نسخه‌های محبوب‌تر ۲۰۰۷ و ۲۰۱۲ تصاویر با تقسیم‌بندی آموزش و اعتبارسنجی وجود دارند که در مجموع شامل ۱۵,۰۰۰ تصویر هستند. تصاویر موجود در این مجموعه داده بیش از ۲۰ دسته از اشیاء عمومی را شامل می‌شوند که عبارتند از: هواپیما، دوچرخه، پرده، قایق، بطری، اتوبوس، خودرو، گربه، صندلی، گاو، میز، سگ، اسب، دوچرخه‌سوار، شخص، گیاه، گوسفند، مبل، قطار و تلویزیون.

این مجموعه داده از اهمیت بسیاری در زمینه تحقیقات بینایی ماشین برخوردار بوده و برای ارزیابی و توسعه الگوریتم ها و مدل های مختلف در وظایف مختلف مانند تشخیص اشیاء و تقسیم بندی تصاویر به کار می رود.




شکل ۳۷ چند نمونه از تصاویر مختلف مجموعه داده Pascal VOC 2007

۳-۴-۸. مجموعه داده SIM10K

مجموعه داده SIM10K از یک موتور شبیه سازی (GTA¹) برای تولید مجموعه داده SIM10K استفاده کردند، که شامل ۱۰۰۰۰ تصویر واقع گرایانه از ماشین ها در محیط های شهری مختلف است. ایجاد شده است.

این مجموعه داده شامل حاشیه نویسی ها برای وظایف تشخیص اشیاء و تقسیم بندی معنایی است، که آن را مناسب برای آموزش شبکه های یادگیری عمیق می سازد. نویسندگان [68] عملکرد شبکه های آموزش دیده بر روی مجموعه داده SIM10K را با شبکه های آموزش دیده بر روی مجموعه داده های واقعی مقایسه کردند، مانند Cityscapes، و یافتند که داده های شبیه سازی شده در تمام سطوح پیچیدگی از داده های واقعی بهتر عمل کردند. نویسندگان پیشنهاد می دهند که این رویکرد می تواند برای به سرعت افزایش اندازه مجموعه داده های آموزشی مفید از طریق شبیه سازی و تأیید آن که مجموعه داده های بزرگ کافی است برای یادگیری مدل های عمومی مورد استفاده قرار گیرد.



شکل ۳۸ چند نمونه از تصاویر مختلف مجموعه داده SIM10K

۳-۴-۹. مجموعه داده BDD100K

این مجموعه داده در حال حاضر بزرگترین مجموعه برای هوش مصنوعی خودران^۲ به شمار می آید. مجموعه مذکور حاوی بیش از 100000 ویدئوی 1100 ساعت تجربه رانندگی در زمان های گوناگون روز


¹ Grand Theft Auto

² self-driving AI

و شرایطهای مختلف آبوهوایی است. تصاویر این مجموعه داده دارای توضیحات و متعلق به نواحی نیویورک و سان فرانسیسکو هستند.

مجموعه داده BDD100K برای تسهیل مطالعات الگوریتمی بر روی داده های تصویری بزرگ و متنوع و چندین وظیفه طراحی شده است. این مجموعه داده شامل وظایف متنوعی مانند تشخیص اشیاء، تقسیم بندی نمونه، تقسیم بندی معنایی، تشخیص خطوط، تقسیم بندی مناطق رانندگی و موارد دیگر می شود. این مجموعه داده برای آموزش مدل هایی که می توانند ترکیبی از وظایف ادراکی با پیچیدگی های مختلف انجام دهند، مناسب است، به جای انجام تنها وظایف یکسان با ساختار پیش بینی یکسان.

این مجموعه داده بزرگ تر و متنوع تر از مجموعه های داده موجود برای رانندگی خودکار است و دارای حاشیه نویسی های غنی و توزیع جغرافیایی متنوعی است. همچنین، این مجموعه داده یک مجموعه داده MOTs را ارائه می دهد که بزرگ تر از مجموعه داده های KITTI و MOTs Challenge است و تعداد حاشیه نویسی های آن با مجموعه داده YouTube VOS بزرگ مقایسه می شود. به طور کلی، مجموعه داده BDD100K درهای تحقیقات آینده در این حوزه مهم را باز می کند و منبع ارزشمندی برای پژوهشگران و توسعه دهندگانی است که در برنامه های رانندگی خودکار کار می کنند.



شکل ۳۹ چند نمونه از تصاویر مختلف مجموعه داده BDD100K


۳-۴-۱۰. مجموعه داده YTBB

YTBB¹ مجموعه ای از آدرس های ویدئو با برچسب های جعبه های محدودکننده برای اشیاء با فراوانی داده های بزرگ می باشد. این مجموعه داده حاوی تقریباً ۳۸۰,۰۰۰ قطعه ویدئویی به طول حدود ۱۹ ثانیه است که به صورت خودکار انتخاب شده اند تا اشیاء را در محیط های طبیعی بدون ویرایش یا پردازش پس از تولید نمایش دهند. کیفیت ضبط این ویدئوها اغلب شبیه به کیفیت دوربین موبایلی

¹ YouTube BoundingBoxes

دستی است. اشیاء در این ویدئوها یک زیرمجموعه از مجموعه برچسب‌های MS COCO را نمایش می‌دهند. تمام قطعات ویدئو با برچسب‌های دقیق با دقت بالا و جعبه‌های محدودکننده در هر فریم در ثانیه واحد توسط انسان توسط توسعه‌دهندگان دیتا آناتومی شده‌اند. که برای مسائل تشخیص اشیاء در ویدئوهای YouTube توسعه داده شده است. این مجموعه داده به منظور تعلیم ماشین و توسعه الگوریتم‌های هوش مصنوعی کاربرد دارد.

مجموعه داده YTBB یکی از مجموعه‌های داده مهم برای تحقیقات در حوزه بینایی ماشین و پردازش تصویر است و محققان و توسعه‌دهندگان از آن برای آموزش و ارزیابی مدل‌های مختلف استفاده می‌کنند. این مجموعه داده به توسعه اپلیکیشن‌های تشخیص در ویدئوها و افزایش امکانات تحلیل ویدئویی نیز کمک می‌کند.



شکل ۴۰ چند نمونه از تصاویر مختلف مجموعه داده YTBB

۵-۳. نتایج

در بخش ۲.۴ به موارد و روش های بیشتری در زمینه های مختلف تطبیق دامنه پرداخته شده است. در جدول ۱ نتایج تجربی مقاله هایی که در بخش ۱.۲.۴ بر روی روش های تطبیق دامنه برای کاربرد تشخیص اشیا کار کرده اند، آورده شده است.

شماره	روش	Labeled target	Basic detector	مجموعه داده	دقت (mAP)
1	Khodabandeh و همکارانش [41]	Unsupervised	Faster RCNN	SIM10k → Cityscapes Cityscapes → Foggy ¹ Cityscapes → KITTI KITTI → Cityscapes	car AP: 42.6, oracle: 68.1 mAP: 36.5, oracle: 43.5 car AP: 77.6, oracle: 90.1 car AP: 43.0, oracle: 68.1
2	Cai و همکارانش [42]	Unsupervised	Faster RCNN	SIM10k → Cityscapes Cityscapes → Foggy Synthetic → COCO Synthetic → YTBB	car AP: 46.6 mAP: 35.1 mAP: 20.7 mAP: 22.8
3	K. Saito و همکارانش [43]	Unsupervised	Faster RCNN	SIM 10k → Cityscapes Cityscapes → Foggy PASCAL → Clipart PASCAL → Watercolor	car AP: 47.7 34.3 38.1 53.3
4	Zhenwei He و همکارانش [44]	Unsupervised	Faster RCNN	SIM 10k → Cityscapes Cityscapes → Foggy KITTI → Cityscapes Cityscapes → KITTI	car AP: 41.1 34.0 car AP: 41.0 car AP: 72.1
5	Yuhua Chen و همکارانش [45]	Unsupervised	Faster RCNN	Cityscapes → Foggy Cityscapes → KITTI KITTI → Cityscapes	27.6 64.1 38.5
6	Lukas Hoyer و همکارانش [46]	Unsupervised	Faster RCNN	Cityscapes → Foggy	47.6
7	Giulio Mattolin و همکارانش [47]	Unsupervised	YOLOv5	Sim10K → Cityscapes KITTI → Cityscapes Cityscapes → Foggy	56.3 52.2 40.8
8	Arruda و همکارانش [51]	Unsupervised	Faster RCNN	BDD100k (day) → night	41.9/67.0

¹ Foggy Cityscapes

9	Jiaxi Wu و همکارانش [52]	Unsupervised	Faster RCNN	Cityscapes + KITTI BDD100K day + night Cityscapes + MS COCO + Synscapes	58.4 39.8 37.1
10	Han-Kai Hsu و همکارانش [53]	Unsupervised	Faster RCNN	KITTI → Cityscapes Cityscapes → Foggy Cityscapes → BDD100k	car AP: 43.9, oracle: 55.8 36.9, oracle: 39.2 24.3, oracle: 43.3
11	T. Kim و همکارانش [54]	Unsupervised	Faster RCNN	PASCAL → Clipart1k PASCAL → Watercolor2k PASCAL → Comic2k Cityscapes → Foggy	41.8 52.0 34.5 34.6
12	Yue و همکارانش [60]	Unsupervised	Faster RCNN Yolov5 X	Cityscapes → Foggy(Yolov5 X) Sim10K → Cityscapes KITTI → Cityscapes ViPeD → COCO (Yolov5 X)	44.3 64.5 64.1 47.4

جدول ۱ نتایج عملی تطبیق دامنه برای تشخیص اشیا در مقالات متناظر

فصل ۴: نتیجه‌گیری و پیشنهادها

۴-۱. نتیجه‌گیری

تحقیق حاضر به بررسی و مقایسه روش‌های مختلف تطبیق دامنه در شبکه‌های عصبی عمیق برای کاربرد تشخیص اشیا در هنگام استفاده از داده‌های آموزشی مصنوعی پرداخت. در این تحقیق، ابتدا دسته‌بندی کلی از روش‌های تطبیق دامنه ارائه شد و دسته‌های مختلفی مانند روش‌های مبتنی بر اختلاف، روش‌های خصمانه، تطابق چند دامنه، روش‌های ترکیبی، تطبیق دامنه چند حالتی و روش‌های نوظهور معرفی شدند. سپس، هر یک از دسته‌های مذکور با جزئیات بیشتر مورد بررسی قرار گرفت و مقالاتی که برای تطبیق دامنه در کاربرد تشخیص اشیا مورد استفاده قرار گرفته بودند، در دسته‌های متناظر با موضوعاتشان قرار گرفتند و نقدهایی درباره نقاط قوت و ضعف هر روش ارائه شد.

در ادامه، مجموعه داده‌هایی که در این مقالات برای آموزش و ارزیابی استفاده شدند، توضیح داده شدند. این مجموعه‌های داده از اهمیت بسیاری برخوردار هستند زیرا کیفیت و تنوع داده‌ها می‌تواند تأثیر مستقیمی بر عملکرد تطبیق دامنه داشته باشد.

در نهایت، با تجمیع نتایج مقالات مورد بررسی و مقایسه درصدهای دقت به دست آمده در هر یک از روش‌ها، مشخص شد که کدام روش‌ها در کاربرد تشخیص اشیا با استفاده از داده‌های آموزشی مصنوعی بهترین عملکرد را داشته‌اند. این نتایج می‌توانند به پژوهشگران و متخصصان در حوزه شبکه‌های عصبی عمیق کمک کنند تا روش‌های بهتری برای تطبیق دامنه در این کاربرد توسعه دهند و عملکرد سیستم‌های تشخیص اشیا را بهبود ببخشند.

در مجموع، تحقیق حاضر نشان می‌دهد که تطبیق دامنه در شبکه‌های عصبی عمیق با استفاده از روش‌های مناسب می‌تواند کارایی و دقت سیستم‌های تشخیص اشیا را افزایش دهد و بهبود بخشد. این تحقیق به عنوان یک منبع مفید برای پژوهش‌های آتی در این حوزه مطالعه و مورد استفاده قرار گیرد.

۲-۴. پیشنهاد کارهای آینده

با توجه به مطالعات انجام شده و روش‌های بررسی شده در راستای آن‌ها، قصد داریم تا در آینده حداقل با یکی از چند رویکرد زیر پیش برویم :

۱- تبدیل و آزمایش بر روی کارهایی که در موضوع تطبیق دامنه انجام شده اند اما برای کاربرد تشخیص اشیا نبوده اند؛ مخصوصاً در بخش کارهای نوین که در این تحقیق تنها به برخی از آن‌ها اشاره شد میتوان آزمایش‌های متعددی را بر روی این روش‌ها انجام داد تا به نتایج بهتری دست یافت.

یکی از روش‌هایی که میتوان به آن اشاره کرد، استفاده از Batch Normalization برای تطبیق دامنه است. این روش برای کار طبقه بندی در مقاله [69] استفاده شده است، و قصد داریم تا با آزمایش‌های متخلف روی تشخیص دهنده های مختلفی مثل YOLO, Faster RCNN و غیره، از این روش برای کار تشخیص اشیا استفاده کنیم.

۲- بهبود نتایج برخی از کارهای انجام شده در زمینه تطبیق دامنه برای تشخیص اشیا

۳- بررسی تاثیر دامنه میانی در عملکرد مدل و نحوه چگونگی تولید آن

در کارهای تطبیق دامنه اصولاً دو بخش اساسی یک مرحله ای و چند مرحله ای وجود دارد: روش یک مرحله‌ای: در این روش، تطبیق دامنه به صورت مستقیم و در یک مرحله صورت می‌گیرد. به عبارت دیگر، برای انتقال دانش از یک دامنه مبدأ به یک دامنه هدف، از یک مدل یادگیری ماشینی به صورت مستقیم استفاده می‌شود. بدین ترتیب، داده‌های دامنه مبدأ و دامنه هدف در یک مستقل سازی تصادفی آورده می‌شوند و مدل عملکرد خود را بهبود می‌بخشد.

روش چند مرحله‌ای: در این روش، تطبیق دامنه از طریق مراحل متعدد صورت می‌گیرد. در اینجا، تلاش برای کاهش تفاوت بین دامنه مبدأ و دامنه هدف در بین مراحل اصلی روش وجود دارد تا به تدریج دانش به دامنه هدف منتقل شود. یک روش رایج در این رویکرد، استفاده از یادگیری نیمه نظارتی است که علاوه بر داده‌های برچسب دار از دامنه مبدأ، از داده‌های بدون برچسب از دامنه هدف نیز استفاده می‌کند. در مراحل متعدد، مدل با استفاده از داده‌های دامنه هدف خود را بهبود می‌بخشد و تطبیق دامنه پیشرفت می‌کند.

در روش های چند مرحله ای برای تطبیق دامنه، دامنه میانی^۱ نقش بسیار مهم دارد. این دامنه میانی در مراحل مختلف تطبیق دامنه به عنوان یک مرحله واسطه عمل می کند تا اطلاعات از دامنه مبدا به دامنه هدف منتقل شوند.

در مرحله اول، یادگیری از داده های دامنه مبدا صورت می گیرد و یک مدل مبتنی بر داده های دامنه مبدا آموزش داده می شود. این مدل تلاش می کند ویژگی های مهم و تطبیق پذیری از دامنه مبدا را یاد بگیرد. سپس در مرحله بعد، از مدلی که در مرحله اول آموزش داده شده استفاده می شود تا ویژگی های مهمی که از دامنه مبدا یاد گرفته است را به دامنه میانی انتقال دهد. این انتقال ویژگی ها می تواند از روش های مختلفی مانند تبدیل های مخصوص یا شبکه های تبدیل دامنه استفاده کند. و در مرحله آخر، ویژگی های تطبیق داده شده از دامنه میانی به دامنه هدف انتقال داده می شوند تا مدل بتواند بر روی داده های دامنه هدف عملکرد خوبی داشته باشد. این مرحله نیز ممکن است با استفاده از تبدیل های یا شبکه های تبدیل دامنه انجام شود.

¹ Intermediate Domain

مراجع

- [1] 'Unsupervised domain adaptation for object detection and whole slide image classification.pdf'.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, 'Deep Residual Learning for Image Recognition'. arXiv, Dec. 10, 2015. Accessed: Sep. 16, 2023. [Online]. Available: <http://arxiv.org/abs/1512.03385>
- [3] K. He, X. Zhang, S. Ren, and J. Sun, 'Identity Mappings in Deep Residual Networks'. arXiv, Jul. 25, 2016. Accessed: Sep. 16, 2023. [Online]. Available: <http://arxiv.org/abs/1603.05027>
- [4] P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus, and Y. LeCun, 'OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks'. arXiv, Feb. 23, 2014. Accessed: Sep. 16, 2023. [Online]. Available: <http://arxiv.org/abs/1312.6229>
- [5] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, 'You Only Look Once: Unified, Real-Time Object Detection', in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA: IEEE, Jun. 2016, pp. 779–788. doi: 10.1109/CVPR.2016.91.
- [6] W. Liu *et al.*, 'SSD: Single Shot MultiBox Detector', 2016, pp. 21–37. doi: 10.1007/978-3-319-46448-0_2.
- [7] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, 'Feature Pyramid Networks for Object Detection'. arXiv, Apr. 19, 2017. Accessed: Sep. 17, 2023. [Online]. Available: <http://arxiv.org/abs/1612.03144>
- [8] R. Girshick, J. Donahue, T. Darrell, and J. Malik, 'Rich feature hierarchies for accurate object detection and semantic segmentation'. arXiv, Oct. 22, 2014. Accessed: Sep. 17, 2023. [Online]. Available: <http://arxiv.org/abs/1311.2524>
- [9] R. Girshick, 'Fast R-CNN'. arXiv, Sep. 27, 2015. Accessed: Sep. 17, 2023. [Online]. Available: <http://arxiv.org/abs/1504.08083>
- [10] S. Ren, K. He, R. Girshick, and J. Sun, 'Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks'. arXiv, Jan. 06, 2016. Accessed: Sep. 17, 2023. [Online]. Available: <http://arxiv.org/abs/1506.01497>
- [11] 'Domain_Adaptation_Challenges_Methods_Datasets_and_Applications.pdf'.
- [12] M. Wang and W. Deng, 'Deep Visual Domain Adaptation: A Survey', *Neurocomputing*, vol. 312, pp. 135–153, Oct. 2018, doi: 10.1016/j.neucom.2018.05.083.
- [13] A. de Mathelin, F. Deheeger, M. Mougeot, and N. Vayatis, 'Discrepancy-Based Active Learning for Domain Adaptation'. arXiv, Sep. 14, 2022. Accessed: Aug. 30, 2023. [Online]. Available: <http://arxiv.org/abs/2103.03757>
- [14] P. Singhal, R. Walambe, S. Ramanna, and K. Kotecha, 'Domain Adaptation: Challenges, Methods, Datasets, and Applications', *IEEE Access*, vol. 11, pp. 6973–7020, 2023, doi: 10.1109/ACCESS.2023.3237025.

- [15] ‘Deep Domain Confusion و Maximizing for Domain Invariance.pdf’.
- [16] K. M. Borgwardt, A. Gretton, M. J. Rasch, H.-P. Kriegel, B. Schölkopf, and A. J. Smola, ‘Integrating structured biological data by Kernel Maximum Mean Discrepancy’, *Bioinformatics*, vol. 22, no. 14, pp. e49–e57, Jul. 2006, doi: 10.1093/bioinformatics/btl242.
- [17] A. R. Kashyap, D. Hazarika, M.-Y. Kan, and R. Zimmermann, ‘Domain Divergences: a Survey and Empirical Analysis’. arXiv, Apr. 19, 2021. Accessed: Aug. 30, 2023. [Online]. Available: <http://arxiv.org/abs/2010.12198>
- [18] Y. Pan, T. Yao, Y. Li, Y. Wang, C.-W. Ngo, and T. Mei, ‘Transferrable Prototypical Networks for Unsupervised Domain Adaptation’. arXiv, Apr. 25, 2019. Accessed: Aug. 29, 2023. [Online]. Available: <http://arxiv.org/abs/1904.11227>
- [19] I. J. Goodfellow *et al.*, ‘Generative Adversarial Networks’. arXiv, Jun. 10, 2014. Accessed: Aug. 31, 2023. [Online]. Available: <http://arxiv.org/abs/1406.2661>
- [20] E. Tzeng, J. Hoffman, K. Saenko, and T. Darrell, ‘Adversarial Discriminative Domain Adaptation’. arXiv, Feb. 17, 2017. Accessed: Aug. 31, 2023. [Online]. Available: <http://arxiv.org/abs/1702.05464>
- [21] J. Hoffman, D. Wang, F. Yu, and T. Darrell, ‘FCNs in the Wild: Pixel-level Adversarial and Constraint-based Adaptation’. arXiv, Dec. 08, 2016. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/1612.02649>
- [22] H. Huang, Q. Huang, and P. Krähenbühl, ‘Domain Transfer Through Deep Activation Matching’, in *Computer Vision – ECCV 2018*, V. Ferrari, M. Hebert, C. Sminchisescu, and Y. Weiss, Eds., in Lecture Notes in Computer Science, vol. 11220. Cham: Springer International Publishing, 2018, pp. 611–626. doi: 10.1007/978-3-030-01270-0_36.
- [23] M. Long, Z. Cao, J. Wang, and M. I. Jordan, ‘Conditional Adversarial Domain Adaptation’. arXiv, Dec. 29, 2018. Accessed: Sep. 03, 2023. [Online]. Available: <http://arxiv.org/abs/1705.10667>
- [24] J. Shen, Y. Qu, W. Zhang, and Y. Yu, ‘Wasserstein Distance Guided Representation Learning for Domain Adaptation’. arXiv, Mar. 09, 2018. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/1707.01217>
- [25] M. Arjovsky, S. Chintala, and L. Bottou, ‘Wasserstein GAN’. arXiv, Dec. 06, 2017. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/1701.07875>
- [26] Y. Du, Z. Tan, Q. Chen, X. Zhang, Y. Yao, and C. Wang, ‘Dual Adversarial Domain Adaptation’. arXiv, Jan. 01, 2020. Accessed: Sep. 03, 2023. [Online]. Available: <http://arxiv.org/abs/2001.00153>
- [27] H. Rangwani, S. K. Aithal, M. Mishra, A. Jain, and R. V. Babu, ‘A Closer Look at Smoothness in Domain Adversarial Training’. arXiv, Jun. 16, 2022. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/2206.08213>
- [28] G. Shi *et al.*, ‘Genre Separation Network with Adversarial Training for Cross-genre Relation Extraction’, in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, Brussels, Belgium: Association for Computational Linguistics, 2018, pp. 1018–1023. doi: 10.18653/v1/D18-1125.

- [29] K. Bousmalis, G. Trigeorgis, N. Silberman, D. Krishnan, and D. Erhan, 'Domain Separation Networks'. arXiv, Aug. 21, 2016. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/1608.06019>
- [30] S. Sun, H. Shi, and Y. Wu, 'A survey of multi-source domain adaptation', *Inf. Fusion*, vol. 24, pp. 84–92, Jul. 2015, doi: 10.1016/j.inffus.2014.12.003.
- [31] S. Zhao, B. Li, C. Reed, P. Xu, and K. Keutzer, 'Multi-source Domain Adaptation in the Deep Learning Era: A Systematic Survey'. arXiv, Feb. 26, 2020. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/2002.12169>
- [32] S. Zhao *et al.*, 'Multi-source Domain Adaptation for Semantic Segmentation'. arXiv, Oct. 27, 2019. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/1910.12181>
- [33] B. Gholami, P. Sahu, O. Rudovic, K. Bousmalis, and V. Pavlovic, 'Unsupervised Multi-Target Domain Adaptation: An Information Theoretic Approach'. arXiv, Oct. 26, 2018. Accessed: Sep. 02, 2023. [Online]. Available: <http://arxiv.org/abs/1810.11547>
- [34] T. Isobe *et al.*, 'Multi-Target Domain Adaptation with Collaborative Consistency Learning'. arXiv, Jun. 07, 2021. Accessed: Sep. 02, 2023. [Online]. Available: <http://arxiv.org/abs/2106.03418>
- [35] L. T. Nguyen-Meidine, A. Belal, M. Kiran, J. Dolz, L.-A. Blais-Morin, and E. Granger, 'Unsupervised Multi-Target Domain Adaptation Through Knowledge Distillation'. arXiv, Nov. 19, 2020. Accessed: Sep. 02, 2023. [Online]. Available: <http://arxiv.org/abs/2007.07077>
- [36] F. Qi, X. Yang, and C. Xu, 'A Unified Framework for Multimodal Domain Adaptation', *Proc. 26th ACM Int. Conf. Multimed.*, 2018, [Online]. Available: <https://api.semanticscholar.org/CorpusID:53034461>
- [37] X. Shu, G.-J. Qi, J. Tang, and J. Wang, 'Weakly-Shared Deep Transfer Networks for Heterogeneous-Domain Knowledge Propagation', Oct. 2015, pp. 35–44. doi: 10.1145/2733373.2806216.
- [38] Z. Ding, M. Shao, and Y. Fu, 'Missing Modality Transfer Learning via Latent Low-Rank Constraint', *IEEE Trans. Image Process.*, vol. 24, no. 11, pp. 4322–4334, 2015, doi: 10.1109/TIP.2015.2462023.
- [39] K.-C. Peng, Z. Wu, and J. Ernst, 'Zero-Shot Deep Domain Adaptation'. arXiv, Jul. 24, 2018. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/1707.01922>
- [40] E. Kodirov, T. Xiang, Z. Fu, and S. Gong, 'Unsupervised Domain Adaptation for Zero-Shot Learning', in *2015 IEEE International Conference on Computer Vision (ICCV)*, Santiago, Chile: IEEE, Dec. 2015, pp. 2452–2460. doi: 10.1109/ICCV.2015.282.
- [41] 'A Robust Learning Approach to Domain Adaptive Object Detection.pdf'.
- [42] Q. Cai, Y. Pan, C.-W. Ngo, X. Tian, L. Duan, and T. Yao, 'Exploring Object Relation in Mean Teacher for Cross-Domain Detection'. arXiv, Dec. 25, 2019. Accessed: Aug. 29, 2023. [Online]. Available: <http://arxiv.org/abs/1904.11245>

- [43] K. Saito, Y. Ushiku, T. Harada, and K. Saenko, 'Strong-Weak Distribution Alignment for Adaptive Object Detection'. arXiv, Apr. 05, 2019. Accessed: Sep. 05, 2023. [Online]. Available: <http://arxiv.org/abs/1812.04798>
- [44] Z. He and L. Zhang, 'Multi-adversarial Faster-RCNN for Unrestricted Object Detection'. arXiv, Sep. 06, 2019. Accessed: Sep. 05, 2023. [Online]. Available: <http://arxiv.org/abs/1907.10343>
- [45] Y. Chen, W. Li, C. Sakaridis, D. Dai, and L. Van Gool, 'Domain Adaptive Faster R-CNN for Object Detection in the Wild'. arXiv, Mar. 08, 2018. Accessed: Sep. 05, 2023. [Online]. Available: <http://arxiv.org/abs/1803.03243>
- [46] L. Hoyer, D. Dai, H. Wang, and L. Van Gool, 'MIC: Masked Image Consistency for Context-Enhanced Domain Adaptation'. arXiv, Mar. 24, 2023. Accessed: Sep. 06, 2023. [Online]. Available: <http://arxiv.org/abs/2212.01322>
- [47] G. Mattolin, L. Zanella, E. Ricci, and Y. Wang, 'ConfMix: Unsupervised Domain Adaptation for Object Detection via Confidence-based Mixing'. arXiv, Oct. 20, 2022. Accessed: Sep. 06, 2023. [Online]. Available: <http://arxiv.org/abs/2210.11539>
- [48] J. Hoffman *et al.*, 'CyCADA: Cycle-Consistent Adversarial Domain Adaptation'. arXiv, Dec. 29, 2017. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/1711.03213>
- [49] M. Ghifary, W. B. Kleijn, M. Zhang, D. Balduzzi, and W. Li, 'Deep Reconstruction-Classification Networks for Unsupervised Domain Adaptation'. arXiv, Aug. 01, 2016. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/1607.03516>
- [50] T. Kim, M. Cha, H. Kim, J. K. Lee, and J. Kim, 'Learning to Discover Cross-Domain Relations with Generative Adversarial Networks'. arXiv, May 15, 2017. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/1703.05192>
- [51] V. F. Arruda *et al.*, 'Cross-Domain Car Detection Using Unsupervised Image-to-Image Translation: From Day to Night', in *2019 International Joint Conference on Neural Networks (IJCNN)*, Jul. 2019, pp. 1–8. doi: 10.1109/IJCNN.2019.8852008.
- [52] J. Wu *et al.*, 'Target-Relevant Knowledge Preservation for Multi-Source Domain Adaptive Object Detection'. arXiv, Apr. 17, 2022. Accessed: Sep. 06, 2023. [Online]. Available: <http://arxiv.org/abs/2204.07964>
- [53] H.-K. Hsu *et al.*, 'Progressive Domain Adaptation for Object Detection'. arXiv, Oct. 24, 2019. Accessed: Sep. 05, 2023. [Online]. Available: <http://arxiv.org/abs/1910.11319>
- [54] T. Kim, M. Jeong, S. Kim, S. Choi, and C. Kim, 'Diversify and Match: A Domain Adaptive Representation Learning Paradigm for Object Detection'. arXiv, May 14, 2019. Accessed: Sep. 05, 2023. [Online]. Available: <http://arxiv.org/abs/1905.05396>
- [55] A. Tarvainen and H. Valpola, 'Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results'. arXiv, Apr. 16, 2018. Accessed: Sep. 02, 2023. [Online]. Available: <http://arxiv.org/abs/1703.01780>

- [56] G. French, M. Mackiewicz, and M. Fisher, 'Self-ensembling for visual domain adaptation'. arXiv, Sep. 23, 2018. Accessed: Sep. 02, 2023. [Online]. Available: <http://arxiv.org/abs/1706.05208>
- [57] X. Peng, Q. Bai, X. Xia, Z. Huang, K. Saenko, and B. Wang, 'Moment Matching for Multi-Source Domain Adaptation'. arXiv, Aug. 27, 2019. Accessed: Sep. 01, 2023. [Online]. Available: <http://arxiv.org/abs/1812.01754>
- [58] S. Motiian, Q. Jones, S. M. Iranmanesh, and G. Doretto, 'Few-Shot Adversarial Domain Adaptation'. arXiv, Nov. 05, 2017. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/1711.02536>
- [59] A. Zhao *et al.*, 'Domain-Adaptive Few-Shot Learning'. arXiv, Mar. 19, 2020. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/2003.08626>
- [60] X. Yue *et al.*, 'Prototypical Cross-domain Self-supervised Learning for Few-shot Unsupervised Domain Adaptation'. arXiv, Mar. 30, 2021. Accessed: Sep. 04, 2023. [Online]. Available: <http://arxiv.org/abs/2103.16765>
- [61] Y. Gao, K.-Y. Lin, J. Yan, Y. Wang, and W.-S. Zheng, 'AsyFOD: An Asymmetric Adaptation Paradigm for Few-Shot Domain Adaptive Object Detection'.
- [62] J. Na, H. Jung, H. J. Chang, and W. Hwang, 'FixBi: Bridging Domain Spaces for Unsupervised Domain Adaptation'. arXiv, Mar. 25, 2021. Accessed: Sep. 18, 2023. [Online]. Available: <http://arxiv.org/abs/2011.09230>
- [63] A. Bituiskii, 'Unsupervised Domain Adaptation with Deep Neural-Network'. arXiv, Jul. 10, 2023. Accessed: Sep. 18, 2023. [Online]. Available: <http://arxiv.org/abs/2307.05601>
- [64] G. Degola, 'Approaches for Domain Adaptive Object Detection in Production Environments'.
- [65] Y. Yang, 'Unsupervised domain adaptation for object detection and whole slide image classification'.
- [66] 'توسعه ی شبکه های تقابلی عمیق برای تطبیق دامنه'.pdf.
- [67] 'ارائه یک چهارچوب جامع برای تطبیق دامنه و وجه در داده های چند وجهی'.pdf.
- [68] M. Johnson-Roberson, C. Barto, R. Mehta, S. N. Sridhar, K. Rosaen, and R. Vasudevan, 'Driving in the Matrix: Can Virtual Worlds Replace Human-Generated Annotations for Real World Tasks?' arXiv, Feb. 25, 2017. Accessed: Sep. 05, 2023. [Online]. Available: <http://arxiv.org/abs/1610.01983>
- [69] W.-G. Chang, T. You, S. Seo, S. Kwak, and B. Han, 'Domain-Specific Batch Normalization for Unsupervised Domain Adaptation'. arXiv, May 27, 2019. Accessed: Sep. 16, 2023. [Online]. Available: <http://arxiv.org/abs/1906.03950>

In the name of God



*Malek Ashtar University
of Technology*

Malek-ashtar University of Technology

Faculty of Electrical and Computer

M.Sc. Seminar

Title

**Domain adaptation in deep neural networks
for object detection applications when using
synthetic training data**

By

Helia Mohamadi

Supervised by

Dr. Mohammad Ali Keyvanrad

September. 2023