

پیشنهاد پایان نامه مقطع کارشناسی ارشد

کمیته محترم تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر

احتراماً، اینجانب امیررضا کاظم لو به شماره دانشجویی ۴۰۳۱۴۱۹۰۱۳ دانشجوی کارشناسی ارشد رشته مهندسی کامپیوتر گرایش هوش مصنوعی و رباتیک شاغل در - که تحصیلات خود را در رشته فوق از نیمسال اول سال تحصیلی ۱۴۰۳ شروع نمودم و تاکنون تعداد ۹ واحد از دروس اصلی و اختصاصی را با موفقیت و با معدل کل ۲۰ گذرانده‌ام در مرحله شروع پایان نامه خود هستم.

پس از انجام مشاوره‌های لازم و با عنایت به زمینه علمی موردنیاز، آقای دکتر محمدعلی کیوان راد را بعنوان استاد راهنمای پایان نامه انتخاب کردم و با استفاده از نظرات و راهنماییهای ایشان پس از بررسی و مطالعه دقیق موضوع تحقیق، موضوع پایان نامه خود را کتباً و در قالب فرم پیوست تقدیم می‌نمایم. بدیهی است پذیرش قطعی موضوع پایان نامه منوط بر تصویب آن در کمیته می‌باشد.

ضمناً با پیشنهاد استاد راهنمای پایان نامه آقای - را نیز بعنوان استاد مشاور انتخاب نموده‌ام.

تاریخ: ۱۴۰۴/۰۷/۲۰



امضاء دانشجو

عنوان کامل پایان نامه :

نوع پروژه:

بدون طبقه‌بندی	محرمانه	خیلی محرمانه	سری	بکلی سری
----------------	---------	--------------	-----	----------

مراتب فوق مورد تأیید است:

- | | |
|---------------|--|
| تاریخ و امضاء | ۱ - نام و نام خانوادگی استاد راهنما
دکتر محمد علی کیوان راد |
| تاریخ و امضاء | ۲ - نام و نام خانوادگی استاد مشاور |
| تاریخ و امضاء | ۳ - نام و نام خانوادگی کارشناس آموزش و تحصیلات تکمیلی مجتمع |
| تاریخ و امضاء | ۴ - نام و نام خانوادگی مدیریت آموزش و تحصیلات تکمیلی مجتمع |

بسمه تعالی
دانشگاه صنعتی مالمک اشتر
معاونت آموزش و تحصیلات تکمیلی

پرسشنامه تهیه پیشنهاد اولیه (پروپوزال) جهت پایان نامه کارشناسی ارشد

نام و نام خانوادگی دانشجو : امیررضا کاظم لو

شماره دانشجویی : ۴۰۳۱۴۱۹۰۱۳

رشته و گرایش تحصیلی : مهندسی کامپیوتر - گرایش هوش مصنوعی و رباتیک

عنوان پایان نامه :

به فارسی : تطبیق دامنه بدون منبع (Source-Free Domain Adaptation) برای تشخیص اشیاء با استفاده از یادگیری خود-محور و مدل های پایه

به لاتین : Source-Free Domain Adaptation for Object Detection using Self-Driven Learning and Foundation Models

نوع تحقیق :

☐ بنیادی ☐ توسعه ای ☐ کاربردی

1 - اطلاعات مربوط به دانشجو :

1-1- تعداد واحدهای گذرانده : ۱۲ تعداد واحدهای باقیمانده : ۲۱ معدل (تاکنون) : ۲۰

1-2- آدرس : تهران، شهرک ولی عصر خیابان آقابابایان، کوچه گلنار، پلاک ۲۳، طبقه اول

1-2-1- شماره تلفن ثابت : ۰۲۱۶۶۱۳۳۵۷۱ 1-2-2- شماره تلفن همراه: ۰۹۱۰۱۷۲۷۲۳۴

1-3 - در صورت بورسیه بودن، نام سازمان بورسیه دهنده :

2 - اطلاعات مربوط به اساتید راهنما و مشاور :

سمت	نام و نام خانوادگی	تخصص یا رشته	رتبه علمی	تعداد پایان نامه های راهنمایی شده		تعداد پایان نامه های تحت راهنمایی	
				ارشد	دکتری	ارشد	دکتری
استاد راهنمای اول							
استاد راهنمای دوم							
استاد مشاور							

* تذکر : در صورتی که اساتید فوق عضو هیأت علمی دانشگاه صنعتی مالمک اشتر نمی باشند؛ آدرس و شماره تلفن آن ها ذیلاً قید شود.
آدرس استاد (اساتید) راهنما :

شماره تلفن استاد (اساتید) راهنما :

آدرس استاد مشاور :

شماره تلفن استاد مشاور :

3- اطلاعات مربوط به پایان نامه :

3-1- مسئله و اهداف اصلی تحقیق :

مسئله تحقیق

تشخیص اشیاء (Object Detection) یکی از وظایف بنیادین در حوزه بینایی ماشین است که کاربردهای حیاتی در زمینه‌هایی مانند خودروهای خودران، نظارت تصویری، رباتیک و تصویربرداری پزشکی دارد. مدل‌های یادگیری عمیق، به ویژه شبکه‌های عصبی کانولوشنی (CNNs)، به موفقیت‌های چشمگیری در این زمینه دست یافته‌اند. با این حال، عملکرد این مدل‌ها به شدت به یک فرض کلیدی وابسته است: داده‌های آموزش و آزمون باید از توزیع یکسانی پیروی کنند.

در دنیای واقعی، این فرض تقریباً هرگز برقرار نیست. یک مدل تشخیص اشیاء که بر روی داده‌های یک دامنه (مانند تصاویر شبیه‌سازی شده یا تصاویر گرفته شده در روز) آموزش دیده است، هنگام مواجهه با داده‌های یک دامنه دیگر (مانند تصاویر واقعی یا تصاویر گرفته شده در شب) با افت عملکرد شدید مواجه می‌شود. این پدیده که به «شکاف دامنه» (Domain Shift) معروف است، مانع اصلی بر سر راه استقرار قابل اعتماد این سیستم‌ها در محیط‌های پویا و کنترل نشده است.

برای غلبه بر این چالش، تطبیق دامنه (Domain Adaptation - DA) به عنوان یک راه‌حل کلیدی مطرح شده است. هدف DA، انتقال دانش از یک دامنه منبع (Source Domain) غنی از داده‌های برچسب‌دار به یک دامنه هدف (Target Domain) است که در آن برچسبی وجود ندارد. (Unsupervised Domain Adaptation - UDA) در سال‌های اخیر، تمرکز اصلی بر روی سناریوی انتقال از داده‌های مصنوعی به واقعی (Synth-to-Real) بوده است، زیرا تولید داده‌های مصنوعی برچسب‌دار ارزان و مقیاس‌پذیر است، اما این داده‌ها شکاف بصری قابل توجهی با دنیای واقعی دارند. با این حال، اکثر روش‌های تطبیق دامنه کلاسیک با یک محدودیت عملی بزرگ روبرو هستند: آن‌ها نیازمند دسترسی همزمان به داده‌های هر دو دامنه منبع و هدف در طول فرآیند آموزش هستند. این امر در بسیاری از کاربردهای واقعی به دلایل زیر غیرممکن یا نامطلوب است:

1. حریم خصوصی و امنیت داده: شرکت‌ها و مؤسسات ممکن است به دلیل محرمانگی یا مالکیت معنوی، تمایلی به اشتراک‌گذاری مجموعه داده‌های منبع (مثلاً داده‌های شبیه‌ساز اختصاصی خود) نداشته باشند.
2. حجم عظیم داده: مجموعه داده‌های منبع می‌تواند بسیار حجیم (در حد ترابایت) باشند و انتقال و ذخیره‌سازی آن‌ها برای هر فرآیند تطبیق، غیرعملی است.

این محدودیت‌ها، یک سناریوی جدید، چالش‌برانگیز و بسیار واقع‌گرایانه را به نام تطبیق دامنه بدون منبع (Source-Free Domain Adaptation - SFDA) به وجود آورده است. در SFDA، ما تنها به یک مدل از پیش آموزش‌دیده بر روی دامنه منبع و داده‌های بدون برچسب دامنه هدف دسترسی داریم. مسئله اصلی در اینجا این است: چگونه می‌توان دانش مدل را به دامنه هدف جدید تطبیق داد، بدون آنکه به داده‌های اصلی منبع دسترسی داشته باشیم و همزمان از فراموشی فاجعه‌بار (Catastrophic Forgetting) دانش اولیه جلوگیری کنیم؟ این پژوهش قصد دارد تا با تمرکز بر این مسئله خطیر، به طراحی و ارزیابی روش‌های نوآورانه در چارچوب SFDA برای وظیفه تشخیص اشیاء بپردازد.

اهداف اصلی تحقیق

در راستای حل مسئله فوق، اهداف اصلی و گام‌های اجرایی این پژوهش به شرح زیر تعریف می‌گردد:

1. طراحی و پیاده‌سازی یک چارچوب نوآورانه برای تطبیق دامنه بدون منبع (SFDA) در وظیفه تشخیص اشیاء.
 - این هدف اصلی تحقیق است که بر روی توسعه یک الگوریتم جدید با تمرکز بر یادگیری خود-محور (Self-Driven Learning) و معماری Teacher-Student متمرکز خواهد بود.
2. بهبود کیفیت و کاهش نویز در فرآیند خود-آموزی (Self-Training).
 - ارائه یک مکانیزم هوشمند برای پالایش شبه-برچسب‌ها (Pseudo-Labels) با استفاده از دانش معنایی استخراج‌شده از مدل‌های پایه بزرگ مانند CLIP به منظور جلوگیری از انباشت خطا در طی فرآیند تطبیق.
3. جلوگیری از فراموشی فاجعه‌بار (Catastrophic Forgetting) در غیاب داده‌های منبع.
 - توسعه یک روش کارآمد برای بازسازی یا تولید ویژگی‌های آماری دامنه منبع به منظور حفظ دانش اولیه مدل در حین سازگاری با دامنه هدف.
4. ارزیابی جامع و مقایسه عملکرد روش پیشنهادی.

- سنجش دقت و کارایی روش طراحی شده بر روی مجموعه داده‌های استاندارد و بنچمارک‌های شناخته شده در حوزه تطبیق دامنه مانند Cityscapes و Foggy Cityscapes
- اعتبارسنجی عملی روش بر روی یک مجموعه داده کاربردی و جدید در حوزه تشخیص کشتی به منظور نمایش قابلیت‌های آن در یک سناریوی واقعی.

5. تحلیل و بررسی میزان تأثیرگذاری مؤلفه‌های پیشنهادی.

- انجام یک مطالعه جامع (Ablation Study) برای ارزیابی نقش و اهمیت هر یک از نوآوری‌های پیشنهادی (مانند مازول پالایش شبه-برچسب و مکانیزم جلوگیری از فراموشی) در عملکرد نهایی مدل.

2-3 - تشریح و بیان موضوع :

اهمیت و چالش تشخیص اشیاء در دنیای واقعی

تشخیص اشیاء (Object Detection) به عنوان یکی از وظایف بنیادین و محوری در حوزه بینایی ماشین، به دنبال شناسایی و مکان‌یابی اشیاء مختلف در تصاویر و ویدئوها است. این فناوری، ستون فقرات بسیاری از کاربردهای حیاتی و مدرن، از جمله سیستم‌های ناوبری خودروهای خودران، رباتیک هوشمند، نظارت تصویری پیشرفته، تحلیل تصاویر پزشکی و مدیریت ترافیک دریایی را تشکیل می‌دهد. در سال‌های اخیر، مدل‌های یادگیری عمیق، به ویژه شبکه‌های عصبی کانولوشنی (CNNs)، با دستیابی به دقت‌های بی‌سابقه، این حوزه را متحول کرده‌اند.

با این حال، موفقیت چشمگیر این مدل‌ها به یک پیش‌فرض اساسی و در عین حال شکننده وابسته است: داده‌های مورد استفاده در مرحله آموزش و مرحله آزمون باید از یک توزیع آماری یکسان پیروی کنند. این فرض در محیط‌های کنترل شده آزمایشگاهی برقرار است، اما در دنیای واقعی به ندرت صدق می‌کند. یک مدل که با دقت بالا بر روی داده‌های یک دامنه (Domain) خاص (مانند تصاویر شبیه‌سازی شده کامپیوتری یا تصاویر ثبت شده در شرایط آب و هوایی آفتابی) آموزش دیده است، هنگام مواجهه با یک دامنه جدید (مانند تصاویر واقعی یا تصاویر ثبت شده در مه یا شب) با افت عملکرد شدید و غیرمنتظره‌ای روبرو می‌شود. این پدیده که به شکاف دامنه (Domain Shift) یا عدم تطابق دامنه (Domain Mismatch) معروف است، بزرگترین مانع بر سر راه استقرار امن و قابل اعتماد سیستم‌های تشخیص اشیاء در کاربردهای دنیای واقعی محسوب می‌شود.

تطبیق دامنه (Domain Adaptation) به عنوان راه حل

برای غلبه بر چالش شکاف دامنه، حوزه تحقیقاتی «تطبیق دامنه (Domain Adaptation - DA)» ظهور کرده است. هدف اصلی DA، انتقال دانش آموخته شده از یک دامنه منبع (Source Domain) که در آن داده‌های برچسب دار فراوانی وجود دارد، به یک دامنه هدف (Target Domain) است که در آن داده‌ها فاقد برچسب هستند) سناریوی تطبیق دامنه بدون نظارت یا UDA در سال‌های اخیر، سناریوی انتقال از داده‌های مصنوعی به واقعی (Synth-to-Real) به دلیل سهولت و هزینه پایین تولید داده‌های مصنوعی برچسب دار، توجه ویژه‌ای را به خود جلب کرده است.

روش‌های تطبیق دامنه برای تشخیص اشیاء در طول زمان تکامل یافته‌اند و می‌توان آن‌ها را به چند دسته اصلی تقسیم کرد:

1. روش‌های مبتنی بر اختلاف (Discrepancy-Based): این روش‌های پیشگام با استفاده از معیارهای آماری مانند [1] MMD، تلاش می‌کنند تا توزیع کلی ویژگی‌ها را در دو دامنه به یکدیگر نزدیک کنند [2].
2. روش‌های مبتنی بر یادگیری تخاصمی (Adversarial-Based): این رویکرد که با الهام از شبکه‌های مولد تخاصمی (GANs) [3] و مقاله [4] DANN شکل گرفت، از یک تفکیک کننده دامنه برای آموزش استخراج کننده ویژگی به منظور تولید ویژگی‌های نامتمایز از دامنه استفاده می‌کند. این ایده در مقالات متعددی مانند Domain Adaptive Faster R-CNN برای هم‌ترازی ویژگی‌ها در سطوح مختلف (تصویر و نمونه) به کار گرفته شد.
3. روش‌های مبتنی بر خود-آموزی (Self-Training): این پارادایم مدرن، به جای هم‌ترازی صریح توزیع‌ها، بر تولید شبه-برچسب (Pseudo-Labels) برای داده‌های هدف و آموزش مدل به صورت خود-نظارت شده متمرکز است.

معماری Teacher-Student [6], [5] که در آن یک مدل «معلم» پایدار، مدل «دانش‌آموز» را هدایت می‌کند، سنگ بنای این رویکرد است و در روش‌های پیشرفته‌ای مانند MIC به کار رفته است.

ظهور یک چالش جدید و واقع‌گرایانه: تطبیق دامنه بدون منبع (SFDA)

با وجود تمام پیشرفت‌ها، تقریباً تمام روش‌های ذکر شده بر یک پیش‌فرض کلیدی استوارند: نیاز به دسترسی همزمان به داده‌های هر دو دامنه منبع و هدف در طول فرآیند آموزش. این پیش‌فرض در بسیاری از سناریوهای عملی، یک محدودیت جدی و گاهی غیرقابل عبور است:

- حریم خصوصی و مالکیت داده: شرکت‌ها و مؤسسات به دلایل امنیتی و رقابتی، حاضر به اشتراک‌گذاری داده‌های منبع خود (مانند شبیه‌سازهای اختصاصی یا داده‌های بالینی) نیستند.
 - هزینه و حجم داده: مجموعه داده‌های منبع مدرن می‌توانند چندین ترابایت حجم داشته باشند. انتقال، ذخیره‌سازی و پردازش این حجم از داده برای هر کاربر نهایی که قصد تطبیق مدل را دارد، غیرعملی است.
- این موانع عملی، منجر به تعریف یک مسئله جدید، پیچیده‌تر و بسیار کاربردی‌تر به نام تطبیق دامنه بدون منبع (Source-Free Domain Adaptation - SFDA) شده است. در این سناریو، تنها دارایی‌های ما عبارتند از:

1. یک مدل از پیش آموزش‌دیده بر روی دامنه منبع.

2. داده‌های بدون برچسب از دامنه هدف.

مسئله اصلی تحقیق در اینجا شکل می‌گیرد: چگونه می‌توان دانش نهفته در مدل از پیش آموزش‌دیده را به دامنه هدف جدید منتقل کرد، بدون آنکه به داده‌های اصلی منبع دسترسی داشته باشیم؟ این فرآیند باید به گونه‌ای هوشمندانه انجام شود که نه تنها مدل با دامنه جدید سازگار شود، بلکه از فراموشی فاجعه‌بار (Catastrophic Forgetting) دانش ارزشمندی که در مرحله اولیه آموخته است نیز جلوگیری به عمل آید. این پژوهش قصد دارد تا با تمرکز بر این چالش کلیدی، روش‌هایی نوآورانه برای وظیفه تشخیص اشیاء در چارچوب SFDA ارائه دهد.

3-3 - ضرورت انجام تحقیق :

انجام این پژوهش با توجه به شکاف‌های موجود میان دستاوردهای آکادمیک و نیازهای عملی در دنیای واقعی، از ضرورت بالایی برخوردار است. این ضرورت را می‌توان در سه جنبه اصلی تشریح کرد:

۱. ضرورت عملی و صنعتی: عبور از محدودیت‌های استقرار مدل‌های هوشمند

اگرچه مدل‌های تشخیص اشیاء به دقت‌های بالایی در محیط‌های آزمایشگاهی دست یافته‌اند، استقرار موفق آن‌ها در دنیای واقعی با یک مانع بزرگ روبرو است: شکنندگی در برابر تغییر دامنه. یک سیستم نظارتی که در یک شهر آموزش دیده، ممکن است در شهر دیگر به دلیل تفاوت در معماری یا شرایط نوری، عملکرد ضعیفی داشته باشد. راه‌حل‌های تطبیق دامنه کلاسیک، با پیش‌فرض دسترسی کامل به داده‌های منبع، این مشکل را در تئوری حل می‌کنند، اما در عمل با موانع جدی مواجه هستند:

- حریم خصوصی و مالکیت معنوی: شرکت‌ها و سازمان‌ها به هیچ وجه حاضر به اشتراک‌گذاری داده‌های اختصاصی و ارزشمند خود (مانند داده‌های شبیه‌سازهای پیشرفته یا داده‌های بالینی) نیستند.
- هزینه و مقیاس‌پذیری: انتقال و پردازش حجم عظیم داده‌های منبع برای هر کاربر نهایی که نیاز به تطبیق مدل دارد، از نظر اقتصادی و فنی غیرعملی است.

بنابراین، ضرورت حرکت به سمت پارادایم «تطبیق دامنه بدون منبع (SFDA)» (یک انتخاب نیست، بلکه یک الزام برای ساخت سیستم‌های هوشمند، مقیاس‌پذیر، امن و قابل اعتماد در دنیای واقعی است. این تحقیق به طور مستقیم به این نیاز صنعتی پاسخ می‌دهد و راه را برای توسعه محصولات هموار می‌کند که می‌توانند به راحتی توسط کاربران نهایی برای محیط‌های جدید، بدون نیاز به دسترسی به داده‌های محرمانه اولیه، سفارشی‌سازی شوند.

۲. ضرورت علمی: حرکت به سمت مرزهای جدید دانش در یادگیری ماشین

حوزه SFDA در تقاطع چندین شاخه کلیدی و پیشرفته یادگیری ماشین قرار دارد، از جمله:

- یادگیری انتقالی (Transfer Learning): چگونه می‌توان دانش را به صورت مؤثر منتقل کرد، زمانی که دسترسی به منبع اصلی دانش قطع شده است؟
 - یادگیری مستمر (Continual Learning): چگونه می‌توان دانش جدید را آموخت بدون آنکه دانش قبلی فراموش شود (جلوگیری از فراموشی فاجعه‌بار)؟
 - یادگیری خود-نظارت شده (Self-Supervised Learning): چگونه می‌توان از ساختار خود داده‌های هدف برای هدایت فرآیند یادگیری استفاده کرد؟
- پژوهش در زمینه SFDA برای وظیفه پیچیده‌ای مانند تشخیص اشیاء، به ناچار منجر به نوآوری در این حوزه‌های بنیادین می‌شود. طراحی الگوریتم‌هایی که بتوانند دانش را از یک مدل «جعبه سیاه» استخراج کنند، آن را در برابر فراموشی مقاوم سازند و به صورت هوشمندانه با داده‌های جدید تطبیق دهند، به پیشبرد مرزهای دانش در هوش مصنوعی کمک شایانی می‌کند.

۳. ضرورت کاربردی: افزایش ایمنی و قابلیت اطمینان در حوزه‌های حساس (مانند رانندگی خودران)

این تحقیق با تمرکز بر روی یک مجموعه داده کاربردی مانند تشخیص خودرو، اهمیت عملی خود را دوچندان می‌کند. سیستم‌های رانندگی خودران (Autonomous Driving) و دستیارهای پیشرفته راننده (ADAS) برای درک محیط اطراف، جلوگیری از تصادفات و اتخاذ تصمیمات ایمن، به شدت به تشخیص دقیق و قابل اعتماد سایر وسایل نقلیه، عابران پیاده و موانع در شرایط مختلف آب و هوایی (آفتابی، بارانی، مه‌آلود، برفی)، نوری (روز و شب) و جغرافیایی (شهرهای مختلف با معماری و علائم متفاوت) وابسته هستند.

مدلی که تنها در شرایط ایده‌آل یا در یک منطقه جغرافیایی خاص آموزش دیده باشد، در یک محیط واقعی و پویا کارایی خود را به سرعت از دست می‌دهد و می‌تواند منجر به تصمیمات فاجعه‌بار و به خطر افتادن جان انسان‌ها شود. انجام این تحقیق و ارائه یک روش تطبیق دامنه قوی و بدون نیاز به منبع، گامی مستقیم و ضروری در جهت افزایش ایمنی، قابلیت اطمینان و تسریع در توسعه خودروهای خودران، یعنی یکی از تحول‌آفرین‌ترین صنایع جهان، خواهد بود. بنابراین، این پژوهش نه تنها به یک چالش علمی مهم پاسخ می‌دهد، بلکه یک راه‌حل عملی برای یکی از بزرگترین موانع موجود بر سر راه استفاده گسترده و قابل اعتماد از هوش مصنوعی در دنیای واقعی ارائه می‌کند.

3-4 - سابقه تحقیقات و مطالعات انجام گرفته :

حوزه تطبیق دامنه (Domain Adaptation) در سال‌های اخیر، به ویژه برای وظایف پیچیده بینایی ماشین مانند تشخیص اشیاء، شاهد رشد و تکامل چشمگیری بوده است. سیر تکاملی این پژوهش‌ها را می‌توان به عنوان حرکتی از راهکارهای کلی و سراسری به سمت روش‌های دقیق، ساختاریافته و در نهایت، خود-محور و مستقل از منبع، خلاصه کرد. در ادامه، این سیر تکاملی در چند دسته اصلی مورد بررسی قرار می‌گیرد.

1. روش‌های مبتنی بر اختلاف (Discrepancy-Based Methods)

این دسته از روش‌ها، به عنوان اولین تلاش‌ها برای مقابله با شکاف دامنه، بر این اصل استوار بودند که با کمینه کردن یک معیار فاصله آماری بین توزیع ویژگی‌های استخراج شده از دامنه‌های منبع و هدف، می‌توان دانش را منتقل کرد. معروف‌ترین معیار مورد استفاده در این روش‌ها، Maximum Mean Discrepancy (MMD) است که در فضاهای کرنل با ابعاد بالا، فاصله بین دو توزیع را اندازه‌گیری می‌کند. مقالات پیشگامی مانند [5] Deep Domain Confusion (DDC) با افزودن یک لایه تطبیق MMD به انتهای شبکه‌های عصبی عمیق، این ایده را پیاده‌سازی کردند.

- نقاط قوت: سادگی مفهومی و پیاده‌سازی آسان.

- نقد و محدودیت: این روش‌ها یک هم‌ترازی کلی (Global Alignment) را انجام می‌دهند و فرض می‌کنند که توزیع داده‌ها تک-حالتی (unimodal) است. این فرض برای وظیفه پیچیده‌ای مانند تشخیص اشیاء که توزیع ویژگی‌ها به شدت چند-حالتی (multi-modal) و وابسته به کلاس‌های مختلف است، صحیح نبوده و منجر به هم‌ترازی ناقص و عملکرد ضعیف می‌شود.

۲. روش‌های مبتنی بر یادگیری تخصصی (Adversarial-Based Methods)

با الهام از موفقیت چشمگیر شبکه‌های مولد تخصصی [12] (GANs)، این پارادایم به سرعت به رویکرد غالب در تطبیق دامنه تبدیل شد. ایده اصلی در مقاله [13] Domain-Adversarial Neural Networks (DANN) معرفی شد که در آن، یک تفکیک‌کننده دامنه (Domain Discriminator) به شبکه اضافه می‌شود. این تفکیک‌کننده تلاش می‌کند تا تشخیص دهد که یک ویژگی ورودی متعلق به دامنه منبع است یا هدف. همزمان، شبکه استخراج‌کننده ویژگی در یک بازی مینی‌مکس، تلاش می‌کند تا ویژگی‌هایی تولید کند که تفکیک‌کننده را "فریب" داده و قادر به تشخیص دامنه آن‌ها نباشد. این فرآیند، شبکه را به سمت یادگیری ویژگی‌های نامتغیر از دامنه (domain-invariant) سوق می‌دهد. برای وظیفه تشخیص اشیاء، مقاله Domain Adaptive Faster R-CNN [21] این ایده را با معرفی یک مکانیزم هم‌ترازی چندسطحی (در سطح تصویر و در سطح نمونه یا instance) به کار برد و به نتایج قابل توجهی دست یافت.

- نقاط قوت: توانایی یادگیری هم‌ترازی‌های پیچیده و غیرخطی.
- نقد و محدودیت: فرآیند آموزش تخصصی می‌تواند ناپایدار باشد و به تنظیم دقیق هایپرپارامترها نیاز دارد. همچنین، در صورت عدم تعادل کلاس‌ها یا تفاوت زیاد بین دامنه‌ها، ممکن است منجر به هم‌ترازی منفی (negative transfer) شود.

۳. روش‌های مبتنی بر بازسازی و ترجمه تصویر (Reconstruction-Based Methods)

این دسته از روش‌ها به جای هم‌تراز کردن ویژگی‌ها در یک فضای نهان، به دنبال کاهش شکاف دامنه در سطح پیکسل هستند. با استفاده از مدل‌های ترجمه تصویر-به-تصویر مانند [15] CycleGAN، این روش‌ها تلاش می‌کنند تا تصاویر دامنه منبع را به سبک بصری دامنه هدف ترجمه کنند. سپس، مدل تشخیص اشیاء بر روی این داده‌های منبع "سبک‌دهی شده" آموزش می‌بیند. مقاله [28] CyCADA یک نمونه برجسته از این رویکرد است که سازگاری را هم در سطح پیکسل و هم در سطح ویژگی اعمال می‌کند.

- نقاط قوت: به صورت شهودی جذاب هستند و به طور مستقیم با تفاوت‌های ظاهری دامنه‌ها مقابله می‌کنند.
- نقد و محدودیت: این روش‌ها از نظر محاسباتی بسیار پرهزینه هستند. فرآیند ترجمه تصویر ممکن است مصنوعات (artifacts) ناخواسته ایجاد کند یا محتوای معنایی مهم تصویر را تغییر دهد که به عملکرد مدل نهایی آسیب می‌زند.

۴. روش‌های مبتنی بر خود-آموزی (Self-Training Methods)

این پارادایم مدرن که در سال‌های اخیر به نتایج پیشرفته‌ای (State-of-the-Art) دست یافته است، رویکردی متفاوت را در پیش می‌گیرد. به جای هم‌ترازی صریح توزیع‌ها، این روش‌ها بر تولید شبه-برچسب (Pseudo-Labels) برای داده‌های بدون برچسب دامنه هدف و استفاده از آن‌ها برای آموزش مدل تمرکز دارند. سنگ بنای این رویکرد، معماری [42] Teacher-Student است. در این چارچوب، یک مدل «معلم» که نسخه‌ای پایدار و میانگین‌گیری شده (EMA) از مدل «دانش‌آموز» است، وظیفه تولید شبه-برچسب‌های باکیفیت و پایدار را بر عهده دارد و مدل دانش‌آموز از این برچسب‌ها برای یادگیری و تطبیق خود استفاده می‌کند. روش‌های نوآورانه‌ای مانند [22] MIC با استفاده از منظم‌سازی سازگاری بر روی تصاویر ماسک‌زده و [26] ConfMix با ترکیب نواحی با اطمینان بالا، به طور مؤثری با مشکل نویز در شبه-برچسب‌ها مقابله کرده و عملکرد را به طور چشمگیری بهبود بخشیده‌اند.

- نقاط قوت: کارایی بسیار بالا، عدم نیاز به هم‌ترازی صریح و قابلیت انطباق با سناریوهای پیچیده.
- نقد و محدودیت: موفقیت این روش‌ها به شدت به کیفیت شبه-برچسب‌های تولیدی وابسته است و در صورت وجود نویز زیاد، ممکن است مدل دچار انباشت خطا (error accumulation) شود.

شکاف تحقیقاتی و حرکت به سمت تطبیق دامنه بدون منبع (SFDA)

با وجود تمام پیشرفت‌های ذکر شده، یک فرض مشترک و محدودکننده در تمامی این روش‌ها وجود دارد: نیاز به دسترسی همزمان به داده‌های دامنه منبع و هدف. همانطور که در بخش بیان مسئله تشریح شد، این فرض در بسیاری از کاربردهای واقعی برقرار نیست. این محدودیت، منجر به شکل‌گیری حوزه تحقیقاتی نوپا، چالش‌برانگیز و بسیار مهم SFDA شده است. در این سناریو، هدف، تطبیق یک مدل از پیش آموزش‌دیده تنها با استفاده از داده‌های هدف است. کارهای اولیه در این حوزه عمدتاً بر روی روش‌هایی مانند تولید داده مجازی (Data Generation) از طریق یک شبکه مولد یا حفظ دانش منبع از طریق تکنیک‌های تقطیر دانش (Knowledge Distillation) تمرکز کرده‌اند. با این حال، این حوزه همچنان در ابتدای راه خود قرار دارد و جای خالی برای پژوهش در زمینه‌های زیر به شدت احساس می‌شود:

- طراحی روش‌های ترکیبی (Hybrid) که به طور همزمان از خود-آموزی، تولید داده و مکانیزم‌های جلوگیری از فراموشی بهره ببرند.
 - استفاده از دانش غنی موجود در مدل‌های پایه بزرگ (Foundation Models) مانند CLIP برای هدایت فرآیند تطبیق و بهبود کیفیت شبه-برچسب‌ها.
 - توسعه روش‌هایی برای افزایش قابلیت اطمینان (Reliability) و تفسیرپذیری (Interpretability) مدل تطبیق‌یافته در سناریوی SFDA.
- این پژوهش قصد دارد با تمرکز دقیق بر این شکاف‌های تحقیقاتی، یک راه حل نوآورانه و کارآمد برای مسئله SFDA در تشخیص اشیاء ارائه دهد.

3-5 - فرضیه‌های تحقیق (سؤالات تحقیق):

3-6 - نتایج مورد انتظار پس از انجام تحقیق:

3-7 - در صورت کاربردی بودن تحقیق، چه سازمان‌هایی می‌توانند از نتایج بدست آمده استفاده کنند.

ردیف	نام سازمان	نوع استفاده
1		
2		
3		

4 - روش انجام تحقیق:

4-1 - روش گردآوری اطلاعات:

4-2 - روش و مراحل تحقیق:

4-3 - قلمرو تحقیق:

این پژوهش با هدف ارائه یک راه‌حل نوآورانه در یک حوزه مشخص و پیشرفته از یادگیری ماشین انجام می‌شود. برای شفاف‌سازی و تعیین دقیق مرزهای تحقیق، قلمرو آن در سه حوزه موضوعی، روش‌شناسی و کاربردی به شرح زیر تعریف می‌گردد:

1. قلمرو موضوعی و مفهومی (Thematic and Conceptual Scope)

این تحقیق در حوزه کلی هوش مصنوعی و زیرشاخه‌های یادگیری ماشین و بینایی ماشین قرار می‌گیرد.

حوزه تخصصی: تمرکز اصلی پژوهش بر روی مبحث یادگیری انتقالی (Transfer Learning) و به طور خاص، تطبیق دامنه (Domain Adaptation) است.

مسئله کانونی: این تحقیق به طور مشخص به سناریوی پیشرفته و واقع‌گرایانه «تطبیق دامنه بدون منبع» (Source-Free Domain Adaptation - SFDA) می‌پردازد. این به آن معناست که فرض می‌شود در مرحله تطبیق، هیچ‌گونه دسترسی به داده‌های دامنه منبع وجود ندارد و تنها دارایی ما، یک مدل از پیش آموزش‌دیده و داده‌های بدون برچسب دامنه هدف است. وظیفه مورد بررسی در این پژوهش، تشخیص اشیاء (Object Detection) است که یک وظیفه پیچیده و ساختاریافته در بینایی ماشین محسوب می‌شود.

مفاهیم مرتبط: این تحقیق برای حل مسئله اصلی، مجموعه‌ای از مفاهیم پیشرفته را به کار می‌گیرد و در تقاطع آن‌ها قرار دارد:

- یادگیری مبتنی بر پروتوتایپ (Prototype-based Learning): به جای تکیه بر یک مدل معلم، تمرکز بر روی یادگیری و به‌روزرسانی نماینده‌های کلاسی (Class Prototypes) در فضای ویژگی خواهد بود. این پروتوتایپ‌ها به عنوان مراکز خوشه‌های هر کلاس عمل کرده و فرآیند تخصیص شبه-برچسب را هدایت می‌کنند.
- یادگیری تخصصی برای ساختارسازی فضای ویژگی (Adversarial Learning for Feature Space Structuring): برخلاف کاربرد کلاسیک یادگیری تخصصی برای هم‌ترازی بین دامنه‌ها، در این پژوهش از آن برای ساختارسازی درون دامنه هدف استفاده خواهد شد. یک مکانیزم تخصصی طراحی می‌شود تا مدل را مجبور به تولید ویژگی‌های منسجم و قابل تفکیک برای نمونه‌های با اطمینان بالا و پایین کند و در نتیجه، فشردگی خوشه‌ها را افزایش دهد.
- یادگیری خود-محور (Self-Driven Learning): کل فرآیند تطبیق به صورت خودکار و تنها با استفاده از اطلاعات استخراج‌شده از خود داده‌های هدف (مانند نزدیکی به پروتوتایپ‌ها) هدایت می‌شود.
- جلوگیری از فراموشی فاجعه‌بار (Catastrophic Forgetting): این مفهوم همچنان یک چالش کلیدی است و برای مقابله با آن، از تکنیک‌های بازسازی ویژگی (Feature Reconstruction) به منظور حفظ دانش اولیه مدل استفاده خواهد شد.

2. قلمرو روش‌شناسی (Methodological Scope)

چارچوب اصلی روش‌شناسی بر اساس پارادایم یادگیری مبتنی بر پروتوتایپ و خوشه‌بندی تخصصی (Prototype-based Learning and Adversarial Clustering) بنا خواهد شد. در این رویکرد، به جای تکیه بر پایداری یک مدل معلم، تمرکز بر روی ساختار ذاتی فضای ویژگی (Feature Space) در دامنه هدف خواهد بود. هدف، ایجاد خوشه‌های (Clusters) فشرده و با جدایی‌پذیری بالا برای هر کلاس، بدون دسترسی به برچسب‌های واقعی است.

نوآوری اصلی تحقیق در ادغام تکنیک‌های زیر با چارچوب اصلی خواهد بود:

- مقابله با فراموشی دانش از طریق بازسازی ویژگی: با استفاده از آمار لایه‌های کلیدی مدل از پیش آموزش‌دیده (مانند Batch Normalization)، یک شبکه مولد (Generator) آموزش داده می‌شود تا ویژگی‌هایی را تولید کند که توزیع دامنه منبع را تقلید می‌کنند. این ویژگی‌های مجازی برای حفظ دانش اولیه مدل در طی فرآیند تطبیق به کار گرفته می‌شوند.
- شروع فرآیند با پروتوتایپ‌های منبع: وزن‌های لایه طبقه‌بندی‌کننده (Classifier Head) مدل اولیه به عنوان نماینده یا پروتوتایپ اولیه برای هر کلاس در نظر گرفته می‌شوند.
- یادگیری تخصصی مبتنی بر خوشه‌بندی: یک تفکیک‌کننده (Discriminator) طراحی می‌شود که تلاش می‌کند تا ویژگی‌های نمونه‌های «نزدیک به پروتوتایپ» (نمونه‌های با اطمینان بالا) را از ویژگی‌های نمونه‌های «دور از پروتوتایپ» (نمونه‌های با عدم قطعیت بالا) تشخیص دهد. شبکه استخراج‌کننده ویژگی (Feature Extractor) به صورت تخصصی

آموزش می‌بیند تا ویژگی‌هایی تولید کند که این تفکیک‌کننده را فریب دهند. این فرآیند، مدل را مجبور می‌کند تا برای تمام نمونه‌های هدف، ویژگی‌هایی منسجم و نزدیک به مراکز کلاس تولید کند و در نتیجه، ساختار فضای ویژگی را بهینه می‌سازد.

- تولید شبه برجسب مبتنی بر نزدیکی به پروتوتایپ: شبه-برجسب‌ها برای داده‌های هدف، بر اساس میزان نزدیکی ویژگی‌های آن‌ها به پروتوتایپ‌های به‌روز شده هر کلاس، تعیین می‌شوند. این رویکرد، برخلاف تکیه صرف بر خروجی Softmax، از ساختار هندسی فضای ویژگی برای تصمیم‌گیری بهره می‌برد.

3. قلمرو کاربردی و داده‌ای (Application and Data Scope)

تمرکز اصلی بر روی سناریوی کاربردی و چالش‌برانگیز انتقال از داده‌های مصنوعی به واقعی (Synth-to-Real) خواهد بود. مجموعه داده‌های استاندارد: برای مقایسه با سایر روش‌های پیشرفته، از مجموعه داده‌های بنچمارک و شناخته‌شده در این حوزه مانند Cityscapes, Foggy Cityscapes و Sim10k استفاده خواهد شد. مجموعه داده کاربردی: به منظور نمایش کارایی عملی روش پیشنهادی، عملکرد آن بر روی یک مجموعه داده خاص در حوزه تشخیص خودرو ارزیابی خواهد شد تا قابلیت اطمینان آن در یک سناریوی حیاتی سنجیده شود.

4-4 - روشهای مورد نظر برای تجزیه و تحلیل اطلاعات و آزمون فرضیه‌ها :

5- نیازهای تحقیق :

5-1 - هزینه انجام تحقیق :

توضیحات	برآورد هزینه (ریال)	شرح هزینه
وابسته به استفاده از منابع دانشگاهی یا سرویس‌های ابری	۵۰۰-۰ میلیون	سخت‌افزار و توان پردازشی
تمامی منابع مورد نیاز رایگان هستند.	۰	نرم‌افزار و داده
تنها در صورت ارسال و پذیرش مقاله اعمال می‌شود.	۱۰۰ میلیون	انتشار نتایج
بسته به شرایط و انتخاب‌های موجود	۶۰۰-۰ میلیون	مجموع برآورد هزینه

5-2 - امکانات لازم (سخت‌افزاری - نرم‌افزاری و منابع و ...):

- پردازنده گرافیکی (GPU): دسترسی به یک یا چند پردازنده گرافیکی قدرتمند، مهم‌ترین نیاز سخت‌افزاری این تحقیق است. به دلیل پیچیدگی مدل‌های تشخیص اشیاء و نیاز به اجرای آزمایش‌های متعدد، استفاده از کارت‌های گرافیکی مدرن با حافظه VRAM بالا (ترجیحاً ۲۴ گیگابایت یا بیشتر) ضروری است. مدل‌های پیشنهادی شامل سری NVIDIA RTX مانند RTX 4090/5090 یا کارت‌های محاسباتی ویژه سرور مانند A100 می‌باشند.
- پردازنده مرکزی (CPU) و حافظه اصلی (RAM): یک پردازنده مرکزی چند-هسته‌ای مدرن و حافظه اصلی کافی (حداقل ۳۲ گیگابایت) برای پیش‌پردازش داده‌ها، مدیریت فرآیندهای آموزش و اجرای روان سیستم عامل ضروری است.
- حافظه ذخیره‌سازی: به دلیل حجم بالای مجموعه داده‌های تصویری، دسترسی به حافظه ذخیره‌سازی پرسرعت SSD ترجیحاً از نوع NVMe با ظرفیت کافی (حداقل ۱ ترابایت) برای تسریع فرآیند بارگذاری داده‌ها و کاهش زمان انتظار در طول آموزش مدل، الزامی است.

۲. امکانات نرم‌افزاری (Software)

- سیستم عامل: سیستم عامل لینوکس ترجیحاً توزیع Ubuntu به دلیل پشتیبانی گسترده و پایداری بالا در اکوسیستم یادگیری عمیق.
- زبان برنامه نویسی پایتون (Python) نسخه ۳.۸ یا بالاتر.
- چارچوب های یادگیری عمیق:
 - PyTorch: به عنوان چارچوب اصلی برای پیاده سازی، آموزش و ارزیابی مدل های تشخیص اشیاء.
- کتابخانه های کمک: کتابخانه های استاندارد علم داده و بینایی ماشینی مانند NumPy, OpenCV, Matplotlib و Scikit-learn برای پردازش تصویر، تحلیل نتایج و مصورسازی.
- محیط توسعه و مدیریت بسته ها: استفاده از Conda برای مدیریت محیط های مجازی و وابستگی های نرم افزاری پروژه.

۳. منابع داده و علمی (Data and Scientific Resources)

- مجموعه داده های استاندارد: دسترسی به مجموعه داده های عمومی و شناخته شده در حوزه تطبیق دامنه برای تشخیص اشیاء به منظور ارزیابی و مقایسه با سایر روش ها. این مجموعه داده ها عبارتند از:
 - Cityscapes: تصاویر واقعی از محیط های شهری.
 - Foggy Cityscapes: نسخه مه آلود از مجموعه داده Cityscapes برای شبیه سازی شرایط آب و هوایی نامساعد.
 - Sim10k: مجموعه داده مصنوعی شامل تصاویر از بازی کامپیوتری Grand Theft Auto V (GTAV)
- مجموعه داده کاربردی: دسترسی به مجموعه داده تشخیص ماشین (شامل داده های شبیه سازی شده و واقعی) که به عنوان یکی از اهداف اصلی تحقیق، برای اعتبارسنجی عملی روش پیشنهادی استفاده خواهد شد.
- منابع علمی: دسترسی به پایگاه های داده مقالات علمی مانند IEEE Xplore, ACM Digital Library, SpringerLink و وبسایت arXiv برای مطالعه مستمر آخرین دستاوردهای پژوهشی در این حوزه. این موارد می توانند از طریق gigalib و iranpaper قابل تامین هستند.

6 - حداکثر زمان مورد نیاز برای انجام تحقیق:

ردیف	فاز تحقیق	شرح فعالیت ها	حداکثر زمان تخصیص یافته (ماه)
۱	فاز اول: مطالعه و تعمیق در مسئله	مرور جامع و عمیق ادبیات موضوع، مطالعه مقالات کلیدی در حوزه های DA, UDA, SFDA دسته بندی و تحلیل دقیق روش های موجود. نهایی سازی ایده نوآورانه و صورت بندی دقیق مسئله تحقیق.	۳ ماه
۲	فاز دوم: آماده سازی و پیاده سازی پایه	-آماده سازی محیط برنامه نویسی و نصب کتابخانه های مورد نیاز مانند PyTorch CUDA, ... و جمع آوری، پیش پردازش و آماده سازی مجموعه داده های استاندارد و کاربردی. پیاده سازی و اجرای یک یا چند مدل پایه (Baseline) برای اطمینان از صحت خط لوله (Pipeline) و کسب نتایج اولیه.	۲ ماه
۳	فاز سوم: طراحی و پیاده سازی روش پیشنهادی	پیاده سازی کامل چارچوب اصلی مانند معماری و توسعه و پیاده سازی ماژول های نوآورانه مانند پالایش شبه-برچسب با CLIP و مکانیزم جلوگیری از فراموشی. ادغام، تست و رفع خطای (Debug) کامل کدهای نوشته شده.	۶ ماه

۴ ماه	اجرای سناریوهای اصلی آزمایش بر روی تمام مجموعه داده‌ها. اجرای آزمایش‌های مربوط به مطالعه مؤلفه‌ها (Ablation Study) برای سنجش تأثیر هر بخش از نوآوری. مقایسه نتایج به دست آمده با روش‌های پیشرفته (State-of-the-art). تحلیل دقیق نتایج، استخراج جداول، نمودارها و نتیجه‌گیری‌های علمی.	فاز چهارم: اجرای آزمایش‌ها و تحلیل نتایج	۴
۳ ماه	نگارش فصول مختلف پایان‌نامه/مقاله (مقدمه، کارهای پیشین، روش پیشنهادی، آزمایش‌ها، نتیجه‌گیری). آماده‌سازی اسلایدهای ارائه برای دفاع. بازبینی و اصلاح نهایی متن بر اساس بازخورد اساتید راهنما.	فاز پنجم: نگارش و تدوین نهایی	۵
۱۸ ماه	مجموع زمان		

۷- زمان‌بندی تحقیق (نمودار گانت):

زمان مورد نیاز	ماه اول	ماه دوم	ماه سوم	ماه چهارم	ماه پنجم	ماه ششم	ماه هفتم	ماه هشتم	ماه نهم	ماه دهم	ماه یازدهم	ماه دوازدهم
فاز اول												
فاز دوم												
فاز سوم												
فاز چهارم												
فاز پنجم												

۸- فهرست منابع و مأخذ:

* کلیه صفحات به صورت تایپ شده تحویل شوند.

9- نظریه شورای تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر
(دقت شود که این صفحه به طور مجزا تهیه و تکمیل شود)

پایان نامه دانشجو خانم / آقای

با موضوع پایان نامه..... به

راهنمایی آقای دکتر و استاد مشاور آقای دکتر..... در

شورای گروه علمی..... مورخ

مورد بررسی قرار و به تصویب رسید.

ردیف	نام و نام خانوادگی اعضاء گروه علمی	محل امضاء
1		
2		
3		
4		
5		
6		
7		
8		
9		

